

Le mille-feuille évolutionnaire, une nouvelle formalisation de l'évolution

Rémy Défossez - encadrants : Sergiu Ivanov et Nicolas Glade
Laboratoire TIMC-IMAG, Université Grenoble Alpes,
CNRS UMR5525, CHU Grenoble Alpes, Grenoble INP, 38700 La Tronche, France
Laboratoire IBISC, Université Paris-Saclay, Univ Évry, 91020, Évry-Courcouronnes, France

24 août 2021

Table des matières

1	Introduction	1
1.1	Réseaux d'interactions biologiques	1
1.2	Réseaux booléens à signe	2
1.3	Réseaux et évolution	2
2	Définitions formelles des SBN	2
2.1	SBF et graphe d'interaction	2
2.2	Fonction de succession et comportement	3
2.3	Réseaux et classes d'équivalence	3
3	Concepts évolutifs : robustesse, évolutivité et viabilité	4
3.1	Quels concepts faut-il retenir pour le modèle ?	4
3.2	Robustesse et évolutivité	5
3.3	Viabilité	5
4	Formaliser l'évolution	7
4.1	Schéma général	7
4.2	Distances sur l'espace des réseaux	8
4.2.1	Distances structurelles	8
4.2.2	Distances dynamiques	10
4.2.3	Distances sur $\mathbb{G}/\mathcal{R}$	12
4.3	Structure de l'espace des réseaux	12
4.4	Robustesse	12
4.5	Coût d'un chemin d'évolution, coût d'une évolution	13
4.6	Évolutivité	14
4.7	Viabilité et score de viabilité	14
4.7.1	Viabilité	14
4.7.2	Viabilité et évolution	14
4.7.3	Score de viabilité :	15
5	Conclusion	15

1 Introduction

1.1 Réseaux d'interactions biologiques

De nombreux systèmes dans le vivant sont constitués d'éléments interagissant les uns avec les autres en réseau : l'ADN d'une cellule est constitué de gènes se régulant entre eux durant l'activité cellulaire.

Le cerveau est un réseau constitué de neurones interconnectés s’activant et s’inhibant les uns les autres pour donner lieu à l’activité cérébrale. À plus grande échelle, un écosystème est un ensemble d’espèces interagissant parfois de manière destructrice (prédation) ou de manière constructive (symbiose). Les réseaux d’interactions biologiques se retrouvent donc à toutes les échelles.

1.2 Réseaux booléens à signe

Un des modèles utilisés pour représenter ces réseaux d’interactions biologiques est le modèle des réseaux booléens à signe (abrégé en SBN pour *Signed Boolean Networks*). On représente chaque élément du système par un noeud portant une valeur 0 ou 1 représentant son état (activé ou non) et chaque interaction par un arc pondéré allant du noeud influant au noeud qui subit l’influence. Le poids de l’arc correspond à la nature (activatrice ou inhibitrice) et à la force de l’interaction. Un SBN a une fonction de succession définie par les poids des arcs qui, à un état du réseau à un temps t , donne l’état au temps $t + 1$.

L’un des objectifs des SBN est de prédire la succession des états pris par le réseau biologique étudié, c’est-à-dire son *comportement*. On ne peut cependant pas s’attendre à une prédiction parfaite car deux hypothèses fortes sont faites : (i) on réduit l’état d’un élément à une valeur booléenne et (ii) la fonction qui associe la valeur suivante à un noeud ne dépend que de la somme des actions de ses prédécesseurs. Ces hypothèses sont justifiées : dans un réseau génétique, par exemple, chaque gène est soit activé, soit d’activité négligeable ou nulle. Dans la nature, lorsque plusieurs éléments agissent sur un unique système, l’action résultante est généralement une somme pondérée des actions distinctes (c’est exactement le cas des neurones). Ces hypothèses permettent d’obtenir un modèle de calcul simple, mais capable de prédictions efficaces sur des systèmes réels [1].

L’équipe BCM¹ où j’ai effectué mon stage s’intéresse donc aux SBN, plus précisément, elle s’intéresse à l’ensemble de tous les réseaux plutôt qu’à un réseau isolé ayant pour vocation de représenter un système biologique. L’une des raisons de ce choix est que même pour une étude précise, se restreindre à un unique réseau n’est pas forcément la meilleure approche, car d’autres réseaux peuvent aussi bien représenter le système. Par exemple, il a été montré que 532 SBN remplissaient parfaitement les contraintes imposées par les données issues des observations de la morphogenèse florale de la fleur *Arabidopsis thaliana* [2]. L’autre raison de ce choix est que certaines notions ne peuvent être étudiées localement mais nécessitent de travailler sur tout l’espace des réseaux : c’est le cas de l’évolution.

1.3 Réseaux et évolution

L’une des principales questions en biologie est la question de l’évolution : comment un système biologique a-t-il évolué en un autre ? Quels sont les formes intermédiaires qu’a pris ce système dans sa lignée ? Quelles évolutions sont possibles et lesquelles ne le sont pas ?

Le modèle des SBN offre un cadre de calcul simple pour approcher des questions biologiques. On aimerait donc pouvoir étudier l’évolution de systèmes biologiques dans le modèle formel des SBN, mais pour cela, il nous faut d’abord disposer d’outils formels pour étudier le sujet. C’est là l’objectif de mon stage au sein de l’équipe BCM du laboratoire TIMC-IMAG de l’université de Grenoble, sous l’encadrement de Nicolas Glade et Sergiu Ivanov : définir les notions spécifiques à l’évolution dans le cadre du modèle formel des SBN.

2 Définitions formelles des SBN

Avant de présenter les notions formelles que j’ai développées au cours de mon stage, il est nécessaire d’explicitier les définitions de base des SBN. Lors de ce stage, on étudiera uniquement des SBN de même dimension, i.e. avec le même nombre de sommets. On fixe donc $d \in \mathbb{N}^*$.

2.1 SBF et graphe d’interaction

On définit une SBF (*Signed Boolean Function*) comme étant un d -uplet f d’entiers (i.e. $f \in \mathbb{Z}^d$). On définit un état comme un d -uplet de booléens. On notera ici $\mathbb{S} = \{0, 1\}^d$ l’ensemble des états possibles.

1. Biologie Computationnelle et Modélisation




FIGURE 1 – Trois représentations d’un même SBN. (a) : Matrice de poids; (b) : Graphe d’interaction, représente la structure du réseau; (c) : Graphe de transition, représente la dynamique du réseau

On définit l’image d’un état s par la SBF f ainsi :

$$f(s) = \begin{cases} 1 & \text{si } \sum_{i=1}^d f_i s_i > 0 \\ 0 & \text{sinon.} \end{cases} \quad (1)$$

Un SBN de dimension d est un d -uplet de SBF reliées entre elles par des arcs associant SBF et entrées des SBF, *i.e.* une matrice carrée de taille d à coefficients entiers. On note donc $\mathbb{G} = \mathcal{M}_d(\mathbb{Z})$ l’ensemble des SBN. La matrice correspondante est la matrice de poids du graphe d’interaction, où g_{ij} est l’arc allant du noeud j au noeud i .

Mentionnons ici un débat encore en cours sur le rôle des arcs de poids nuls. La question est de savoir s’il y a un sens à considérer un réseau ayant de tels arcs. Si en pratique un arc de poids nul n’a jamais d’influence, il est intéressant de noter que dans la structure d’un système biologique deux éléments reliés par une liaison de force nulle ne sont pas identiques à deux éléments non liés, car cette liaison nulle peut ou bien traduire un résidu de l’évolution (la liaison a perdu en force au cours de la lignée jusqu’à être nulle) ou un potentiel évolutif. Dans le cas de notre modèle, nous choisirons cependant de ne pas distinguer arc inexistant d’un arc de poids nul, ou plutôt de considérer les SBN comme des graphes complets dont on ne représente que les arcs de poids non nul dans la représentation structurelle (figure 1(b)). Notamment, le graphe est toujours connexe, pourvu que l’on s’autorise à passer par des arcs de poids nul.

2.2 Fonction de succession et comportement

On associe à chaque SBN g sa fonction de succession succ_g définie ainsi :

$$\begin{aligned} \text{succ}_g : \mathbb{S} &\rightarrow \mathbb{S} \\ s &\mapsto (g_i(s))_{1 \leq i \leq d} \end{aligned} \quad (2)$$

Où g_i est la i -ème SBF de g , soit la i -ème ligne de la matrice de poids.

La fonction de succession correspond à ce que l’on appelle le *comportement* du système biologique. On représente la fonction de succession avec un graphe de transition comportant tous les états possibles. Un exemple est donné en figure 1(c). On comprend aisément que plusieurs SBN peuvent avoir le même comportement, car l’ensemble des réseaux est infini tandis qu’il n’y a qu’un nombre fini de comportements.

2.3 Réseaux et classes d’équivalence

L’un des premiers objectifs de l’équipe BCM en étudiant les SBN a été de chercher une organisation de l’espace des réseaux, et de regrouper ces réseaux par catégories, ce qui a mené naturellement à définir des classes d’équivalence.

Cette approche s’est révélée très utile en pratique dans l’étude informatique des SBN, car $\mathbb{G}$ est de cardinal infini. Pour se ramener à un ensemble d’étude plus petit, on choisit une relation d’équivalence $\mathcal{R}$ sur les SBN dépendant du modèle et on travaille sur $\mathbb{G}/\mathcal{R}$. La relation d’équivalence choisie par l’équipe

dimension	nombre de classes
2	60
3	31065
4	3.623×10^9
5	$\approx 3.5 \times 10^{20}$

FIGURE 2 – Nombres de classes d’équivalence des réseaux de dimensions 2, 3, 4 et 5

où je travaille est la suivante :

$$g\mathcal{R}g' \iff \begin{cases} \forall i, TV(g_i) = TV(g'_i) \\ \forall i, j; g_{ij} = 0 \iff g'_{ij} = 0 \end{cases} \quad (3)$$

où $TV(g_i)$ est la table de vérité de la fonction représentée par g_i .

La première condition garantit qu’il n’y ait pas de différence au niveau logique entre les SBN d’une même classe, et surtout que deux éléments d’une même classe d’équivalence aient le même comportement. La deuxième condition vient du fait que les arcs de poids 0 ont une signification particulière sur le modèle, comme on l’a vu précédemment.

Cette relation a pour vocation de réduire la taille de l’espace des réseaux en perdant un minimum d’information. Cependant, même ainsi, on obtient un nombre trop important de classes d’équivalence (figure 2). C’est pourquoi on ne peut pas faire de calcul exhaustif sur l’espace des réseaux pour $d \geq 4$. D’autres approches sont possibles : par exemple, pour $d = 4$, l’équipe BCM étudie l’espace des réseaux avec un échantillonnage de 1/100.

Cependant, cette relation d’équivalence est toujours un choix de travail de l’équipe, même si elle est particulièrement adaptée à l’étude des SBN. Afin de conserver la flexibilité de notre modèle, j’ai décidé de travailler par la suite avec une relation d’équivalence $\mathcal{R}$ quelconque qui satisfait les deux conditions suivantes :

- $\mathbb{G}/\mathcal{R}$ est fini.
- Deux réseaux équivalents ont le même comportement.

De cette manière, d’autres critères d’équivalence spécifiques aux systèmes étudiés peuvent être choisis sans perturber le reste de la formalisation.

3 Concepts évolutifs : robustesse, évolutivité et viabilité

Comme on l’a vu, le modèle formel des SBN est à la fois simple en termes de calculs et pourtant capable de prédictions efficaces sur des systèmes biologiques réels. On aimerait donc pouvoir étudier des concepts complexes dans ce modèle simple, tel que l’évolution biologique. C’est ce travail que j’ai fait lors de mon stage. Ce travail est en deux parties : une première consistant à disséquer le sujet et étudier la structure et le fonctionnement des SBN afin de comprendre quelles sont les notions évolutives et quels aspects on souhaite retranscrire dans le modèle formel, et une deuxième consistant à construire effectivement le modèle formel de l’évolution dans les SBN.

3.1 Quels concepts faut-il retenir pour le modèle ?

Pour injecter les concepts évolutifs dans le modèle formel des SBN, il est nécessaire d’établir une sélection de notions précises décrivant au mieux le processus évolutif. Ce travail de bibliographie et de discussion a en réalité représenté une majeure partie de mon stage, car il était important de beaucoup dialoguer avec le reste de l’équipe afin de comprendre au mieux les enjeux de la formalisation, et surtout pour bien comprendre informellement quelles étaient les notions étudiées dans l’évolution. Bien entendu, une fois les axes de réflexion du sujet bien compris, la difficulté principale était encore à venir : poser un cadre formel flexible sur des questions exprimées jusque-là uniquement de manière très informelle.

Au terme de ces discussions, j’ai choisi de concentrer mon travail sur trois notions précises : la *robustesse*, l’*évolutivité* et la *viabilité*. La robustesse est la résistance d’un système aux mutations, ce qui est important pour une lignée afin de ne pas s’éteindre toute seule. L’évolutivité est la capacité d’un système à changer de comportement en peu de mutations, ce qui est une qualité nécessaire pour s’adapter à un environnement changeant. La viabilité est la contrainte exercée par l’environnement et la physique sur les

systèmes. On parle de systèmes viables ou non. De façon plus nuancée, on parlera de conditions favorables à la vie de tels systèmes.

Ces trois notions représentent très bien les principaux axes d'étude de l'évolution, et leur définition est nécessaire pour des travaux futurs. Je vais maintenant développer ces notions plus en détail ainsi que les enjeux derrière afin de pouvoir comprendre au mieux les raisons d'être du modèle formel que je construirai ensuite.

3.2 Robustesse et évolutivité

La capacité d'un système à évoluer dépend de deux qualités : il faut qu'il soit suffisamment stable au cours de la lignée pour que celle-ci puisse survivre, mais il doit être capable de s'adapter rapidement aux modifications de son environnement ou d'améliorer sa propre capacité de survie. Ces deux qualités, robustesse et évolutivité, sont nécessaires à la survie à long terme du système, que l'on étudie le réseau génétique d'une cellule ou un écosystème. Même si ces deux qualités semblent à priori antagonistes, il a été montré qu'elles peuvent être réconciliées [4]. Ce sont donc ces deux concepts que nous utiliserons pour qualifier le rapport d'un système à l'évolution.

Les définitions communément acceptées de la robustesse et de l'évolutivité en biologie théorique sont les suivantes :

- Un système biologique est dit robuste si son comportement est conservé après une mutation dans sa structure.
- Un système biologique est dit évolutif si des mutations dans sa structure peuvent induire une grande diversité de comportements.

On cherche ici à traduire ces définitions en langage formel. On comprend que la structure d'un système biologique correspond à la matrice d'interaction de nos SBN et que le comportement correspond au graphe de transition. En revanche, il n'est pas aussi évident de comprendre ce qu'est formellement une mutation et ce que signifie « conserver le comportement ». Ces deux notions demandent de pouvoir comparer des SBN, mais pour l'instant l'espace des réseaux n'a ni mesure de comparaison, ni mesure de similarité. Il sera donc nécessaire de définir une ou plusieurs distances sur l'espace des réseaux dans le formalisme.

3.3 Viabilité

Certains des systèmes biologiques possiblement représentés par nos SBN ne sont pas viables. Par exemple, un écosystème constitué uniquement de prédateurs s'attaquant les uns les autres n'est absolument pas viable, car il finit par s'éteindre tout seul. Mais cette viabilité peut être aussi due à l'environnement. Le métabolisme de l'ours polaire est particulièrement adapté à la banquise, mais dans un climat désertique comme le Sahara, il n'a aucune chance de survie. Il est nécessaire de prendre en compte pour notre formalisme l'action de l'environnement, que nous résumerons ici à la capacité de survie du système biologique dans cet environnement, et que nous appellerons la contrainte de viabilité, ou plus simplement la viabilité.

A priori, comme nous travaillons sur des réseaux formels détachés de la réalité, que ceux-ci peuvent représenter des systèmes très différents les uns des autres, et que pour un modèle, l'environnement peut varier, on ne peut pas se permettre de fixer une contrainte de viabilité universelle. Pour cette raison, le formalisme que j'exposerai ne devra pas définir ce qu'est dans l'absolu un réseau viable ou non, mais plutôt ce qu'est une contrainte de viabilité dans le cadre des SBN, et comparer les différentes viabilités possibles.

Pour offrir une mesure de comparaison entre les viabilités, introduisons la notion de chemins viables. Un chemin est une trajectoire dans l'espace des réseaux composée d'une succession de SBN proches. Il représente une évolution du réseau de départ en le réseau d'arrivée. Parmi les SBN composant la trajectoire, les uns sont viables et les autres non. On parle de chemin viable lorsque tous les points de la trajectoire sont viables (figure 3). Dans les systèmes biologiques réels, seules les évolutions empruntant des trajectoires viables sont possibles : tous les membres de la lignée doivent survivre suffisamment longtemps pour avoir un descendant. La question qui se pose pour deux réseaux et une viabilité donnés est la suivante : existe-t-il un chemin viable reliant l'un à l'autre, ou bien le premier système ne peut-il jamais devenir le second au cours de l'évolution ? Par exemple, sur la figure 4(a), le réseau A peut évoluer en le réseau B, mais dans un environnement plus contraignant comme la figure 4(b), l'évolution n'est pas possible.






FIGURE 3 – Deux exemples de chemins dans l'espace des réseaux. On considère ici comme voisins deux SBN qui ne diffèrent que d'un arc et comme viable un SBN dont aucun état non nul n'aboutit à l'état nul. Le chemin orange est viable, le chemin bleu ne l'est pas.



(a) Environnement peu contraignant : score de viabilité fort



(b) Environnement très contraignant : score de viabilité faible

FIGURE 4 – Représentation de l'espace des réseaux avec deux viabilités différentes : on cherche à construire un score de viabilité qui attribue une valeur plus élevée à la viabilité de gauche.




FIGURE 5 – Organisation des définitions formelles autour de l'évolution. Les flèches entrantes d'un bloc indiquent quelles sont les notions supposées déjà définies utilisées dans la définition du bloc.

De manière plus générale, pour une contrainte de viabilité donnée, toute évolution est-elle possible ou bien l'espace des réseaux est-il constitué d'une multitude de blocs viables isolés ? Pour répondre à cette question, on aimerait pouvoir définir un *score de viabilité*, qui serait élevé dans le cas où l'espace des réseaux viables est composé d'un bloc unique (figure 4(a)), et faible dans le cas où il a plutôt une forme d'archipel composé de petits blocs isolés (figure 4(b)).

4 Formaliser l'évolution

4.1 Schéma général

Dans cette partie, je présenterai le formalisme que j'ai construit pour permettre de définir les notions relatives à l'évolution, tout en garantissant une grande flexibilité par rapport au modèle choisi. Il est donc nécessaire de pouvoir modifier une définition du système formel sans avoir à retravailler tout le système. La solution que j'ai trouvée est une architecture modulaire, dont le schéma est présenté en figure 5. L'idée est de séparer l'existence d'une notion de sa définition. Par exemple, la définition formelle de la robustesse fait intervenir la notion de distance, mais est totalement indépendante de la manière dont sont définies ces distances. On peut comparer cette architecture avec un programme informatique bien organisé où l'on peut ajuster une variable sur la ligne où elle est définie sans avoir à reporter la modification sur l'ensemble du programme.

Donnons une première approche informelle de ce schéma. Notre réflexion est fondée essentiellement sur la notion de distance. On utilise une distance structurelle et une distance dynamique. La distance structurelle permet de comparer la structure de deux systèmes et de formaliser la notion de mutation sur la structure. La distance dynamique permet de comparer deux comportements, afin de quantifier les termes "conserver son comportement" et "changer de comportement". À partir de ces deux notions, on peut quantifier la robustesse.

Pour définir l'évolutivité, il faut d'abord comprendre ce que signifie "évoluer" dans l'espace des réseaux. Pour cela, il faut déterminer la structure de l'espace des réseaux induite par les distances pour savoir comment les sauts de réseau en réseau y ont lieu. On distingue donc deux cas possibles de structure de l'espace des réseaux : une forme de graphe, et une forme d'espace métrique.

On définit ensuite deux notions : le chemin d'évolution, qui est une trajectoire dans l'espace des réseaux, ainsi que le coût de cette trajectoire, qui représente la difficulté d'obtenir une telle trajectoire (notion variable qui dépendra du modèle). À partir de l'ensemble des trajectoires d'un réseau g vers un réseau g' , on peut attribuer une valeur à l'évolution $g \rightarrow g'$ indépendante de la trajectoire traduisant la difficulté d'obtenir g' depuis g .

Depuis cette grandeur, on peut définir l'évolutivité d'un réseau g en observant l'ensemble de ses évolutions possibles. On définit en parallèle la notion de viabilité. C'est enfin à partir de la viabilité (et de la manière dont elle contraint les évolutions) et de l'évolutivité qu'on peut définir le score de viabilité énoncé plus haut.

Dans les prochaines parties, j'exposerai les détails formels derrière ces notions.

4.2 Distances sur l'espace des réseaux

Comme nous l'avons énoncé en introduction, pour pouvoir définir les notions de robustesse, d'évolutivité et de contrainte de viabilité, il nous faut d'abord définir ce qu'on entend par deux réseaux similaires ou deux comportements similaires. Pour cela, nous avons besoin d'une distance sur l'espace des réseaux, que l'on appellera *distance structurelle*, et une distance entre les comportements, qu'on appellera *distance dynamique*.

Dans cette partie, pour illustrer le concept d'architecture formelle modulaire, nous allons définir deux distances structurelles. Le système formel ne nécessite qu'une seule distance structurelle, mais nous verrons que les deux que nous définirons remplissent chacune tous les critères d'une distance et que, suivant les cas, on peut choisir librement l'une ou l'autre car chacune valorise un aspect différent des réseaux. Nous définirons de la même manière deux distances dynamiques au lieu d'une.

Rappelons avant de passer aux définitions formelles la définition d'une distance : pour tout ensemble E , on appelle distance toute fonction $d : E^2 \rightarrow \mathbb{R}_+$ respectant ces trois conditions :

- Axiome de séparation : $\forall a, b \in E, d(a, b) = 0 \iff a = b$
- Axiome de symétrie : $\forall a, b \in E, d(a, b) = d(b, a)$
- Inégalité triangulaire : $\forall a, b, c \in E, d(a, b) \leq d(a, c) + d(c, b)$

4.2.1 Distances structurelles

Les distances structurelles ne s'intéressent, comme leur nom l'indique, qu'à la représentation structurelle, c'est-à-dire le graphe d'interaction du réseau. On définit ici deux distances : la distance structurelle de Hamming et la distance sur les chemins.

Distance structurelle de Hamming : Une première distance simple à définir et à calculer sur les réseaux est la distance de Hamming. Elle compte le nombre de modifications, ou mutations, nécessaires pour passer d'un réseau à un autre. On compte comme mutation ici un changement de 1 sur la valeur d'un arc (nul ou non). On a donc comme définition de la distance structurelle de Hamming :

$$\forall g, g' \in \mathbb{G}, d_{SH}(g, g') = \sum_{i=1}^d \sum_{j=1}^d |g_{ij} - g'_{ij}| \quad (4)$$

On montre trivialement que d_{SH} est bien une distance. Celle-ci a de nombreux avantages : elle est simple à calculer, et nous donne une bonne idée de proximité de réseaux.


Distance sur les chemins La distance de Hamming qu'on a définie accorde la même importance à chacun des arcs (proportionnellement à son poids), mais on peut chercher à définir une distance qui accorde plus d'importance à certains arcs qu'à d'autres. Par exemple, il peut exister des systèmes biologiques où l'importance d'une interaction dans le réseau impacte directement le coût de modification de cette interaction.

En théorie des graphes, définir l'importance d'un arc revient à définir ce que l'on appelle un indicateur de centralité [3]. Il n'y a pas de définition universelle de la centralité, il faut poser des critères venant du système à modéliser. Ici, on se fixera deux critères, illustrés avec la figure 6 :

- A poids équivalent, un arc a plus d'importance s'il est plus impliqué dans la connectivité du réseau.
- A position équivalente, un arc a plus d'importance si son poids (en valeur absolue) est plus élevé.

On veut construire ensuite une distance pour laquelle une modification sur un arc a un coût d'autant plus élevé que l'arc a de l'importance.

Notre nouvelle distance doit prendre en compte la connectivité du réseau : on devra faire un calcul non pas sur les arcs, mais sur les chemins qu'il contient. Ici, on ne considère que les chemins qui ne comptent pas de cycle, afin de maintenir les calculs sur des ensembles finis. En outre, on doit étendre la notion de poids aux chemins. On introduira pour cela la notion d'*influence* d'un arc et d'un chemin.



(a) Tous les arcs sur cette figure n'ont pas la même importance. L'arc DA (en rouge) est le seul à faire communiquer le bloc DEF avec le bloc ABC , tandis que l'arc FF (en bleu) n'influe que sur le sommet F , car celui-ci n'a pas d'arc sortant.

(b) Ici, l'arc BA (en rouge) et l'arc DA (en bleu) ont une position équivalente, mais ils n'ont pas le même poids. On s'attend à ce que l'arc DA ait moins d'importance que BA car il est de poids plus faible.

FIGURE 6 – Deux illustrations de l'importance d'un arc dans un réseau : à poids équivalent (à gauche) et à position équivalente (à droite)

On définit l'influence d'un arc a à la position g_{ij} ainsi :

$$I_g(a) = \frac{g_{ij}}{\sum_{k=1}^d |g_{ik}|} \quad (5)$$

où g_{ij} est l'arc allant de j à i .

L'influence d'un arc représente la corrélation que l'on peut espérer entre la valeur des deux sommets liés. Si elle vaut 1, le sommet de départ détermine complètement l'état du sommet d'arrivée. Si elle est proche de zéro, alors la probabilité que la valeur du sommet de départ ait une importance pour déterminer la valeur du sommet d'arrivée est faible.

On définit ensuite l'influence d'un chemin c par la formule :

$$I_g(c) = \prod_{a \in \text{arcs}(c)} I_g(a) \quad (6)$$

Ainsi, si l'influence d'un chemin est proche de 1, cela signifie que l'état du sommet de départ détermine en grande partie l'état du sommet d'arrivée (après un certain nombre d'étapes). Un chemin d'influence nulle signifie qu'un de ses arcs est de poids nul, donc qu'il n'existe pas dans le réseau.

Après avoir défini l'influence d'un chemin, on peut définir la distance d_{SC} sur les chemins entre deux réseaux ainsi :

$$d_{SC}(g; g') = \sum_{c \in \text{paths}(g) \cap \text{paths}(g')} |I_g(c) - I_{g'}(c)| + \sum_{c \in \text{paths}(g) \setminus \text{paths}(g')} |I_g(c)| + \sum_{c \in \text{paths}(g') \setminus \text{paths}(g)} |I_{g'}(c)| \quad (7)$$

Ou de manière équivalente, en notant K_d le graphe complet à d sommets :

$$d_{SC}(g; g') = \sum_{c \in \text{paths}(K_d)} |I_g(c) - I_{g'}(c)| \quad (8)$$

Notons que d_{SC} ne vérifie pas l'axiome de séparation : en effet, pour $\lambda \in \mathbb{R}_+^*$, $d_{SC}(g, \lambda g) = 0$. Il s'agit donc formellement d'une *pseudométrie* : une fonction qui vérifie tous les critères des distances sauf l'axiome de séparation. Cette dégénérescence est parfaitement justifiée : si l'on considère que les valeurs

des poids n'ont de sens que relativement les unes aux autres, il est logique de considérer que deux réseaux identiques à multiplication par un réel strictement positif près sont exactement les mêmes réseaux.

Par la suite, pour simplifier l'écriture, on continuera d'utiliser le terme "distance" en parlant de pseudométriques.

4.2.2 Distances dynamiques

De même qu'on ne s'intéressait qu'à la représentation structurelle des réseaux pour calculer les distances structurelles, on ne s'intéressera dans cette section qu'à la représentation dynamique, c'est-à-dire formellement la fonction de succession et informellement le comportement du réseau. On définit la distance dynamique de Hamming et la distance sur les attracteurs.

Distance dynamique de Hamming : De même que sur la structure, on peut définir une distance de Hamming sur la dynamique du réseau. On définit d'abord la distance de Hamming entre deux états avec :

$$\forall s, s' \in \mathbb{S}; H(s, s') = \sum_{i=1}^d |s_i - s'_i|$$

Et on définit la distance dynamique de Hamming entre deux réseaux :

$$d_{DH}(g; g') = \sum_{s \in \mathbb{S}} H(succ_g(s); succ_{g'}(s)) \quad (9)$$

Cette distance représente comme proches deux réseaux où la fonction *succ* ne change que sur peu d'entrées, ce qui est une bonne première approche de la distance entre comportements.

Distance sur les attracteurs : Suivant le système étudié, comparer directement les fonctions de succession n'est pas forcément la meilleure représentation. Généralement, l'intégralité de la fonction *succ* n'est pas nécessaire à l'étude du système, on a un surplus d'information. Il suffit souvent de ne connaître que les *attracteurs* et les *bassins d'attraction*. Définissons ces deux notions formellement :

On appelle *attracteur* d'un réseau *g* une suite d'états $(s_0, s_1, \dots, s_k)$ telle que

$$\forall (0 \leq i \leq k-1), succ_g(s_i) = s_{i+1} \text{ et } succ_g(s_k) = s_0$$

k est la taille de l'attracteur. On appelle *point fixe* un attracteur de taille 1 et *cycle* un attracteur qui n'est pas un point fixe.

On appelle *bassin d'attraction* d'un attracteur $a = (s_0, \dots, s_k)$ (dans un réseau *g*) l'ensemble des états qui mènent à cet attracteur par applications répétées de la fonction *succ_g* :

$$BA(a) = \{s \in \mathbb{S}; \exists n \in \mathbb{N}; succ_g^n(s) = s_0\}$$

De ces définitions découlent les propriétés suivantes pour tout SBN *g* :

- L'état nul est un point fixe de *g*. En effet, la définition du comportement des SBN induit $succ_g(0) = 0$.
- Tout état *s* appartient à un bassin d'attraction. En effet, la suite $(succ_g^n(s))_{n>0}$ est à valeurs dans un ensemble fini, donc est périodique à partir d'un certain rang. La période correspond à l'attracteur.
- L'ensemble des bassins d'attraction de *g* forme une partition de $\mathbb{S}$. Ce fait découle directement de la propriété précédente.

Bien souvent, il est important de considérer les attracteurs dans l'étude des systèmes, car ils représentent leurs états asymptotiques. L'étude des bassins d'attraction est importante également dans une moindre mesure, car ils témoignent de nombreuses propriétés de l'état asymptotique correspondant du système biologique. Suivant les modèles, un attracteur avec un plus grand bassin d'attraction aura une plus grande stabilité face aux changements d'états, ou une plus grande probabilité d'apparaître.

On cherche donc à construire une distance selon ces contraintes :

- Modifier un bassin d'attraction coûte moins cher que de modifier son attracteur.
- Modifier (ou supprimer) un attracteur à petit bassin d'attraction coûte moins cher que de modifier (ou supprimer) un attracteur avec un grand bassin d'attraction.




FIGURE 7 – Trois graphes de transition avec différents bassins d’attraction. Selon la distance de Hamming, (a) est plus proche de (c) que de (b), mais les attracteurs et les bassins d’attraction sont plus ressemblants entre (a) et (b) qu’entre (a) et (c). Une distance alternative serait utile pour mesurer ces différences.

Nous allons prendre en compte la taille des bassins d’attraction. Pour cela on effectue un calcul sur chaque état du bassin d’attraction. L’ensemble des bassins d’attraction étant une partition de $\mathbb{S}$, il nous faut finalement faire un calcul sur $\mathbb{S}$.

Il nous faut maintenant introduire une distance entre les attracteurs pour les différencier.

Il n’est pas évident de mesurer une distance entre deux attracteurs de longueur différentes, car une boucle n’a pas de début ni de fin et qu’on compare des objets de tailles différentes.

On va devoir tester tous les débuts de boucle possibles et prendre le minimum, ce qui donne pour deux attracteurs de même taille :

$$d_{CYCLE,1}(\mathcal{C}_1; \mathcal{C}_2) = \min_{1 \leq j \leq |\mathcal{C}_1|} \left(\sum_{i=1}^{|\mathcal{C}_1|} H((\mathcal{C}_1)_{i+j}; (\mathcal{C}_2)_i) \right) \quad (10)$$

où l’on a $(\mathcal{C}_1)_1 = (\mathcal{C}_1)_{|\mathcal{C}_1|+1}$.

Concernant la longueur, on choisit ici d’allonger le cycle le plus court en ajoutant l’état nul autant de fois que nécessaire, ce qui nous donne pour un début de boucle arbitraire si $|\mathcal{C}_1| \geq |\mathcal{C}_2|$:

$$d_{CYCLE,2}(\mathcal{C}_1; \mathcal{C}_2) = \sum_{i=1}^{|\mathcal{C}_2|} H((\mathcal{C}_1)_i; (\mathcal{C}_2)_i) + \sum_{i=|\mathcal{C}_2|+1}^{|\mathcal{C}_1|} H((\mathcal{C}_1)_i; 0) \quad (11)$$

On obtient donc en combinant les deux solutions :

$$d_{CYCLE}(\mathcal{C}_1; \mathcal{C}_2) = \begin{cases} \min_{1 \leq j \leq |\mathcal{C}_1|} \left(\sum_{i=1}^{|\mathcal{C}_2|} H((\mathcal{C}_1)_{i+j}; (\mathcal{C}_2)_i) + \sum_{i=|\mathcal{C}_2|+1}^{|\mathcal{C}_1|} H((\mathcal{C}_1)_{i+j}; 0) \right) & \text{si } |\mathcal{C}_1| \geq |\mathcal{C}_2| \\ d_{CYCLE}(\mathcal{C}_2; \mathcal{C}_1) & \text{sinon} \end{cases} \quad (12)$$

Avec ces deux mesures, on peut enfin définir une distance d_{DA} sur les attracteurs des réseaux. En notant $\lim_g(s)$ l’attracteur dans lequel finit s dans g :

$$d_{DA}(g; g') = \sum_{s \in \mathbb{S}} d_{CYCLE}(\lim_g(s); \lim_{g'}(s)) \quad (13)$$

Cette distance remplit bien nos deux critères de construction : si seul le bassin d’attraction est modifié, seuls les états déplacés produiront une différence, tandis que si l’attracteur change, tous les états du bassin produiront une différence. En outre, si un attracteur est modifié, le coût de la modification est proportionnel à la taille du bassin d’attraction.

Comme on le voit en figure 7, deux comportements ((a) et (b)) peuvent avoir les mêmes attracteurs et les mêmes bassins d’attraction. Ainsi, de même que la distance sur les chemins vue plus tôt, la distance sur les attracteurs ne respecte pas non plus l’axiome de séparation : c’est une pseudométrique. Cela ne cause pas de problème non plus : travailler avec d_{DA} suppose que seuls les attracteurs comptent dans l’étude, il est donc normal de ne pas différencier les comportements sur d’autres critères.

4.2.3 Distances sur $\mathbb{G}/\mathcal{R}$

Nous avons défini ici des distances sur $\mathbb{G}$, mais la plupart des travaux menés sur l'espace des réseaux le sont sur $\mathbb{G}/\mathcal{R}$. On a donc besoin de pouvoir porter simplement ces distances sur $\mathbb{G}/\mathcal{R}$. Ainsi, si d est une pseudométrie sur $\mathbb{G}$, on définit d^* pseudométrie sur $\mathbb{G}/\mathcal{R}$ de la façon suivante :

$$d^*(\bar{h}; \bar{h}') = \min_{g \in \bar{h}, g' \in \bar{h}'} d(g; g')$$

En pratique, comme $\mathcal{R}$ et les distances sont choisies au même moment, on construit $\mathcal{R}$ de telle manière que la distance structurelle obtenue sur $\mathbb{G}/\mathcal{R}$ respecte bien l'axiome de séparation.

4.3 Structure de l'espace des réseaux

Pour pouvoir étudier les concepts évolutifs par la suite, il est nécessaire tout d'abord de se faire une idée de la structure de l'espace des réseaux induite par la distance choisie. Pour cela, nous allons revenir sur les deux distances structurelles définies plus haut.

D'une part, la distance structurelle de Hamming d_{SH} est à valeurs entières, et permet de définir de manière très claire la notion de réseaux voisins : deux réseaux g et g' sont dits *voisins* si $d_{SH}(g, g') = 1$. Cela nous permet également de définir clairement une mutation : la transformation d'un réseau en un de ses voisins. Ainsi, l'espace des réseaux prend la forme d'un graphe non orienté où chaque réseau est connecté à ses voisins.

D'autre part, la distance sur les chemins d_{SC} prend un très grand nombre de valeurs différentes rationnelles, et il est plus ambigu de définir à partir de quelle distance deux réseaux sont voisins. Il est plus cohérent de considérer l'espace des réseaux comme un espace métrique où chaque réseau est bel et bien en relation avec tous les autres.

Ainsi, suivant si d_S est à valeurs discrètes ou continues, on a deux structures bien différentes. J'ai décidé de ne pas choisir une structure ou l'autre, mais d'adapter le système de manière à pouvoir prendre en compte chacun des deux cas. La raison est que les deux structures ont leurs propres avantages et inconvénients. La structure de graphe est plus simple et bien adaptée à une première approche des SBN, mais ne contient en réalité que peu d'informations et peut ne pas traduire une complexité existante ; tandis que la structure d'espace métrique permet de poser un formalisme qui conserve une certaine complexité. En outre, à nouveau, certains systèmes se prêtent mieux à l'étude avec une certaine structure que d'autres. On peut comprendre que des réseaux génétiques tendent à évoluer par petites mutations tandis que les écosystèmes peuvent faire de grands pas d'évolution, chaque espèce évoluant séparément.

Notons que la frontière entre graphe et espace métrique est perméable. D'une part, un graphe peut aussi être vu comme un espace métrique et, d'autre part, si d_S est à valeurs continues, on peut fixer un seuil en-deçà duquel deux réseaux sont considérés comme voisins et obtenir ainsi une structure de graphe.

Du fait de cette distinction, il sera nécessaire pour définir certaines notions, comme celles de chemins dans l'espace des réseaux, de prêter attention à la structure de l'espace dans laquelle on travaille.

4.4 Robustesse

La plupart des notions qui suivent sont définies à partir de calculs de moyennes ou de sommes sur l'ensemble des réseaux. C'est pour cette raison qu'à partir de maintenant, on mènera l'étude non plus sur $\mathbb{G}$ mais sur $\mathbb{G}/\mathcal{R}$ où $\mathcal{R}$ est une relation d'équivalence quelconque remplissant les conditions énoncées plus haut.

La robustesse d'un système est souvent définie comme sa capacité à conserver son comportement lorsqu'il subit des mutations. On cherche donc à traduire cette notion par une fonction $R : \mathbb{G}/\mathcal{R} \rightarrow [0; 1]$ avec $R(g) = 1$ dans le cas (parfois non atteint) où toutes les mutations conservent le comportement de g . Je donne ici pour illustrer cette notion deux exemples de définitions de la robustesse suivant la structure de l'espace des réseaux.

Structure de graphe : Dans le cas où l'espace des réseaux adopte une structure de graphe, on a vu qu'une mutation se traduit formellement par la transformation d'un réseau en l'un de ses voisins. Pour la conservation du comportement, en l'absence de données supplémentaires sur le système biologique étudié, on fixe arbitrairement un seuil ϵ en-dessous duquel le comportement est considéré comme étant conservé.

On obtient ainsi la formule suivante :

$$R_\epsilon(g) = \frac{|\{g' \in \text{Voisins}(g); d_D(g, g') < \epsilon\}|}{|\text{Voisins}(g)|}$$

Structure d'espace métrique : Dans le cas où l'espace des réseaux a une structure d'espace métrique, il est nécessaire de considérer l'intégralité des autres réseaux comme résultant potentiellement de mutations. On pondère chacun des réseaux par sa distance au réseau étudié et par la différence de comportement, pour obtenir la formule suivante :

$$R(g) = \frac{\sum_{g' \in \mathbb{G}/\mathcal{R}} (e^{-d_S(g, g')} \times e^{-d_D(g, g')})}{\sum_{g' \in \mathbb{G}/\mathcal{R}} (e^{-d_S(g, g')})}$$

On a bien ici $R(g) = 1$ dans le cas limite où tous les autres réseaux ont le même comportement que g .

4.5 Coût d'un chemin d'évolution, coût d'une évolution

Avant de définir l'évolutivité, il est nécessaire de définir deux notions intermédiaires : le coût d'un chemin d'évolution et le coût d'une évolution. Dans tout ce rapport, on définit formellement un chemin d'évolution comme une suite finie de réseaux $(g_0; \dots; g_k)$, et on appelle *réseau de départ* g_0 et *réseau d'arrivée* g_k . On définit une évolution comme un couple de réseaux $(g \rightarrow g')$, où g est le réseau de départ et g' le réseau d'arrivée. On désigne donc ici par un chemin d'évolution une trajectoire dans l'espace des réseaux, tandis qu'une évolution désigne une transformation d'un réseau en un autre, indépendamment du chemin choisi. Les notions de coût de chemin d'évolution et de coût d'évolution ont pour objet de traduire la difficulté ou la rareté d'une certaine évolution d'un système biologique.

On cherche donc à définir deux fonctions CC (coût d'un chemin) et CE (coût d'une évolution), l'une sur les chemins dans $\mathbb{G}/\mathcal{R}$, l'autre sur $(\mathbb{G}/\mathcal{R})^2$, à valeurs dans $\mathbb{R}^*$. On doit avoir en outre $CE(g \rightarrow g') = \infty$ s'il n'y pas de chemin de g à g' .

À nouveau, ces notions ont des définitions très différentes suivant si l'espace des réseaux a une structure de graphe ou d'espace métrique, et il convient de distinguer les deux cas.

Structure de graphe : La notion de coût d'une transformation est complexe et intimement liée au système étudié. C'est pourquoi il vaut mieux sans doute faire le choix de la définition lors du choix du système étudié. Je donnerai cependant ici une définition simple à titre d'exemple du coût d'un chemin d'évolution et d'une évolution.

Dans une structure de graphe, on se restreint aux chemins de voisins en voisins. Un chemin d'évolution est donc une suite finie de réseaux telle que deux réseaux consécutifs sont voisins. Définissons par exemple le coût d'un chemin d'évolution comme étant la longueur du chemin :

$$CC(g_0; \dots; g_k) = k$$

On peut alors définir le coût d'une évolution comme étant le coût minimal d'un chemin allant du réseau de départ au réseau d'arrivée :

$$CE(g \rightarrow g') = \begin{cases} \min_{c \in \text{paths}(g \rightarrow g')} CC(c) & \text{si } \text{paths}(g \rightarrow g') \neq \emptyset \\ +\infty & \text{sinon} \end{cases}$$

Il est important de noter que CC et CE sont deux notions bien distinctes à ne pas fusionner, pour garantir la flexibilité du système formel élaboré. La définition du coût de chemin d'évolution est sujette à beaucoup de variations suivant le système étudié comme expliqué plus haut, tandis que la définition du coût d'évolution fait déjà intervenir le coût des chemins, et donc peut être commune à de nombreux systèmes biologiques.

Structure d'espace métrique : Comme dit précédemment, la structure d'espace métrique est bien plus compliquée à appréhender que celle de graphe. C'est pourquoi je n'ai pas eu le temps lors de mon stage de définir des exemples de coût de chemin d'évolution et de coût d'évolution dans un espace métrique. Cependant, il s'agit là de calculs et de détails formels qui ne changent pas la forme générale du formalisme.

Une piste de travail consisterait à étudier des marches aléatoires sur l'espace des réseaux, en étudiant d'abord la structure de graphe et en adaptant le modèle obtenu sur la structure d'espace métrique.

4.6 Évolutivité

L'évolutivité est définie comme la capacité d'un système biologique à acquérir de nouveaux comportements avec de petites évolutions. Pour calculer l'évolutivité d'un système, on fera donc un calcul sur l'ensemble des réseaux. Les évolutions faisant varier le comportement doivent être mises en valeur, tandis que les évolutions coûteuses seront dévalorisées. Je suis arrivé ainsi à la formule suivante :

$$E(g) = \text{moyenne}_{g' \in \mathbb{G}/\mathcal{R}} \left(\frac{d_D(g, g')}{CE(g \rightarrow g')} \right)$$

où *moyenne* désigne ici (et par la suite également) la moyenne arithmétique.

On note ici l'importance d'avoir $CE > 0$. Notons que sont prises en compte les évolutions impossibles dans le calcul. Comme on a $CE(g \rightarrow g') = \infty$, le terme correspondant dans le calcul de la moyenne est nul.

4.7 Viabilité et score de viabilité

4.7.1 Viabilité

La contrainte de viabilité de l'environnement détermine la survie des systèmes biologiques. Il y a deux manières de présenter cette contrainte. D'une part, on peut choisir une viabilité binaire, pour laquelle un système survit ou ne survit pas. D'autre part, on peut choisir une viabilité graduelle, pour laquelle un système a plus ou moins de chances de survie. Ce cas correspond à un animal normal et un autre amputé d'une patte. Les deux animaux peuvent vivre et se reproduire, mais le deuxième a toutefois moins de chances de survie, car il y a une probabilité qu'il finisse par se retrouver dans une situation où sa patte en moins lui est fatale.

Ici à nouveau, on va donner des définitions dans les deux cas, car le premier cas présente l'avantage d'être plus simple à appréhender pour une première étude, mais le deuxième cas permet plus de complexité qui peut représenter plus fidèlement certains modèles.

On appelle donc *viabilité binaire* toute fonction de $\mathbb{G}/\mathcal{R}$ dans $\{0, 1\}$ et *viabilité graduelle* toute fonction de $\mathbb{G}/\mathcal{R}$ dans $[0; 1]$. On appellera *viabilité parfaite* la fonction V_P constante égale à 1 et *viabilité nulle* la fonction V_N constante égale à 0.

4.7.2 Viabilité et évolution

Rajouter une contrainte de viabilité modifie les coûts des chemins d'évolution, les coûts d'évolution et l'évolutivité. On notera respectivement CC_V , CE_V et E_V ces quantités modifiées où V est la viabilité. Cette modification est bien entendu différente suivant le modèle. Or, les définitions données jusqu'ici ne supposent pas l'existence d'une contrainte de viabilité, ce qui revient à se placer dans le cas d'une viabilité parfaite. On voudrait donc avoir les propriétés suivantes :

- Les définitions précédentes correspondent à une viabilité parfaite, donc $CC_{V_P} = CC$, $CE_{V_P} = CE$ et $E_{V_P} = E$.
- Rajouter une contrainte de viabilité ne peut qu'augmenter les coûts et entraver l'évolution, donc on a pour toute viabilité V : $CC \leq CC_V$, $CE \leq CE_V$ et $E \geq E_V$.
- Dans le cas d'une viabilité nulle, il n'y a aucune évolution possible, donc : $CC_{V_N} = CE_{V_N} = \infty$ et $E_{V_N} = 0$.

Nos nouvelles définitions devront donc remplir ces critères. Je donne ici un exemple d'une modification prenant en compte la viabilité (en se plaçant dans une structure de graphe). Les définitions qui suivent sont valables pour une viabilité binaire aussi bien qu'une viabilité graduelle :

$$CC_V(g_0; \dots; g_k) = \frac{k}{\prod_{i=0}^{k-1} V(g_i)}$$

$$CE_V(g \rightarrow g') = \min_{c \in \text{paths}(g \rightarrow g')} CC_V(c)$$

$$E_V(g) = \text{moyenne}_{g' \in \mathbb{G}/\mathcal{R}} \left(\frac{d_D(g, g') \times V(g')}{CE_V(g \rightarrow g')} \right)$$

Elles remplissent bien les contraintes demandées plus haut. En outre, l'esprit de la définition de l'évolutivité est préservé : un système est évolutif si des mutations dans sa structure peuvent induire un caractère

héritable [4]. Un trait "héritable" est un trait qui fait augmenter les chances de survie du système pour une certaine contrainte de viabilité. On ne peut le définir simplement dans le système formel, mais on constate que nos définitions gardent cet esprit : les évolutions vers des systèmes plus viables, donc qui offrent des caractères héréditaires, sont valorisées.

4.7.3 Score de viabilité :

On peut enfin définir le score de viabilité. On cherche ici à définir une fonction sur l'ensemble des viabilités qui attribue un score élevé à une viabilité binaire si elle ne contraint que peu l'évolution des systèmes, et un score faible si de nombreuses évolutions sont impossibles. Dans le cas d'une viabilité graduelle, on aimerait que les chemins maximisant la viabilité de la trajectoire ne fassent que peu de détours par rapport à la viabilité parfaite. Les contraintes à remplir sont donc les suivantes :

- Sc est une fonction de l'ensemble des viabilités dans $[0; 1]$.
- La viabilité parfaite a un score de 1 et la viabilité nulle a un score de 0.

On a déjà défini avec E_V comment une viabilité contraignait l'évolution, il ne nous reste plus qu'à trouver une formule synthétisant ces valeurs. Dans notre description du score de viabilité, on compare les viabilités au cas idéal. Notre formule sera probablement un quotient avec le cas réel au numérateur et le cas idéal au dénominateur. Enfin, pour intégrer sur l'espace des réseaux, nous choisirons une moyenne. Cela nous donne la formule suivante :

$$Sc(V) = \frac{\text{moyenne}_{g \in \mathbb{G}} E_V(g)}{\text{moyenne}_{g \in \mathbb{G}} E(g)}$$

5 Conclusion

Au terme de mon stage, j'ai montré qu'il était possible de définir dans le modèle formel des SBN des concepts relatifs à l'évolution qui permettront à l'avenir d'étudier formellement l'évolution de systèmes spécifiques comme des réseaux génétiques. J'ai également montré qu'on pouvait étudier des trajectoires dans l'espace des réseaux et de leur attribuer un coût dépendant de leur longueur (temps d'évolution), leur robustesse, leur évolutivité et leur viabilité. Ces définitions permettront de calculer des trajectoires maximisant certains paramètres et de les comparer avec les trajectoires empruntées par les systèmes réels.

Le travail de mon stage pourra être continué en poursuivant les calculs effectués, et notamment en cherchant des exemples de définition des coûts d'évolution dans les espaces métriques, ce qui passera très probablement par l'étude des marches aléatoires dans l'espace des SBN. Le travail le plus important à venir consistera surtout à élargir les définitions obtenues non pas pour une certaine dimension, mais pour comparer des réseaux de tailles différentes. En effet, dans l'évolution d'un écosystème, on constate non seulement des modifications des interactions entre les espèces, mais aussi l'apparition et la disparition d'autres espèces. Certaines notions s'adapteront sans problème (le score de viabilité, notamment), mais d'autres, comme les distances, demanderont un travail conceptuel supplémentaire.

Références

- [1] Stefan Bornholdt. Boolean network models of cellular regulation : prospects and limitations. *J. R. Soc. Interface*, 5 :S85–S92, 2008.
- [2] Nicolas Glade. Le rare, le faible et l'amorphe dans les systèmes naturels. *HDR en cours de préparation*, 2021.
- [3] Elio Nushi, Victor-Bogdan Popescu, Jose Angel Sanchez Martin, Sergiu Ivanov, Eugen Czeizler, and Ion Petre. Network modeling methods for precision medicine, 2021.
- [4] Andreas Wagner. Robustness and evolvability : a paradox resolved. *Proc. R. Soc. B*, 275 :91–100, 2008.