

THÈSE

Pour obtenir le grade de

DOCTEUR DE L'UNIVERSITÉ GRENOBLE ALPES

École doctorale : ISCE - Ingénierie pour la Santé la Cognition et l'Environnement

Spécialité : MBS - Modèles, méthodes et algorithmes en biologie, santé et environnement

Unité de recherche : Translational Innovation in Medicine and Complexity

Complexité et évolution : étude des Réseaux Booléens à Signe

Complexity and evolution : study of Sign Boolean Networks

Présentée par :

Rémi SEGRETAİN

Direction de thèse :

Nicolas GLADE

MAITRE DE CONFERENCE, Université Grenoble Alpes

Directeur de thèse

Rapporteurs :

Élisabeth REMY

DIRECTEUR DE RECHERCHE, CNRS Délégation Provence et Corse

Loïc PAULEVE

CHARGE DE RECHERCHE, CNRS Délégation Aquitaine

Thèse soutenue publiquement le **29 mars 2023**, devant le jury composé de :

Nicolas GLADE

MAITRE DE CONFERENCES, Université Grenoble Alpes

Directeur de thèse

Élisabeth REMY

DIRECTEUR DE RECHERCHE, CNRS Délégation Provence et Corse

Rapporteuse

Pascal BALLE

MAITRE DE CONFERENCES, Université de Bretagne Occidentale

Examineur

Gilles BERNOT

PROFESSEUR DES UNIVERSITES, Université Côte d'Azur

Examineur

Olivier FRANCOIS

PROFESSEUR DES UNIVERSITES, Université Grenoble Alpes

Examineur


Loïc PAULEVE

CHARGE DE RECHERCHE, CNRS Délégation Aquitaine

Rapporteur

COMPLEXITÉ ET ÉVOLUTION : ÉTUDE DES RÉSEAUX BOOLÉENS À
SIGNE

RÉMI SEGRETAIN



Version du 18 avril 2024 – 15h23

J'ai vécu longtemps, beaucoup lu, étudié, pensé. Je sais désormais que je ne sais rien.

— Maître Duom Nil'Erg

Force lumineuse et bienveillante
Gratitude infinie pour celui qui guide
Respect.

— Ellana Caldin

Le ridicule tue moins que la prétention. Et il fait rire.

— Merwyn Ril' Avalon

Une page de ma vie se tourne et je suis pas certaine d'avoir lu avec attention le chapitre qui s'achève...

— Nawel Hélianthas

Je suis moi et j'ai l'intention de poursuivre mon chemin, où qu'il me mène.

— Ellana Caldin

RÉSUMÉ

Les systèmes biologiques sont complexes et il peut être difficile de les étudier *in vivo*. Les Réseaux Booléens sont une famille de formalismes fréquemment utilisée en biologie pour les modéliser quelle que soit l'échelle du système : les gènes pour les réseaux de régulation génétique, les neurones pour le cerveau ou les espèces qui composent un écosystème.

Les travaux présentés dans ce manuscrit utilisent le formalisme des Réseaux Booléens à Signe, un modèle particulièrement simple dans son expression et dans celle de ses comportements, ce qui permet de réaliser des études de grandes envergures. Nous les employons ici pour étudier les systèmes biologiques d'une manière globale : nous considérons l'ensemble de tous les réseaux possibles composés d'un nombre donné d'éléments. Cela nous donne accès toute la diversité des structures et des dynamiques dans le but d'étudier les relations entre les deux. Nous nous intéressons également à l'évolution des réseaux, leur évolutivité et leur robustesse via l'ajout ou la modification d'éléments.

Ce manuscrit présente les différentes méthodes développées afin d'obtenir de manière efficiente les ensembles complets de réseaux fiables. Le volume de données traitées est important. Différents outils logiciels spécifiques ont dû être conçus pour en permettre l'analyse, notamment une bibliothèque nommée Java-Parallel-Pipeline. Celle-ci permet la construction de chaînes de traitement dont l'exécution est automatiquement parallélisée et orchestrée de telle sorte que l'utilisation de la mémoire et des processeurs soit aussi efficiente que possible.

Nous analysons ainsi pour de large population de réseaux les liens entre la complexité de leur structure et plusieurs aspects de leur dynamique, ce qui nous permet d'établir qu'une structure complexe est nécessaire pour obtenir un comportement complexe, mais peut également permettre à un réseau de présenter de multiples comportements.

En mesurant les distances entre les réseaux de ces populations, nous évaluons leurs évolutivités et leurs robustesses et observons que des modifications de leurs structures entraînent des modifications proportionnelles de leurs dynamiques. Nous montrons ainsi que nous sommes à présent capables de cartographier l'espace des réseaux et d'étudier les divers chemins d'évolution qu'un réseau est susceptible de suivre, par la modification de ses éléments mais également par extension : l'ajout d'un nouvel élément tout en conservant à la fois sa structure et sa dynamique.

Ces travaux trouvent des applications dans divers domaines de recherche tels que les origines du vivant et l'évolution, la théorie ataviste du cancer et tout autre sujet où la question des relations entre la structure et la dynamique des réseaux, mais aussi celle de leur capacité à évoluer et à maintenir leur comportement, sont impliquées.

REMERCIEMENTS

En cours de rédaction.

PUBLICATIONS

Une partie des idées, de la méthodologie, des résultats et des figures présents dans ce manuscrit ont déjà fait l’objet de publications. Ils peuvent être retrouvés dans les articles suivants :

- Urvan CHRISTEN et al. « On Computing Structural and Behavioral Complexities of Threshold Boolean Networks ». Dans : *Acta Biotheoretica* 68.1 (2019), p. 119-138. DOI : [10.1007/s10441-019-09358-8](https://doi.org/10.1007/s10441-019-09358-8)
- Rémi SEGRETAINE et al. « A Methodology for Evaluating the Extensibility of Boolean Networks’ Structure and Function ». Dans : *Complex Networks & Their Applications IX* (2021), p. 372-385. DOI : [10.1007/978-3-030-65351-4_30](https://doi.org/10.1007/978-3-030-65351-4_30)
- Rémi SEGRETAINE et al. « Implementation of a Computing Pipeline for Evaluating the Extensibility of Boolean Networks’ Structure and Function ». Dans : *bioRxiv* (2020). DOI : [10.1101/2020.10.02.323949](https://doi.org/10.1101/2020.10.02.323949)
- Remi SEGRETAINE et al. « Who Plays Complex Music? On the Correlations Between Structural and Behavioral Complexity Measures in Sign Boolean Networks ». Dans : *2021 IEEE 21st International Conference on Bioinformatics and Bioengineering (BIBE)*. IEEE, 2021. DOI : [10.1109/bibe52308.2021.9635403](https://doi.org/10.1109/bibe52308.2021.9635403)

TABLE DES MATIÈRES

Dédication	v
Résumé	vii
Liste des figures	xvi
Liste des tableaux	xxviii
Avant-propos	xxix
Introduction	1
Les réseaux pour étudier les systèmes biologiques	4
Étudier l'évolution	5
Les Réseaux Booléens à Signe	6
Modéliser un système biologique	8
Approche et objectifs	8
I LES RÉSEAUX BOOLÉENS À SIGNE	13
1 LES FONCTIONS BOOLÉENNES À SIGNE (FBS)	15
1.1 Les Fonctions Booléennes	15
1.2 Définition des Fonctions Booléennes à Signe	16
1.3 Notations	16
1.3.1 Vecteur d'entiers	16
1.3.2 Table de vérité	16
2 LES RÉSEAUX BOOLÉENS À SIGNE (RBS)	19
2.1 Définition	19
2.1.1 Dimension d'un RBS	19
2.2 Représentation des RBS	19
2.3 Dynamique des RBS	20
2.3.1 Définition	20
2.3.2 Graphe de transition (GT)	21
2.3.3 Analyse	22
3 CLASSES D'ÉQUIVALENCES (CE)	25
3.1 Classe d'Équivalence des FBS	25
3.1.1 Définition	25
3.1.2 Équivalence par permutations	26
3.1.3 Visualiser les classes d'équivalences	28
3.2 Classes d'équivalences des RBS	30
3.2.1 Définition	30
3.2.2 Équivalence par permutations	30
3.3 Choix de modélisation : poids nuls	32
3.3.1 Impacts sur les classes d'équivalence de FBS	32
II DÉVELOPPEMENTS THÉORIQUES ET MÉTHODOLOGIQUES SUR LES RBS	35
4 L'ÉNUMÉRATION DE TOUTES LES CLASSES DE FBS	37
4.1 FBS canonique	37
4.1.1 FBS minimale	37

4.1.2	Poids triés	37
4.1.3	Unicité	38
4.2	Première méthode : Énumération des poids	38
4.3	Seconde méthode : Énumération des contraintes sur les poids	40
4.3.1	Définitions	42
4.3.2	Méthode	44
4.3.3	Règles logiques	44
4.3.4	Limites	48
5	L'ÉNUMÉRATION DE TOUTES LES CLASSES DE RBS	51
5.1	Le coût de l'énumération	51
5.2	Combinaisons de FBS	52
5.2.1	Ordre sur les classes d'équivalence de FBS	53
5.2.2	Énumération des combinaisons	53
5.3	Arrangements des FBS	54
5.4	Filtrage des réseaux déconnectés	56
5.5	Filtrage des doublons	56
5.5.1	Réseau minimal	58
5.5.2	Filtrage par sélection des réseaux minimaux	58
5.5.3	Filtrage des réseaux identiques	59
6	TECHNIQUES ET OUTILS LOGICIELS : PARALLÉLISME ET MÉLANGE DE PARADIGMES	61
6.1	Le choix du langage Java	62
6.2	Java-Parallel-Pipeline (JPP) : un outil pour faire des outils	63
6.2.1	Fonctionnement	63
6.2.2	Modularisation du code	66
6.2.3	Gestion de l'utilisation de la mémoire	66
6.2.4	Synchronisation	68
6.2.5	Les usages de JPP dans l'équipe	68
6.3	Filtrage des RBS	70
6.4	Programmation logique par contraintes	72
6.4.1	Answer Set Programming (ASP)	72
6.4.2	Architecture modulaire	72
6.4.3	Intégration	73
III	ÉTUDE DE L'ÉVOLUTION DES RBS ET DES RELATIONS ENTRE LEUR STRUCTURE ET LEUR DYNAMIQUE	75
7	RELATIONS ENTRE LA STRUCTURE ET LA DYNAMIQUE	77
7.1	Mesurer la complexité des RBS	79
7.1.1	Rareté des FBS	79
7.1.2	Centralité des RBS	80
7.1.3	Complexité du comportement	88
7.2	Résultats	90
7.2.1	Arité	92
7.2.2	Centralité par chemins d'influence	100
7.2.3	Rareté et répartition de l'influence	102
7.2.4	Complexité dynamique	104
7.2.5	Multi-attractivité	108
7.2.6	Robustesse	112
7.3	Synthèse des résultats	117

7.3.1	Comportements complexes	117
7.3.2	Multi-attractivité	117
7.3.3	Robustesse	117
8	ÉTUDIER L'ÉVOLUTION DES SYSTÈMES BIOLOGIQUES	119
8.1	Formaliser l'évolution	120
8.1.1	Robustesse et évolutivité	120
8.1.2	Définition des distances	120
8.2	Robustesse et Évolutivité : exploration du paysage des réseaux	126
8.2.1	Méthodologie	126
8.2.2	Résultats	128
8.3	Évaluer l'extensibilité de la structure et de la fonction des RBS	138
8.3.1	Définition de l'extension d'un RBS	139
8.3.2	Méthodologie	140
8.3.3	Résultats de l'extension	143
8.4	Synthèse	146
	Conclusion	149
	Évolution artificielle	152
	Atavisme	153
	BIBLIOGRAPHIE	157

LISTE DES FIGURES

Figure 1	Représentation d'un réseau	4
Figure 2	Exemple de représentation de la nature de l'influence d'un nœud vers un autre. Les deux réseaux possèdent les mêmes arcs, mais représentés différemment. À gauche, une influence négative est représentée par une flèche en T et une influence négative par une flèche en V. À droite, le type de l'influence est indiqué par le signe du poids lié à un arc.	5
Figure 3	Simulation d'une fonction booléenne à seuil, à gauche, par l'assemblage, à droite, de deux fonctions booléennes à signe. La fonction du nœud A simule l'effet du seuil et la fonction du nœud B simule l'effet des poids. Le nœud A doit être activé à l'initialisation puis se maintient lui-même activé. . .	7
Figure 4	Table de vérité représentant une FBS de dimension 2, définie par les poids $\langle 2, -1 \rangle_P$ et ayant le comportement $\langle 0, 1, 0, 1 \rangle_{TV}$. Ce dernier est obtenu par l'application de la fonction aux 4 configurations $\langle 0, 0 \rangle_{Cfg}$, $\langle 0, 1 \rangle_{Cfg}$, $\langle 1, 0 \rangle_{Cfg}$ et $\langle 1, 1 \rangle_{Cfg}$. . .	17
Figure 5	Un RBS (c) composé des deux FBS A et B dont les tables de vérité sont présentées en (a) et (b).	20
Figure 6	Graphe de transition du réseau de la figure 5-c. Le réseau présente deux comportements asymptotiques : un point fixe sur l'état $\langle 0, 0 \rangle_E$ et un cycle sur les deux états $\langle 0, 1 \rangle_E$ et $\langle 1, 1 \rangle_E$. Il faut voir ce graphe comme un hypercube de dimension d où chaque dimension représente l'état d'un nœud du réseau. Les lignes grises pointillées servent seulement à montrer la représentation de l'hypercube 2D formé par les états. Les états $\langle 0, 0 \rangle_E$ et $\langle 1, 1 \rangle_E$ sont donc distants de deux arêtes sur ce cube, puisqu'il faut modifier l'état de deux nœuds pour passer de l'un à l'autre.	21
Figure 7	Graphe de transition du RBS de la figure 5-c. Les états et arcs en rouges représentent les attracteurs et les zones jaunes les bassins d'attractions. L'attracteur faisant partie du bassin d'attraction, l'état $\langle 0, 0 \rangle_E$ est à la fois dans un attracteur ET dans le bassin d'attraction lié. Il est en de même pour l'attracteur composé des états $\langle 0, 1 \rangle_E$ et $\langle 1, 1 \rangle_E$	22
Figure 8	Deux FBS définies par des vecteurs de poids différents, mais possédant la même table de vérité. Les deux FBS sont donc équivalentes ; elles font partie de la même classe d'équivalence.	25
Figure 9	Deux FBS définies par les mêmes poids ordonnés différemment, elles possèdent donc des tables de vérité différentes. . .	26

Figure 10	Présentation visuelle de l'application d'un vecteur de permutation sur un vecteur de poids. Une fois la permutation $\langle 1, 0, 2 \rangle_{\text{prm}}$ appliquée, le poids p_0 devient p_1 puisque l'indice de valeur 0 se trouve à l'indice 1 dans le vecteur de permutation.	27
Figure 11	Exemple de permutation des poids en dimension 3. La permutation nulle $\langle 0, 1, 2 \rangle_{\text{prm}}$ ne modifie pas le vecteur de poids, tandis que la permutation $\langle 2, 0, 1 \rangle_{\text{prm}}$ transforme le vecteur de poids en $\langle 6, 2, 4 \rangle_{\text{p}}$	27
Figure 12	Espace des poids en dimension 2 dans la boule unité. Les différentes zones délimitées représentent les différentes classes d'équivalence de FBS. Les zones de même couleur sont équivalentes par permutation, comme le met en avant la ligne blanche. Pour chaque classe, la sortie de la table de vérité correspondante est rappelée. Les rayures blanches indiquent à quelle classe appartient l'axe lié, par exemple un point sur l'origine appartient à la classe $\langle 0, 0, 0, 0 \rangle_{\text{TV}}$	28
Figure 13	Espace des poids en dimension 3 dans la boule unité. Les trois images montrent la même boule sous différents angles. Les lignes de couleurs sont les intersections entre la surface de la boule et les plans dont les équations sont données dans la légende. Ces lignes sont en pointillées lorsqu'elles passent derrière un des plans visibles. Les surfaces sur la boule délimitées par ces lignes définissent les différentes classes d'équivalence. Les plans qui délimitent les classes d'équivalence forment des "pyramides" dont les bases sont les surfaces sur la boule, leurs pointes sont tournées vers l'origine. Les classes équivalentes par permutations des poids sont mises en avant par les trois plans bleus-gris qui délimitent les six permutations possibles en dimension 3. Ces derniers sont vus de face dans la première image et de côté dans la seconde. La troisième image montre une des six tranches de la boule délimitées par les plans de permutation. Chacune de ces tranches contient une permutation des dix classes d'équivalence de FBS en dimension 3. Il est possible de manipuler cette figure en 3D à l'adresse suivante : https://www.geogebra.org/m/kgqbkhqk ou en scannant le QR code.	29
Figure 14	Deux RBS de la même classe d'équivalence. Ils sont composés des mêmes classes d'équivalence de FBS et ont la même dynamique.	30
Figure 15	Deux RBS composés des mêmes classes d'équivalence de FBS mais n'ayant pas la même dynamique. Dans le RBS de droite, la FBS du nœud A est permutée par rapport à son homologue dans le RBS de gauche. Il en résulte une dynamique différente, comme l'attestent les graphes de transition.	31
Figure 16	Deux RBS composés des mêmes classes d'équivalence de FBS. Les dynamiques semblent différentes, cependant elles sont équivalentes par permutation des deux nœuds du réseau.	31

Figure 17	Table de vérité d'une FBS de dimension 2 et sa projection en dimension 3. Puisque le poids ajouté est nul, la sortie de la table de vérité reste la même que l'entrée liée à ce poids soit à 1 ou à 0. Afin de mettre en avant que la FBS reste la même après la projection, le poids nul ajouté est grisé, de même que les configurations où l'entrée liée à ce dernier est à 1.	32
Figure 18	Espace des poids en dimension 2, découpé selon les classes d'équivalence de FBS. Les classes d'équivalence projetées sont hachurées.	33
Figure 19	Discrétisation de l'espace des poids en dimension 2. Chaque point représente un vecteur de poids entiers, leurs couleurs indiquent la classe d'équivalence dont ils font partie. . . .	38
Figure 20	Illustration d'une classe d'équivalence trop "fine" dans l'espace des poids. Avec cet intervalle, aucun points énumérés (en noirs) ne se trouve dans la classe d'équivalence délimitée par les droites. Les points bleus désignent les premiers points permettant d'obtenir des FBS de cette classe d'équivalence. Cette dernière n'est donc pas énumérée avec cet intervalle et l'ensemble de FBS généré est incomplet.	39
Figure 21	Espace des poids divisé par les plans issus des configurations. $d = 2$	40
Figure 22	Exemple de contraintes incompatibles sur l'espace des poids. Les contraintes $p_A > 0$ en (1) et $p_B > 0$ en (2) délimitent chacune une moitié de l'espace. Leurs intersections donnent (3). (4) montre la zone délimitée par la contrainte $p_A + p_B \leq 0$, elle est incompatible avec (3) : leur intersection est nulle. Étant donné $p_A > 0$ et $p_B > 0$, la contrainte sur le plan $p_A + p_B = 0$ ne peut donc être que $p_A + p_B > 0$	41
Figure 23	C_A et C_B sont des dépendances de C_{AB}	43
Figure 24	Arbre des dépendances en dimension 3. Une flèche entre deux contraintes indique que la contrainte au départ de la flèche est une dépendance de la contrainte à l'arrivée. Les contraintes sont classées selon leurs niveaux. Le chiffre en rouge sous chaque contrainte indique son rang.	44
Figure 25	Relation d'inférence entre contraintes illustrant la règle "Ma supérieure l'a dit" pour chaque niveau de contrainte de la dimension 5. Une flèche entre deux contraintes implique que si la première est négative alors la seconde l'est également. Les nombres en rouge sont les rangs des contraintes, les contraintes alignées verticalement au sein du même niveau possèdent la même valeur de rang.	45
Figure 26	Exemple de l'inférence du signe d'une contrainte lorsque les dépendances sont un mélange de contraintes positives et de contraintes négatives. L'étape 1 présente l'état de départ : l'inférence du signe de C_{ABCD} depuis le signe de ses dépendances n'est pas possible puisqu'elles ne sont pas toutes du même signe.	46

Figure 27	L'étape 2 montre la séparation entre les côté positifs et négatifs des dépendances, avec en gris le côté perdant. Les dépendances ABC et $\neg ABD$ forment une paire où $Z = AB$.	47
Figure 28	L'étape 3 montre que $\neg ABD$ annule l'influence de ABC parce qu'elles partagent le même côté positif AB , mais ce côté est perdant dans $\neg ABD$. La dépendance ABC est donc ignorable puisque son influence positive sur la contrainte C_{ABCD} , provenant de AB , est surpassée par l'influence négative de $\neg D$.	47
Figure 29	L'étape 4 montre que puisque la dépendance ABC est ignorable, il ne reste que des dépendances négatives, il est donc possible d'inférer le signe de C_{ABCD} : négatif.	47
Figure 30	Schéma des étapes de génération des RBS	52
Figure 31	Exemple en dimension 2 des combinaisons générées à partir d'un ensemble fictif de deux FBS. Parmi les combinaisons équivalentes, une seule est retenue.	53
Figure 32	Table de vérité représentant une FBS de dimension 2, définie par les poids $\langle 2, -1 \rangle_p$ et ayant le comportement $\langle 0, 1, 0, 1 \rangle_{Tv}$. L'identifiant de cette classe de FBS est 5, qui est la valeur décimale de 0101_2 .	53
Figure 33	Schéma des étapes de l'énumération des combinaisons de FBS avec l'ordre entre FBS.	54
Figure 34	Traduction d'un RBS depuis la forme d'une matrice de poids vers la forme de graphe.	55
Figure 35	Les différents réseaux énumérables à partir d'une même combinaison de FBS canoniques en dimension 2. L'opérateur $+$ symbolise l'application des arrangements aux FBS.	55
Figure 36	Exemple de RBS de dimension 3 où les nœuds ne sont pas connectés. Les arcs grisés portent des poids d'une valeur de 0; ils n'existent donc pas dans ce modèle.	56
Figure 37	Deux RBS équivalents par permutations de leurs nœuds. Les nœuds portent les mêmes classes d'équivalence de FBS et les arrangements appliqués sont différents, mais ils font partie de la même classe d'équivalence. Lorsque les nœuds de l'un des deux réseaux sont permutés, l'autre réseau est obtenu. Les flèches pointillées symbolisent cette permutation.	57
Figure 38	Deux RBS identiques. Les arrangements appliqués sont différents, mais cela ne change pas le réseau final puisque la seconde FBS possède deux fois le même poids.	57
Figure 39	Ordre de lecture d'une matrice.	58
Figure 40	Comparaison entre deux matrices de poids pour déterminer la minimale. Les poids sont comparés deux à deux selon l'ordre de gauche à droite et de haut en bas.	58
Figure 41	Processus d'évaluation d'un réseau ayant deux nœuds portant la même classe d'équivalence de FBS. Si le réseau est le minimal parmi les versions permutées alors il est conservé.	59
Figure 42	Exemple de la division d'un traitement en plusieurs étapes. Chaque étape devient un processeur du pipeline.	64

Figure 43	Exemple du passage des données entre deux processeurs JPP. (1) les données produites par le processeur A sont transmises une par une au processeur B, chacune d'entre elle donne lieu à une exécution du processeur B. (2) les données sont transmises par lot de 3, chaque lot donne lieu à une exécution du processeur B. (3) les données sont transmises d'un seul bloc, le processeur B n'est exécuté qu'une seule fois.	65
Figure 44	Illustration de l'ordonnancement des exécutions des processeurs dans un pipeline disposant de deux threads. L'ordonnancement est donné selon un temps logique indiqué par les chiffres. Ces derniers sont en rouge ou bleu pour indiquer lequel des deux threads exécute le processeur en question. Le nombre attribué à une donnée indique le temps logique de sa génération. Les threads se répartissent à la volée sur les processeurs selon les données disponibles. Les deux threads peuvent donc exécuter le même processeur en parallèle sur des données différentes, comme le processeur B au temps 2.	65
Figure 45	Exemple comparant l'utilisation de la mémoire entre deux modes d'ordonnancement : la répartition équitable entre les processeurs et la priorité pour les processeurs plus profonds. Pour simplifier l'exemple, les pipelines ne disposent que d'un seul thread. L'exécution du premier pipeline échoue : avec la répartition équitable des threads, le processeur A produit trop de données et sature la mémoire au temps 5. L'exécution du second pipeline parvient à écouler les données produites par le processeur A grâce à la priorité en profondeur et atteint le pas de temps 10 sans saturer la mémoire.	67
Figure 46	Exemple de limitation du nombre de thread par processeur. Dans le premier pipeline, sans limite, au temps 1 les deux threads débutent une exécution du processeur A, menant à une saturation de la mémoire. Dans le second pipeline, le processeur A est limité, un seul thread peut l'exécuter en même temps. Au temps 1 seul le thread 1 l'exécute tandis que le thread 2 est inactif. Puis les deux threads exécutent le processeur B pour consommer les données produites par le processeur A. La mémoire n'est pas saturée.	67
Figure 47	Exemple de retenue de données en attente d'un évènement. Le processeur A est le premier du pipeline et a quatre données à traiter. Le processeur B doit attendre la fin du processeur A pour commencer son traitement. Il y a donc une file d'attente entre les deux processeurs. Cette dernière est débloquée au temps 4 lorsque A a terminé, B peut alors débiter ses exécutions.	68
Figure 48	Capture d'écran d'un message de mon directeur de thèse Nicolas Glade : " <i>@remi.segretain j' imagine qu'il n'existe pas de réseau d=3 capable de ça ?</i> ".	70

Figure 49	Modules ASP définissant diverses notions autour des RBS. Les modules au-dessus dépendent des modules en dessous.	73
Figure 50	Schéma des trois caractéristiques de la dynamique d'un réseau : la complexité, la robustesse et la multi-attractivité. Les trois réseaux et leur graphe de transition représentent chacun une des catégories de dynamique. Les arcs colorés mettent en avant les attracteurs et les bassins d'attraction d'intérêt. En haut se trouvent les réseaux capables d'un comportement complexe, ce qui se traduit par un attracteur occupant la majorité du graphe de transition. En bas à gauche les réseaux capables de plusieurs comportements différents. Enfin en bas à droite les réseaux possédant un comportement robuste. L'exemple présente une robustesse aux erreurs d'états : l'attracteur possède un grand bassin d'attraction, en cas d'erreur l'état du réseau à toutes les chances de revenir à terme dans l'attracteur.	78
Figure 51	Décompte du nombre de point de l'espace contenu dans chaque classe d'équivalence de dimension 2 afin d'estimer leurs volumes. Les poids sont limités à des valeurs comprises entre -7 et 7 , l'espace compte donc 225 points, répartis entre les sept classes d'équivalence. Chaque couleur de point dénote une classe d'équivalence différente.	80
Figure 52	Exemple des probabilités d'influence des arcs entrants sur un nœud. La somme des valeurs absolues des poids est égale à 4, l'influence de l'arc a est donc de $2/4 = 0.5$ et celles de b et c de $1/4 = 0.25$	82
Figure 53	Exemple de calcul de la probabilité d'influence du chemin en rouge entre les nœuds A et B. Les influences de chacun des arcs du chemin sont multipliées entre elles, puis le produit est normalisé par la longueur du chemin, ici 3.	83
Figure 54	Exemple de la probabilité globale que le nœud A influence le nœud B. Il existe trois chemins de A vers B, l'union de leurs probabilités respectives donne la probabilité globale.	84
Figure 55	Exemple de répartition de l'influence dans des réseaux. Dans le réseau de gauche, le nœud A est le seul à posséder des arcs sortants, il concentre donc toute l'influence du réseau. Dans le réseau de droite, les deux nœuds ont le même nombre d'arcs avec les mêmes valeurs de poids, ils influencent donc autant le réseau l'un que l'autre.	85
Figure 56	RBS de dimension 4. Les arcs portent deux valeurs, en noir leur poids et en rouge leur probabilité d'influence.	85
Figure 57	Influences directes des nœuds (en rouge), calculées à partir des probabilités d'influence de leurs arcs sortants. Le calcul pour le nœud A est en bleu, il possède trois arcs sortants ayant chacun une probabilité d'influence de 0.5, son influence directe est égale à la somme de leurs influences, divisée par la dimension.	85

Figure 58	Influences indirectes des nœuds (en bleu), calculées à partir des influences directes (en rouge). Le calcul pour le nœud C est en vert, il influence les nœuds B et D, donc son influence de degré 1 est égale à la somme des produits des influences de degré 0 des nœuds B et D avec respectivement $PI(Arc_{CB})$ et $PI(Arc_{CD})$, qui sont les probabilités d'influence des arcs reliant C à B et C à D.	86
Figure 59	Répartition de l'influence du réseau des figures 56-58. La moitié de l'influence se situe dans 1.25 nœuds.	87
Figure 60	Exemples de la répartition de l'influence dans des cas aux bornes. Au minimum, un seul nœud concentre toute l'influence, la valeur de répartition est donc de 0.5. Au maximum la répartition est parfaite, la moitié de l'influence se situe dans la moitié des nœuds donc la valeur de répartition est de $d/2$	87
Figure 61	Décomposition en sous-blocs de la musique 10011*. Le motif 10011 est répété pour éviter les effets aux bords. Les sous-blocs recherchés sont tous les blocs de la taille 1 à la taille de la longueur de la musique, ici 5.	89
Figure 62	Explication des histogrammes 2D utilisés pour présenter les résultats. Ces histogrammes permettent de croiser trois mesures différentes. Deux mesures forment les axes et la troisième est présentée sous la forme d'une moyenne pour chacune des classes de l'histogramme. Les valeurs de ces moyennes sont données par la couleur des points et l'échelle de couleurs dans la légende. La taille des points indique le nombre de musiques observées dans chaque classe. En bas à droite se trouvent les histogrammes des moyennes et des écarts-types (SD), ils permettent d'estimer l'ampleur des variations de la troisième mesure au sein de chaque classe. . .	90
Figure 63	Histogrammes 2D en dimension 3 en haut et 4 en bas de la complexité du comportement et de la rareté des fonctions , colorés selon l' arité moyenne . Les RBS énumérés incluent les FBS projetées et innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	93
Figure 64	Histogrammes 2D en dimension 3 en haut et 4 en bas de la complexité du comportement et du nombre d'attracteurs , colorés selon l' arité moyenne . Les RBS énumérés incluent les FBS projetées et innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	95
Figure 65	Histogrammes 2D en dimension 3 en haut et 4 en bas de l' arité et de la rareté des fonctions , colorés selon la répartition moyenne de l'influence . Les RBS énumérés incluent les FBS projetées et innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	96

Figure 66	Histogrammes 2D en dimension 3 en haut et 4 en bas de l' arité et de la répartition de l'influence , colorés selon la rareté moyenne des FBS . Les RBS énumérés incluent les FBS projetées et innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	97
Figure 67	Corrélogramme des mesures effectuées en dimension 3 sur les RBS incluant les FBS projetées et innées. Au croisement de deux mesures, la taille et l'intensité de la couleur du point indique la force de la corrélation et la couleur, bleue ou rouge, indique respectivement si cette corrélation est positive ou négative. Toutes les p-values sont au moins inférieures à 10^{-6} à l'exception de la corrélation entre l'arité et le nombre d'attracteurs (2.43×10^{-3}).	98
Figure 68	Histogrammes 2D en dimension 3 en haut et 4 en bas de l' arité et de la centralité par chemins , colorés selon la rareté moyenne des FBS . Les RBS énumérés incluent les FBS projetées et innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	101
Figure 69	Histogrammes 2D en dimension 3 en haut et 4 en bas de la rareté des FBS et de la répartition de l'influence , colorés selon la taille moyenne des attracteurs . Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	102
Figure 70	Corrélogramme des mesures effectuées en dimension 3 sur les RBS n'incluant que les FBS innées. Au croisement de deux mesures, la taille et l'intensité de la couleur du point indique la force de la corrélation et la couleur, bleue ou rouge, indique respectivement si cette corrélation est positive ou négative. Toutes les p-values sont au moins inférieures à 10^{-6} à l'exception des corrélations entre la répartition d'influence et le nombre d'attracteurs : 2.25×10^{-5} pour une corrélation de 0.028; ainsi qu'entre cette première et la taille du bassin d'attraction : 1.02×10^{-2} pour une corrélation de -0.0167	103
Figure 71	Histogrammes 2D en dimension 3 en haut et 4 en bas de la taille de l'attracteur et de la taille du bassin d'attraction , colorés selon la complexité moyenne des comportements . Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	105
Figure 72	Histogrammes 2D en dimension 3 en haut et 4 en bas de la complexité du comportement et de la répartition de l'influence , colorés selon la taille moyenne des attracteurs . Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	106

Figure 73	Histogrammes 2D en dimension 3 en haut et 4 en bas de la complexité du comportement et de la rareté des FBS , colorés selon la taille moyenne des attracteurs . Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	107
Figure 74	Histogrammes 2D en dimension 3 en haut et 4 en bas de la répartition de l'influence et du nombre d'attracteurs , colorés selon la taille moyenne des attracteurs . Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	108
Figure 75	Histogrammes 2D en dimension 3 en haut et 4 en bas de la rareté des FBS et du nombre d'attracteurs , colorés selon la répartition moyenne de l'influence . Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	109
Figure 76	Histogrammes 2D en dimension 3 en haut et 4 en bas de la complexité du comportement et du nombre d'attracteurs , colorés selon la taille moyenne des attracteurs . Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	110
Figure 77	Histogrammes 2D en dimension 3 en haut et 4 en bas de la taille de l'attracteur et de la taille du bassin d'attraction , colorés selon le nombre moyen d'attracteurs . Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	111
Figure 78	Histogrammes 2D en dimension 3 en haut et 4 en bas de la taille du bassin d'attraction et du nombre d'attracteurs , colorés selon la robustesse moyenne . Obtenu par un échantillonnage de 1% des RBS de la dimension 4 n'incluant que les FBS innées.	113
Figure 79	Histogramme 2D en dimension 4 de la robustesse et de la répartition de l'influence , colorés selon la rareté moyenne des FBS . Obtenu par un échantillonnage de 1% des RBS de la dimension 4 n'incluant que les FBS innées.	114
Figure 80	Histogrammes 2D en dimension 3 en haut et 4 en bas de la complexité du comportement et de la répartition de l'influence , colorés selon la taille moyenne des bassins d'attraction . Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	115

Figure 81	Histogrammes 2D en dimension 3 en haut et 4 en bas de la complexité du comportement et de la rareté des FBS , colorés selon la taille moyenne des bassins d'attraction . Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.	116
Figure 82	Exemple de calcul de la distance structurelle de Hamming entre deux RBS de dimension 2. Les poids colorés diffèrent entre R et R' , la somme de ces différences donne la distance structurelle de Hamming entre les deux réseaux.	121
Figure 83	Exemples de l'importance d'un arc dans la connectivité d'un réseau. Les arcs en rouge sont plus importants que les arcs en bleu. Dans R_1 , l'arc rouge est le seul à relier les deux moitiés du réseau, tous les chemins entre les nœuds de gauche et de droite passent donc par cet arc tandis que l'arc bleu ne relie que le nœud D à lui-même. Dans R_2 , les deux arcs colorés ont des positions similaires, mais l'arc rouge ayant un poids plus important, en valeur absolue, les chemins qui l'empruntent ont plus d'influence que ceux qui empruntent l'arc bleu.	122
Figure 84	Illustration de la distance dynamique de Hamming entre deux états. L'état $\langle 0, 0 \rangle_E$ est distant de 1 avec les états $\langle 0, 1 \rangle_E$ et $\langle 1, 0 \rangle_E$ et de 2 avec l'état $\langle 1, 1 \rangle_E$	123
Figure 85	Exemple de trois graphes de transition différents. GT_1 et GT_2 possèdent les mêmes attracteurs, mais diffèrent sur leurs bassins d'attraction. Pourtant, selon la distance dynamique de Hamming, GT_1 est plus proche de GT_3 qu'il ne l'est de GT_2	124
Figure 86	Schéma de la fragmentation de l'énumération des tâches dans un pipeline JPP. Dans le premier cas, la tâche initiale génère trop de tâches concrètes ce qui sature la mémoire. Dans le second cas, avec la fragmentation, puisque les tâches des processeurs les plus profonds sont prioritaires, les premières tâches concrètes générées sont exécutées avant que les suivantes ne soient énumérées.	127
Figure 87	Schéma du pipeline JPP permettant de calculer les distances entre tous les RBS jusqu'en dimension 3. Pour des dimensions supérieures, le stockage des RBS en mémoire risque de ne pas être possible.	127

Figure 88	Matrices des distances en dimension 2 à gauche et 3 à droite. Dans chacune d'entre-elles, les RBS sont regroupés selon la distance structurelle de Hamming. La couleur de chaque carré indique la distance qui sépare les deux RBS concernés. Dans le cas de la dimension 3, puisqu'il existe 31199 RBS, la résolution requise pour afficher toutes les distances individuellement serait trop importante. En conséquence, la couleur d'un carré est le résultat de la moyenne des distances entre 100 RBS. Les trois distances calculées sont la distance structurelle (HSTR), la distance dynamique de Hamming (HDYN) et la distance dynamique sur les attracteurs (CYCLE).	129
Figure 89	Histogrammes 2D en dimension 2 en haut et en dimension 3 en bas, croisant la distance structurelle de Hamming, la distance dynamique de Hamming et la distance dynamique sur les attracteurs. La couleur et la taille des points indiquent le nombre de paires de réseaux par classe des histogrammes.	130
Figure 90	Métagraphe structurel des 60 RBS de dimension 2. Dans cet exemple, deux RBS sont reliés s'ils sont distants de 1 selon la distance structurelle de Hamming ($\epsilon = 1$). Les numéros sur les nœuds sont les identifiants attribués à chaque RBS. .	132
Figure 91	Métagraphes des RBS de dimension 2 avec la distance dynamique de Hamming. Les arcs rouges dans les métagraphes structurels (à gauche) sont ceux qui n'existent pas dans les métagraphe restreints (à droite) à cause de l'ajout du seuil δ . Les numéros sur les nœuds sont les identifiants attribués à chaque RBS.	133
Figure 92	Métagraphe des RBS de dimension 2 avec $\epsilon = 1$, coloré selon la robustesse. Cette dernière est calculée avec $\delta = 0$ selon la distance dynamique de Hamming.	134
Figure 93	Tableau des robustesses moyennes des RBS de dimension 2 selon les différentes valeurs de ϵ pour le métagraphe structurel et de δ pour la robustesse, avec la distance dynamique de Hamming.	135
Figure 94	Tableau des robustesses moyennes des RBS de dimension 2 selon les différentes valeurs de ϵ pour le métagraphe structurel et de δ pour la robustesse, avec la distance dynamique sur les attracteurs.	135
Figure 95	Métagraphes des RBS de dimension 2 avec $\epsilon = 1$, $\delta = 1$, coloré selon l'évolutivité. La distance dynamique considérée est celle de Hamming. Les réseaux entourés sont commentés dans le texte.	137
Figure 96	Histogramme 2D de la complexité dynamique et structurelle des Réseaux Booléens à Seuil de dimension 4. La couleur des points indique le nombre de couples $\{M, R\}$, où M représente une musique et R le réseau capable de la jouer sur l'un de ses nœuds. Au plus un point est jaune, au plus il contient de couples.	138
Figure 97	Schéma des contraintes de l'extension d'un réseau.	140

- Figure 98 Exemple d'extension d'un RBS de dimension 2. En haut le réseau R_1 de dimension 2 avec son graphe de transition. Le comportement considéré est celui du nœud A en rouge : $M_1 = 10^*$. Il est étendu par le suffixe $M_k = 1$. L'extension de R_1 mène à 48 possibilités, 2 d'entre-elles sont présentées. En bas : deux RBS R avec leurs graphes de transition respectifs. Les nœuds et arcs ajoutés par l'extension sont en gris afin de mettre en avant la conservation de la structure de R_1 . Le comportement du nœud A dans les deux RBS R respecte la contrainte $M = M_1 \cdot M_k$ puisque $M = 101^*$ 141
- Figure 99 Schéma du pipeline en charge de calculer d'une part l'extension des RBS et d'autre part les mesures permettant de les analyser. 142
- Figure 100 Histogramme 3D présentant les 777216 quadruplets $\{R_1, M_1, R, M\}$ résultants de l'extension des RBS de dimension 2 vers les RBS de dimension 3. L'axe bleu mesure la complexité structurelle de R_1 , l'axe vert la complexité dynamique de M_1 et l'axe en profondeur la complexité dynamique de M . La couleur des points indique la moyenne de complexité structurelle des R présents dans cette classe de l'histogramme. La taille des points, en échelle logarithmique, indique le nombre de R recensés dans cette classe. L'histogramme 2D en haut de la figure correspond à la "face avant" de l'histogramme 3D, il présente le croisement de la complexité structurelle et de la complexité dynamique des RBS de dimension 2. 144
- Figure 101 Projections 1D des trois axes de l'histogramme 3D de la figure 100. Les multiples fréquences présentes dans chaque classe de ces histogrammes 1D résultent de la projection des classes de l'histogramme 3D. Pour chaque série de projections en ligne, la taille et la couleur des points représentent les moyennes de mesures additionnelles pour chaque classe de l'histogramme 3D. Le croisement de ces projections permet de mieux suivre les corrélations entre les mesures présentées. 145
- Figure 102 Schéma du *paysage des réseaux*. Les couches représentent les différentes dimensions, chacune représente l'espace des RBS de cette dimension. Ces espaces sont métrés par la distance structurelle de Hamming. Chaque point représente un RBS, sa couleur symbolise sa dynamique. Deux points de la même couleur représentent donc deux RBS différents structurellement, mais qui présentent la même dynamique. Une flèche pleine représente l'évolution par extension, tandis qu'une flèche pointillée représente une évolution par mutation : la modification de la valeur d'un poids. 146
- Figure 103 Illustration de la re-primarisation des systèmes biologiques. Les cernes de l'arbre représentent les différents éléments structurels apparus au fil de l'évolution. 154

LISTE DES TABLEAUX

Tableau 1	Les différentes configurations de valeurs possibles en dimension 2 pour les variables d'entrée, notées x_0 et x_1	15
Tableau 2	Acronymes utilisés pour indiquer la nature des vecteurs d'entiers.	16
Tableau 3	Nombre de vecteurs à énumérer et intervalle des poids minimum selon la dimension pour énumérer toutes classes d'équivalence de FBS. En dimension 2, avec l'intervalle prévu, les poids peuvent prendre 5 valeurs différentes. En dimension 3, 7 valeurs différentes <i>etc</i>	38
Tableau 4	Nombre de classes d'équivalence innées et cumulées (innées + projetées) de FBS selon la dimension d . Tels que trouvés avec la méthode d'énumération des poids.	39
Tableau 5	Nombre de classes d'équivalence de FBS et de RBS par dimension, obtenu par l'énumération des poids pour les FBS et par la méthode d'énumération des RBS présentée dans ce chapitre. Le nombre de classes d'équivalence de FBS cumulées correspond à la somme des classes d'équivalence innées et projetées. Le nombre de RBS en dimension 5 et 6 n'est pas précisément connu, la valeur indiquée est le maximum théorique obtenu par la formule 6	51
Tableau 6	Tableau des influences des nœuds, du degré 0 jusqu'à N , pour le réseau des figures 56-58.	86
Tableau 7	Résumé des différentes mesures effectuées lors de l'énumération de tous les RBS de dimension 3 incluant les FBS projetées.	94
Tableau 8	Tableau des corrélations selon la dimension, entre la distance structurelle de Hamming (HSTR), la distance dynamique de Hamming (HDYN) et la distance dynamique sur les attracteurs (CYCLE). Elles sont toutes très significatives; la plus haute p -value est de l'ordre de 10^{-50} et toutes les autres sont inférieures à 10^{-200}	128
Tableau 9	Nombres connus de FBS, RBS, triplet $\{R_1, M_1, M\}$ et de RBS étendus R par dimension d lors des calculs de l'extension. Les intervalles de valeurs sont des estimations fondées sur l'extension des RBS de dimension 2 vers 3.	143

AVANT-PROPOS

LA THÈSE ET LE COVID

Je tiens à préciser l'objectif de cette section. Il n'est ni d'exposer des plaintes, ni de chercher à excuser des manquements de mon travail. Non, cette section cherche à apporter un éclairage, sur les difficultés rencontrées, sur un aspect de ma thèse que je ne souhaite pas laisser de côté au prétexte qu'il est plus sombre.

La pandémie de covid a eu un impact important sur le déroulement de ma thèse. En mars 2020, ma thèse avait alors débuté depuis 6 mois, beaucoup de travail avait déjà été réalisé et la suite s'annonçait très bien. Le covid et le premier confinement ont donné un coup d'arrêt brutal. D'abord en étant directement infecté : j'ai passé ce confinement cloué au lit et les mois qui suivent à retrouver une forme physique et mentale convenable. Ensuite et en parallèle, par l'organisation en catastrophe du déroulement des enseignements à distances, puisque j'étais alors directement responsable d'un cours complet (Architecture Logicielle, à Polytech Grenoble).

Ce n'est qu'en été, une fois les enseignements de l'année terminés, pour moi, mais également pour les autres membres de l'équipe et que le laboratoire a recommencé à vivre que j'ai pu reprendre le travail, à cadence réduite. Une rechute en septembre, suivi du second confinement, ont réduit à néant ce petit rythme de travail. Ma motivation et l'intérêt que je portais à ma thèse en ont sérieusement pris un coup.

Après cela, je ne peux me défaire du sentiment que les progrès réalisés pendant toute l'année 2021 n'ont été possibles que par l'inertie restante des 6 premiers mois de thèse. Ce n'est qu'au fil de 2022 que j'ai réellement retrouvé goût à ma thèse, du plaisir à mon travail et un nouvel élan.

Ces lignes, j'en conviens, ne sont guère joyeuses et pourraient donner une fausse idée de mon ressenti de la thèse. Si je regrette les conséquences des événements sur mon moral durant cette période, ainsi que sur le degré d'aboutissement de mes travaux ; le sentiment qui domine largement reste la fierté de mes réalisations, dont ce manuscrit et les développements théoriques et logiciels qui ont entre autre permis les travaux des étudiants que nous avons encadrés récemment.

STYLE DE RÉDACTION

J'ai fait le choix des styles de rédaction qui suivent, afin, autant que possible, de garder ce manuscrit accessible et confortable à lire.

Les notions introduites, en plus d'être définies formellement, sont autant que possible illustrées et expliquées verbalement dans le texte.

Pour éviter au lecteur des aller-retours, les citations apparaissent dans la marge du texte sous forme abrégée. La bibliographie complète est bien entendu disponible en fin de document.

Enfin, pour que les figures apparaissent sur la même double page que le texte qui les commente en version imprimée, certaines pages, au sein d'un chapitre, peuvent être laissées incomplètes, voire entièrement vierges.

INTRODUCTION

Alea jacta est...

INTRODUCTION

Comment les organismes vivants sont-ils apparus ? Comment sont-ils devenus ce qu'ils sont aujourd'hui ? Ce sont les deux grandes questions qui sous-tendent les travaux menés dans ce manuscrit, qui, je l'espère, offre un pas de plus en direction de leurs réponses.

Qu'est-ce qu'un organisme vivant ? Encore une vaste question, mais qui n'est pas le sujet ici. Nous travaillons avec la définition (l'hypothèse ?) très abstraite suivante : les organismes vivants sont des ensembles d'éléments, à différentes échelles, dont les interactions font émerger des comportements globaux. Ce sont par exemple les interactions entre protéines ou entre les gènes au niveau moléculaire, les signaux électriques entre neurones à l'échelle des tissus, la synchronisation entre les différents organes à l'échelle d'un individu ou encore les interactions intra et inter-espèces au sein d'un écosystème.

Ces éléments forment des systèmes : les "actions" de chaque élément influencent la manière dont lui et les autres se comportent et se comporteront ensuite. En biologie, il peut être difficile de comprendre la manière dont tous ces éléments s'intercontrôlent. En conséquence, même en toute connaissance, toute compréhension des différents éléments, prédire le comportement global des systèmes biologiques est ardu : ce sont des systèmes complexes.

Cette complexité des systèmes biologiques, la manière dont leurs éléments se sont mis à interagir de façon harmonieuse, les systèmes de contrôle nécessaires, *etc* ne sont pas apparus en un jour. Ils sont le fruit de l'évolution, depuis les origines du vivant à nos jours. Les systèmes biologiques encore présents aujourd'hui ont traversé au fil du temps des environnements différents, chacun amenant des contraintes particulières. Ces systèmes, pour rester viables, ont du progressivement s'adapter. L'accumulation de ces modifications est une des raisons pour laquelle ces systèmes nous paraissent si complexes. L'évolution n'est pas un ingénieur ! Les systèmes biologiques n'ont pas été conçus dans le but de les amener à ce qu'ils sont aujourd'hui. Ils n'ont d'ailleurs pas été conçus tout court. Ils ne sont que le résultat de modifications erratiques auxquelles ne s'applique finalement qu'une seule règle : survivre. Il n'est donc pas rare d'observer des systèmes dont certaines caractéristiques sont aujourd'hui inutiles ou aberrantes et qui ne seraient surement pas incluses si ces systèmes devaient apparaître maintenant. Soit ces caractéristiques ont été nécessaires à une époque, soit elles n'ont jamais posé de problèmes ; toujours est-il que les systèmes ont ensuite évolué en les incluant, ce qui les a mené à leur forme moderne. Au début de ce paragraphe, je dis que les éléments des systèmes biologiques actuels interagissent de manière harmonieuse. Ce n'est pas vrai, ce n'est qu'un biais bien humain que de mettre sur un piédestal ce qui nous fascine et ne comprenons pas vraiment. L'évolution ne sélectionne ni l'harmonie, ni l'efficacité, seulement ce qui survit.

LES RÉSEAUX POUR ÉTUDIER LES SYSTÈMES BIOLOGIQUES

Les systèmes biologiques sont donc des systèmes complexes. D'un point de vue global, il est difficile dans un tel système, parfois même impossible, de comprendre le rôle d'un élément ou d'identifier un phénomène, tant il y a d'interactions croisées. Afin de réduire la difficulté de cette tâche, une approche utilisée est dans un premier temps d'étudier ces systèmes de manière théorique et indirecte, en travaillant sur un modèle. Dans le cas des systèmes biologiques, il est courant de les modéliser sous la forme de réseaux.

Un réseau est un ensemble d'objets, appelés des *nœuds*. Ces derniers sont reliés lorsque les éléments qu'ils représentent interagissent. Tous les éléments n'affectent pas nécessairement tous les autres. Aussi, un élément peut en influencer un autre sans que cela ne soit réciproque : l'influence est alors unidirectionnelle. Dans ce cas, le lien entre deux éléments est orienté et est appelé un *arc*, symbolisé par une flèche. Dans ce manuscrit, tous les liens employés seront des arcs, deux éléments qui s'entre-influencent seront donc reliés par deux arcs, l'un dans un sens et l'autre dans le sens inverse. Un arc est dit *sortant* du point de vue du nœud d'où il part, et il est dit *entrant* pour le nœud qui le reçoit. La figure 1 introduit la manière dont les réseaux sont représentés.




Figure 1 : Illustration d'un réseau. Les cercles représentent les nœuds, les flèches représentent les arcs.

À partir de cette définition, de multiples formalisations des réseaux existent, adaptées pour représenter divers types spécifiques de réseaux biologiques (les réseaux sont également employés comme outils de modélisation dans d'autres domaines que la biologie, tels que les sciences sociales ou l'informatique). Les réseaux de Thomas [5] par exemple, sont largement utilisés en biologie du fait de leur expressivité. Ils permettent d'exprimer de manière naturelle les relations qui gouvernent les réseaux génétiques et métaboliques.

Nous nous intéressons dans ce travail aux réseaux d'automates booléens, introduit en premier lieu par McCulloch et Pitts en 1943 [6] dans le cadre de l'étude des neurones. Brièvement, (ceux-ci seront introduits plus formellement dans la suite de ce manuscrit) la caractéristique d'un réseau dit *Booléen* est que chacun de ses nœuds peut se trouver dans deux états possibles : *actif* ou *inactif* ; et est porteur d'une *fonction booléenne*, qui dicte l'état du nœud selon l'état de tous les nœuds du

[5] THOMAS « On the Relation Between the Logical Structure of Systems and Their Ability to Generate Multiple Steady States or Sustained Oscillations » (1981)

[6] MCCULLOCH et PITTS « A logical calculus of the ideas immanent in nervous activity » (1943)

réseau. Ce n'est que lorsqu'un nœud est actif qu'il influence les nœuds auxquels il est connecté.

Dans le cas, par exemple, des réseaux de régulation génétique, un nœud représente alors un gène et son état représente si ce dernier est exprimé. Les arcs représentent l'influence de cette expression sur celle des autres gènes. Selon si cette influence est activatrice ou inhibitrice, une représentation particulière est utilisée, présentée dans le réseau de la figure 2a. Des poids, positifs ou négatifs, peuvent également être associés aux arcs pour remplir le même rôle, comme l'illustre le réseau de la figure 2b.




Figure 2 : Exemple de représentation de la nature de l'influence d'un nœud vers un autre. Les deux réseaux possèdent les mêmes arcs, mais représentés différemment. À gauche, une influence négative est représentée par une flèche en T et une influence négative par une flèche en V. À droite, le type de l'influence est indiqué par le signe du poids lié à un arc.

L'utilisation de poids pour indiquer la nature d'une influence permet en plus de pouvoir indiquer la force de celle-ci et donc de modéliser des influences de force différentes. Dans ce manuscrit, le formalisme utilisé (présenté plus loin) est fondé sur les poids, c'est donc la représentation pondérée qui sera employée.

ÉTUDIER L'ÉVOLUTION

De nombreuses questions entourent l'évolution des systèmes biologiques. Les modifications survenant au fil du temps sont aveugles, elles peuvent aussi bien améliorer un système que le conduire à sa perte. Une stratégie qui pourrait émerger serait, pour un système, de développer sa robustesse de telle sorte que toutes les modifications pouvant survenir ne puissent plus modifier suffisamment son comportement pour le tuer. Tant que les conditions de viabilité restent les mêmes, un tel système survivrait. Mais une modification trop brutale de ces conditions le mènerait nécessairement à sa perte, puisque trop enfoncé dans son comportement, il ne serait plus capable d'évoluer à temps. À l'inverse, un système "girouette", dont le comportement change radicalement à la moindre modification, aurait certes la souplesse d'évoluer avec son environnement, mais n'aurait que peu de chance de maintenir son comportement viable. Sauf à adopter en complément une autre stratégie de survie comme se multiplier rapidement et à outrance, comme le font les bactéries ou les virus. Où se situe donc l'équilibre, le curseur entre robustesse et évolutivité? Comment est-ce que les systèmes évitent les impasses évolutives? Comment parviennent-ils à conserver cet équilibre au fil des générations? Parmi les systèmes ayant survécu jusqu'à aujourd'hui, retrouve-t-on des stratégies communes d'évolution répondant à ce problème? Autrement dit,

l'évolution sélectionne-t-elle des systèmes, non seulement capables de survivre à court terme, mais aussi à long terme et donc d'évoluer ?

Les systèmes biologiques sont donc ici modélisés par des réseaux. Afin d'étudier ces questions, nous imaginons un espace, que nous nommons le *paysage des réseaux*, qui contient tous les réseaux qu'il est possible de créer. Cet espace, tel un mille-feuille, est une superposition de couches, contenant chacune les réseaux d'une taille donnée. Ainsi, la première couche contient les réseaux fait d'un seul nœud, la suivante ceux fait de deux nœuds et ainsi de suite. Le tout forme donc une pile d'une hauteur infinie. Deux réseaux proches voisins dans ce paysage sont donc très similaires : peu de modifications sont nécessaires pour transformer l'un en l'autre.

L'idée est donc, dans un premier temps, d'explorer ce paysage et de caractériser les réseaux qui s'y trouvent. À quoi ressemblent-ils ? De quoi sont-ils capables ? Et dans un second temps, d'étudier les voies empruntées par les réseaux au fil de leur évolution. Quelles lignées survivent ? Quelles sont celles qui s'éteignent ? Il y en a-t-il qui convergent ? Ou qui restent proches sans jamais se rejoindre ?

LES RÉSEAUX BOOLÉENS À SIGNE

[7] HOPFIELD « Neural networks and physical systems with emergent collective computational abilities. » (1982)

[8] KAUFFMAN « Metabolic stability and epigenesis in randomly constructed genetic nets » (1969)

[9] BORNHOLDT « Boolean network models of cellular regulation : prospects and limitations » (2008)

[10] TRAN et al. « On the underlying assumptions of threshold Boolean networks as a model for genetic regulatory network behavior » (2013)

Le formalisme utilisé dans ce manuscrit, présenté en détails dans le chapitre 2, est celui des Réseaux Booléens à Signe (RBS). Ces derniers sont une sous-classe des Réseaux Booléens à Seuil, popularisée en 1982 par Hopfield [7].

Les réseaux booléens à seuil sont eux-mêmes une sous-classe d'un autre formalisme : les Réseaux Booléens Propositionnel, introduite par Kauffman en 1969 [8]. La caractéristique du formalisme de Kauffman est que les fonctions booléennes utilisées sont définies par une proposition logique, dont les variables sont les états des nœuds du réseau. Cela permet d'utiliser toutes les fonctions booléennes qu'il est possible de construire à partir de ce nombre de variables. L'avantage de ce fonctionnement est qu'il offre une grande expressivité [9] [10], permettant aisément de retranscrire des observations biologiques. Cependant, il complique l'analyse de ces réseaux, puisque toutes les fonctions booléennes propositionnelles ne sont pas nécessairement de même nature. Toutes les propositions logiques ne cachent pas la même complexité interne, de la même manière que deux boutons sur un appareil électrique peuvent déclencher des opérations d'une complexité extrêmement différente : l'un fermera un circuit, allumant simplement une LED, tandis que l'autre lancera un programme de plusieurs heures d'un lave-linge, incluant plusieurs périodes à différentes vitesses de rotation du tambour et différentes températures de l'eau.

Le formalisme des réseaux booléens à seuil ne présente pas cet inconvénient puisque les fonctions utilisées sont toutes définies selon la même règle. Elles sont toutes des machines binaires au fonctionnement similaire, qui ne diffèrent que par leur paramétrage. Celui-ci provient des poids que les réseaux booléens à seuil présentent sur chaque arc, ainsi que d'une valeur seuil, appelée θ , que porte chaque nœud. C'est là l'origine du nom de ces réseaux et ces fonctions sont donc appelées des *fonctions booléennes à seuil*. Leur comportement est dicté par la règle commune à toute, paramétrée par les valeurs des poids des arcs entrants et par la valeur du seuil de leur nœud. Ainsi, toutes les fonctions booléennes à seuil sont de même nature. Cela se fait toutefois au prix d'une expressivité réduite en comparaison

des réseaux booléens propositionnel, puisqu'une fonction booléenne à seuil n'est pas capable d'exprimer tous les comportements que peut produire une fonction booléenne propositionnelle.

Toutefois, les réseaux booléens à seuil présentent également un problème : l'hétérogénéité des paramètres. En effet, comme expliqué dans [1] (section 2.2.5), la valeur de seuil des nœuds est d'une nature différente de celle des poids et complique l'analyse des fonctions.

Pour cette raison, nous utilisons ici les Réseaux Booléens à Signe (RBS). Ceux-ci réduisent encore l'expressivité (les fonctions booléennes à signe ne peuvent pas produire tous les comportements des fonctions booléennes à seuils), mais gagnent en homogénéité des paramètres. Leur fonctionnement est similaire aux réseaux booléens à seuil, à la différence que le seuil de toutes les fonctions est toujours le même : 0. De cette manière, le paramétrage des fonctions ne dépend plus que des poids, tous de même nature.

La perte d'expressivité des RBS n'est pas si importante, puisqu'en réalité, toute fonction booléenne à seuil peut être exprimée avec des fonctions booléennes à signe. Si le seuil est nul, alors une unique fonction booléenne à signe suffit. Sinon, la fonction booléenne à seuil peut être simulée via l'assemblage de deux fonctions booléennes à signe, comme illustré dans la figure 3. L'une simule les poids de la fonction d'origine et l'autre simule l'effet du seuil en influençant la première via un arc portant un poids de valeur $-\theta$. Pour cela, cette dernière doit être *auto-activatrice*, c'est-à-dire qu'elle se maintient activée d'elle-même une fois active, elle doit donc être activée à l'initialisation. Ainsi, tout réseau booléen à seuil composé de d éléments peut être simulé par un réseau booléen à signe composé de $d + 1$ éléments et dont le nœud simulant l'effet des seuils porte une fonction auto-activatrice et est initialisé actif.

[1] CHRISTEN et al. « On Computing Structural and Behavioral Complexities of Threshold Boolean Networks » (2019)




Figure 3 : Simulation d'une fonction booléenne à seuil, à gauche, par l'assemblage, à droite, de deux fonctions booléennes à signe. La fonction du nœud A simule l'effet du seuil et la fonction du nœud B simule l'effet des poids. Le nœud A doit être activé à l'initialisation puis se maintient lui-même activé.

Cette construction, en plus de montrer que les RBS ne perdent pas tant en expressivité, illustre bien que le seuil est d'une nature différente des poids et est bien plus complexe. Sa simulation demande une fonction à lui seul, un élément complet de structure. De plus, cette fonction se doit d'être initialisée d'une manière particulière, ce qui indique que le seuil intègre et dissimule également de la dynamique.

MODÉLISER UN SYSTÈME BIOLOGIQUE

La modélisation par un réseau d'un système biologique en particulier, s'effectue, la plupart du temps, via un cycle d'essais-erreurs. À partir des observations du système, des paramètres sont choisis, un réseau candidat est construit puis simulé. Des ajustements des paramètres sont effectués, jusqu'à tant que la dynamique du réseau corresponde à celle observée du système.

Un premier inconvénient survient lorsque les observations sont incomplètes et qu'il n'y a aucune information sur la forme de certaines parties du réseau. Le contenu de ces zones de flou ne peut alors être décidé que selon les intuitions du modélisateur, qui, aussi réfléchies soient-elles, peuvent apporter des biais importants et ignorer des pans complets de solutions. Le second inconvénient de cette approche est qu'elle ne produit qu'un seul réseau valide, alors que d'autres réseaux tout aussi valides peuvent exister. Et il est possible, si ce n'est probable, que ces autres réseaux suivent des stratégies complètement différentes de celles intuitées par le modélisateur.

[11] MENDOZA et ALVAREZ-BUYLLA « Dynamics of the Genetic Regulatory Network for *Arabidopsis thaliana* Flower Morphogenesis » (1998)

[12] GLADE et al. « Determination, Optimization and Taxonomy of Regulatory Networks : The Example of *Arabidopsis thaliana* Flower Morphogenesis » (2011)

[13] AMOR et al. « Formal Methods for Hopfield-Like Networks » (2013)

Un exemple de cette situation est le cas du réseau de régulation génétique de la morphogenèse florale d'*Arabidopsis thaliana*. Un réseau booléen à seuil spécifique qui le modélise est proposé par Mendoza en 1998 [11], à partir d'un ensemble d'observations biologiques et d'une exploration par un algorithme génétique. De précédents travaux de mon équipe [12] ont montré en 2011 qu'il existe en réalité 532 réseaux booléens à seuil différents qui respectent les observations biologiques utilisées par Mendoza. Pour obtenir ce résultat, la méthode utilisée, décrite en détail dans [13], est la suivante. Les informations sur la structure et la dynamique tirées des observations sont traduites sous la forme de contraintes formelles et sont ensuite soumises à un solveur logique pour inférer l'ensemble des réseaux-solutions. Attention toutefois à ce que des contraintes ne soient pas oubliées, pour éviter que des réseaux aberrants ne soient inférés. Par exemple, des contraintes tellement évidentes pour un biologiste qu'il ne pense pas à les spécifier ou des contraintes reproduisant l'environnement du système étudié. Une revue manuelle des réseaux inférés est donc nécessaire pour s'assurer que les solutions trouvées font sens, le solveur ne se souciant que des contraintes fournies.

APPROCHE ET OBJECTIFS

Les travaux présentés dans ce manuscrit ont pour intention d'apporter un éclairage sur la manière dont fonctionnent les systèmes biologiques dans leur globalité. Ils héritent de l'approche exhaustive introduite dans la section précédente : nous n'étudions que les ensembles complets de réseaux d'une certaine taille, une ou plusieurs couches du paysage des réseaux, afin de prendre en compte toute leur diversité.

Cette thèse donne suite au travail réalisé au sein de l'équipe en 2018 sur les réseaux booléens à seuil [1], mené par Urvan Christen et moi-même, tout-deux alors en stage de M1. Venant de l'école polytechnique (l'X) pour sa part, et du master informatique de Grenoble pour la mienne. Je tiens ici à souligner l'ampleur et la qualité du travail d'Urvan, réalisé durant un stage de courte durée : seulement 3 mois. Dans ces travaux, nous étudions déjà les réseaux globalement, dans le but d'établir une taxonomie des réseaux. Cela a mené à la mise au point de

[1] CHRISTEN et al. « On Computing Structural and Behavioral Complexities of Threshold Boolean Networks » (2019)

différentes mesures. Certaines permettent de qualifier les différents aspects d'un réseau, organisé en deux catégories : la complexité de la structure et la complexité de la dynamique. D'autres, des distances, permettant de comparer des réseaux, d'évaluer leur ressemblance.

Les travaux de cette thèse reprennent et poursuivent donc ces travaux. Ils n'utilisent cependant pas les réseaux booléens à seuil, mais les Réseaux Booléens à Signe (RBS), ceux-ci sont présentés en détail dans la partie I. C'est un formalisme dont la simplicité permet d'envisager, computationnellement, de réaliser nos analyses à grande échelle et de les appliquer à de larges ensembles de réseaux. Ainsi, les ensembles étudiés dans ce manuscrit sont tels qu'ils contiennent tous les réseaux uniques qui existent pour un nombre d'éléments donnés. L'objectif est que toutes les dynamiques possibles, toutes les stratégies structurelles soient représentées, mais une seule fois. Cela permet d'identifier, sans biais de représentativité, d'éventuelles caractéristiques communes à différentes catégories de réseaux.

L'obtention de tels ensembles de réseaux est un défi méthodologique et technique important. La partie II de ce manuscrit y est entièrement dédié. Les réseaux recherchés ne modélisant pas un système spécifique, il n'y a pas de contraintes structurelles ou dynamiques particulières qui permettent de limiter leur nombre. La seule utilisation d'inférence logique n'est donc pas adaptée. De plus, puisque toutes les catégories de réseaux sont représentées, le volume de données à traiter est très important, il est donc nécessaire que les calculs soient parallélisés. En conséquence, les méthodes permettant l'énumération et l'analyse des réseaux, spécifiquement des RBS, ainsi que les outils logiciels attenants, ont dû être entièrement re-développées. Leur mise au point a occupée la majeure partie de ma thèse. Elles s'appuient sur de la programmation impérative "classique", pour énumérer les réseaux et les analyser, mais aussi pour orchestrer la parallélisation de ces traitements ainsi que, lorsqu'ils s'y prêtent, la résolution de certains d'entre eux par programmation logique par contraintes.

La partie III présente différents travaux qui bénéficient et s'appuient sur ces méthodes, menés par moi-même durant la thèse, mais également par les stagiaires que j'ai participé à encadrer. Nous mesurons pour tous les réseaux de ces ensembles, différents aspects de leur dynamique que nous mettons en rapport avec leur structure. **RFML: L'objectif est d'identifier quelles caractéristiques structurelles permettent d'obtenir tel ou tel type de dynamique.** Nous étudions également les aspects évolutifs de ces réseaux. Nous définissons un cadre méthodologique et proposons des outils permettant de qualifier à quel point un réseau est ou non capable d'évoluer, selon divers types de modification de sa structure. L'objectif à long terme est d'explorer la ou les manières dont les systèmes biologiques ont évolués et les conséquences de ces voies évolutives sur les caractéristiques qu'ils présentent de nos jours.

Il est cependant important de ne pas perdre de vue qu'il n'existe pas de réseaux dans la réalité. Bien que représentant de manière suffisamment fidèle la structure et le comportement des systèmes réels, les RBS (comme tous les autres réseaux formels) ne sont que des modèles. Il en va de même pour les mesures que nous utilisons (ex : les mesures de complexité, les distances entre réseaux, *etc*), elles sont nécessairement biaisées, par l'état de notre compréhension lors de leur conception, ainsi que par les nouveautés que nous devinons et que nous cherchons à faire apparaître par elles. Les enseignements que nous obtenons ne sont donc pas des

NOTE: rfml selon comment sera modifié le ch8

vérités universelles de la biologie, loin s'en faut, cela d'autant plus que notre approche, puisqu'elle est généraliste, ne prend en compte aucune spécificité d'un système en particulier. Le rôle de ces enseignements est de nourrir les réflexions et les discussions futures, d'améliorer notre compréhension du vivant et donc de faire progresser, à terme, ce qui est communément admis comme étant juste.

Première partie

LES RÉSEAUX BOOLÉENS À SIGNE

Les trois chapitres de cette partie introduisent et définissent les notions fondamentales utilisées par les travaux présentés dans les parties II et III.

Le chapitre 1 présente ce que sont les Fonctions Booléennes à Signe.

Le chapitre 2 explique comment elles sont employées pour construire les Réseaux Booléens à Signe, ainsi que la manière dont ceux-ci sont caractérisés.

Le chapitre 3 présente pourquoi et comment nous catégorisons les fonctions et les réseaux booléens à signe en classes d'équivalence. Il introduit également la manière dont nous interprétons le modèle des réseaux booléens à signe dans le cadre de l'étude des systèmes biologiques.

LES FONCTIONS BOOLÉENNES À SIGNE (FBS)

Les Fonctions Booléennes à Signe (FBS) forment la base des travaux présentés dans ce manuscrit. Elles sont présentées formellement dans ce chapitre, il est important de bien le comprendre pour la suite.

Ce chapitre commence par introduire les fonctions booléennes d'une manière générale, puis précise les particularités des fonctions booléennes à signe, qui sont une sous-famille des fonctions booléennes. Enfin, les notations qui seront utilisées par la suite sont présentées.

1.1 LES FONCTIONS BOOLÉENNES

Une Fonction Booléenne (FB) est une fonction qui, à partir d'un certain nombre de variables booléennes en entrée, produit une valeur booléenne, *vrai* ou *faux*, également notée 0 ou 1. Le nombre de variables en entrée de la fonction est appelé la dimension de la fonction et est notée d . Par exemple une fonction de dimension 2 acceptera 2 variables en entrée.

$$f : \{0, 1\}^d \rightarrow \{0, 1\} \quad (1)$$

Les différentes valeurs que peuvent avoir les variables d'entrées sont appelées des configurations. Puisque chaque variable peut prendre deux valeurs différentes, il y a toujours 2^d configurations. Par exemple en dimension 2, les configurations possible sont listées dans le tableau 1 ci-dessous.

x_0	x_1
0	0
0	1
1	0
1	1

Tableau 1 : Les différentes configurations de valeurs possibles en dimension 2 pour les variables d'entrée, notées x_0 et x_1 .

Le comportement d'une fonction booléenne est défini par une formule logique ayant pour variable les entrées de la fonction. Les fonctions booléennes sont généralistes, elles peuvent exprimer tous les comportements qu'il est possible de décrire avec une formule logique sur ses variables en entrées.

Le comportement d'une fonction booléenne est généralement résumé dans une table de vérité, ces dernières sont présentées plus en détail dans la section 1.3.2.

1.2 DÉFINITION DES FONCTIONS BOOLÉENNES À SIGNE

Les Fonctions Booléennes à Signe (FBS) forment un sous-ensemble des fonctions booléennes . À la différence de ces dernières, leur comportement n'est pas défini par une formule logique sur leurs entrées. Au lieu de ça, un poids p_i est associé à chaque entrée x_i , une valeur entière positive, négative ou nulle. Le comportement d'une FBS est alors défini selon la règle suivante, commune à toutes les FBS :

$$\text{FBS : } f(x_0, \dots, x_{d-1}) = \begin{cases} 1, & \text{si } \left(\sum_{i=0}^{d-1} p_i x_i \right) > 0 \\ 0, & \text{sinon} \end{cases} \quad (2)$$

La sortie de la fonction est vraie si et seulement si la somme des poids associés aux entrées actives (*i.e.* dont la variable booléenne associée vaut vrai) est strictement supérieure à zéro.

C'est la raison du nom des fonctions booléennes "à signe" : leur comportement est entièrement défini par les signes des différentes sommes des poids.

Contrairement aux fonctions booléennes , il n'est pas possible avec des fonctions booléennes à signe d'obtenir tous les comportements possibles exprimables à partir des entrées d'une fonction. Ainsi il n'est pas possible d'encoder un XOR, un NOT, un AND, un NAND. En revanche il sera toujours possible d'obtenir un OR sur toutes ou parties des entrées ou un falsum*.

* : Falsum désigne ici une fonction booléenne qui renvoie toujours faux quelque soit les valeurs des variables en entrée.

1.3 NOTATIONS

1.3.1 Vecteur d'entiers

Plusieurs éléments de nature différentes dans le texte qui va suivre sont notés comme des vecteurs d'entiers, sous la forme suivante : $\langle 0, 1, 2, 3 \rangle$. Afin de réduire le risque de confusion, ces vecteurs seront systématiquement indicés d'un acronyme rappelant leur nature. Ceux nécessaires dans la suite de ce chapitre sont listés dans le tableau 2, d'autres seront introduits au fil du texte.

Nature	Acronyme	Exemple
Poids d'une FBS	P	$\langle 1, -2 \rangle_P$
Sortie d'une table de vérité	Tv	$\langle 0, 1, 0, 1 \rangle_{Tv}$
Configuration d'une table de vérité	Cfg	$\langle 0, 1, 1 \rangle_{Cfg}$

Tableau 2 : Acronymes utilisés pour indiquer la nature des vecteurs d'entiers.

1.3.2 Table de vérité

Comme pour toutes les fonctions booléennes, les fonctions booléennes à signe peuvent être représentées par une table de vérité (TV). Une table de vérité est un tableau qui liste toutes les configurations de valeurs pour les variables d'entrées

d'une fonction et y associe la valeur produite en retour par cette dernière. Comme l'illustre la table de vérité de la figure 4, à chaque configuration est associée la valeur de sortie produite par l'application de la fonction à cette configuration.

Entrées	x_1	x_0	
Poids	-1	2	Sortie
Configurations	0	0	0
	0	1	1
	1	0	0
	1	1	1

Figure 4 : Table de vérité représentant une FBS de dimension 2, définie par les poids $\langle 2, -1 \rangle_P$ et ayant le comportement $\langle 0, 1, 0, 1 \rangle_{T_V}$. Ce dernier est obtenu par l'application de la fonction aux 4 configurations $\langle 0, 0 \rangle_{C_{fg}}$, $\langle 0, 1 \rangle_{C_{fg}}$, $\langle 1, 0 \rangle_{C_{fg}}$ et $\langle 1, 1 \rangle_{C_{fg}}$.

Dans le cadre des fonctions booléennes à signe, les poids associés aux entrées sont également rappelés en haut de la table de vérité.

Tout au long de ce manuscrit, dans les tables de vérité, l'ordre des configurations présenté dans la figure 4 sera utilisé. Cet ordre a pour avantage que l'indice d'une configuration dans la table de vérité correspond à la valeur décimale encodée par la suite binaire que forme la configuration. C'est la raison pour laquelle les entrées sont notées de droite à gauche et indicées de 0 à $d - 1$ et que sur la figure 4, x_0 apparaît à droite de x_1 : pour correspondre à l'ordre de lecture d'un nombre binaire ainsi qu'à sa valeur décimale.

Ainsi, en connaissant la dimension courante, l'indice d'une configuration est la configuration !

Exemple : En dimension 3, la configuration d'indice 6 sera toujours $\langle 1, 1, 0 \rangle_{C_{fg}}$, indiquant que seules les entrées 1 et 2 sont actives, puisque $6 = 2^1 + 2^2$.

LES RÉSEAUX BOOLÉENS À SIGNE (RBS)

Les Réseaux Booléens à Signe nous servent à modéliser les systèmes biologiques, par leur structure, leur dynamique ou les deux.

Ce chapitre les définit puis introduit le vocabulaire et les représentations utilisés pour désigner, caractériser et illustrer leur structure et leur dynamique.

2.1 DÉFINITION

Un réseau booléen est un ensemble de variables booléennes, dont chacune est associée à une fonction booléenne qui en définit la valeur selon l'état de toutes les variables booléennes du réseau.

Formellement, un réseau booléen est défini comme un couple (V, F) , où V est un ensemble de variables booléennes et F un ensemble de fonctions booléennes. Pour chaque variable x dans V , il existe dans F une fonction booléenne f_x associée qui définit la valeur de x au temps t à partir des valeurs des variables de V au pas de temps précédent $t - 1$. Tel que résumé dans la définition suivante :

Definition 1 Soit (V, F) un couple. V un ensemble de variables booléennes. F un ensemble de fonctions booléennes :

$$\forall x \in V, \exists f_x \in F, \text{ tel que } x_t = f_x(V_{t-1})$$

La nature des fonctions booléennes de F définit le type du réseau booléen. Un Réseau Booléen à Signe (RBS) est donc un réseau booléen où toutes les fonctions booléennes sont des fonctions booléennes à signe.

2.1.1 Dimension d'un RBS

Pour les RBS, le terme "dimension" ne désigne pas directement la même propriété que pour les FBS. La dimension d'un RBS désigne le nombre de nœuds qui le compose et donc la dimension des FBS associées à ces nœuds. Ainsi, chaque FBS du réseau lit l'état de l'ensemble des nœuds du réseau. Un RBS ne peut pas être composé de FBS de dimensions différentes de celle du réseau ; plus de détails sont présentés à ce sujet en 3.3.

2.2 REPRÉSENTATION DES RBS

Un RBS est représenté sous la forme d'un graphe orienté dont chaque nœud est une variable booléenne. Les arcs du graphe véhiculent l'état de leur nœud d'origine vers leur nœud de destination. Les arcs entrants d'un nœud correspondent aux entrées de la fonction, ils décrivent la FBS associée à la variable puisqu'ils sont pondérés par le poids lié à l'entrée qu'ils représentent. Le nœud d'origine de l'arc désigne alors la variable booléenne lue par la fonction pour cette entrée.

Remarque : Puisqu'un nœud est une variable booléenne, mentionner l'état d'un nœud équivaut à parler de l'état de la variable booléenne.

La figure 5c présente un RBS de dimension 2 sous forme de graphe.




Figure 5 : Un RBS (c) composé des deux FBS A et B dont les tables de vérité sont présentées en (a) et (b).

2.3 DYNAMIQUE DES RBS

2.3.1 Définition

L'état d'un réseau est défini comme étant l'ensemble des états booléens de ses nœuds. En conséquence, un réseau ne peut se trouver que dans un nombre limité d'états : 2^d , puisque chaque nœud peut être dans deux états et qu'un RBS est composé de d nœuds.

À chaque pas de simulation, les FBS lisent l'état du réseau au pas de temps précédent via leurs arcs entrants et enregistrent leurs sorties dans leurs variables liées.

2.3.1.1 Mode de mise à jour

Il est classique en travaillant avec les réseaux booléens de considérer un mode de mise à jour. Ce dernier indique dans quel ordre les différents nœuds ou groupe de nœuds mettent à jour leur état. Par exemple, dans un réseau de dimension 2, le nœud A pourrait être mis à jour en premier, puis le nœud B qui en conséquence lirait le nouvel état du nœud A au temps t et non son état au pas de temps précédent $t - 1$.

L'utilisation de ces modes de mise à jour introduit une couche de complexité supplémentaire, puisqu'un même réseau, simulé avec des modes de mise à jour différents présente des dynamiques différentes.

Cette complexité rend plus ardue l'analyse de la complexité intrinsèque des réseaux eux-mêmes, ce qui est un des objectifs des travaux présentés ici. Le mode de mise à jour considéré dans ce manuscrit est donc toujours le mode *synchrone* : tous les nœuds sont mis à jour "en même temps", selon l'état du réseau au pas de temps précédent.

De plus, les autres modes de mise à jour, dit *asynchrones*, peuvent être simulés dans le mode synchrone avec un réseau comportant davantage de nœuds ([14] pages 167 et 189). Les nœuds supplémentaires permettent d'ajouter autant de délais que nécessaire entre les autres nœuds pour obtenir la même dynamique que le réseau initial avec le mode de mise à jour asynchrone.

[14] GLADE « Le Vivant Rare, Faible et Amorphe. Evolution depuis les Origines jusqu'à la Vie telle qu'elle nous Apparaît » (2022)

2.3.2 Graphe de transition (GT)

L'ensemble des transitions d'état, c'est-à-dire les passages d'un état du réseau à un autre, peut être synthétisé dans ce qui est appelé un Graphe de Transition (GT) d'un réseau. Dans un tel graphe, chaque sommet représente un des différents états possibles du réseau sous la forme d'un vecteur de 0 et de 1, indicé de la lettre E pour *État*. Pour conserver la cohérence avec les tables de vérité, les états des sommets sont triés dans l'ordre alphabétique inverse : $\langle B, A \rangle_E$. Par exemple, $\langle 0, 1 \rangle_E$ indique que le nœud A est dans l'état vrai et le nœud B dans l'état faux. De cette façon, les états sont cohérent avec les configurations des tables de vérité et pour connaître la dynamique d'une fonction lorsque qu'un réseau est dans un état $\langle x, y \rangle_E$ il faut lire la sortie de la table de vérité correspondante à la configuration $\langle x, y \rangle_{Cfg}$.

Les arcs représentent les transitions d'état lors de la simulation d'un pas de temps. La figure 6 présente un exemple de graphe de transition.




Figure 6 : Graphe de transition du réseau de la figure 5-c. Le réseau présente deux comportements asymptotiques : un point fixe sur l'état $\langle 0, 0 \rangle_E$ et un cycle sur les deux états $\langle 0, 1 \rangle_E$ et $\langle 1, 1 \rangle_E$. Il faut voir ce graphe comme un hypercube de dimension d où chaque dimension représente l'état d'un nœud du réseau. Les lignes grises pointillées servent seulement à montrer la représentation de l'hypercube 2D formé par les états. Les états $\langle 0, 0 \rangle_E$ et $\langle 1, 1 \rangle_E$ sont donc distants de deux arêtes sur ce cube, puisqu'il faut modifier l'état de deux nœuds pour passer de l'un à l'autre.

Les FBS étant déterministes les RBS le sont également ; il y a donc toujours une et une seule transition partant d'un état. L'état atteint via cette unique transition sortante est appelé l'état *successeur*.

Dans le cadre des RBS, un état ne peut donc avoir qu'un seul état successeur. Cependant, plusieurs états peuvent partager le même état successeur. Enfin rien n'empêche un état d'être son propre successeur.

2.3.3 Analyse

2.3.3.1 Attracteur

* : Dans des conditions de simulation sans erreurs.

Les éléments de base de l'étude de la dynamique d'un réseau sont les cycles d'états : un ensemble d'états qui forment une boucle. Une fois l'un de ces états atteint, le réseau passera successivement et indéfiniment* par chaque état du cycle. Le nombre d'états différents pour un réseau étant au maximum de 2^d , un réseau ne peut donc pas présenter de cycle de taille supérieure à cette limite.

Ces cycles sont appelés des *attracteurs*, puisque l'état d'un réseau finira invariablement par être "attiré" dans l'un d'eux.

Les attracteurs composés d'un unique état sont appelées des *points fixes*.

2.3.3.2 Bassin d'attraction

Tous les états font soit partis d'un attracteur, soit d'une trajectoire qui mène à un attracteur. Les états qui mènent à un attracteur et ceux qui composent cet attracteur forment un ensemble appelé *bassin d'attraction*. La taille d'un bassin d'attraction désigne le nombre d'états qu'il contient. La figure 7 présente un graphe de transition dont les zones de couleurs font la distinction entre les attracteurs et les bassins d'attraction.




Figure 7 : Graphe de transition du RBS de la figure 5-c. Les états et arcs en rouges représentent les attracteurs et les zones jaunes les bassins d'attractions. L'attracteur faisant partie du bassin d'attraction, l'état $\langle 0, 0 \rangle_E$ est à la fois dans un attracteur ET dans le bassin d'attraction lié. Il est en de même pour l'attracteur composé des états $\langle 0, 1 \rangle_E$ et $\langle 1, 1 \rangle_E$.

2.3.3.3 Comportement

Le terme *comportement* désigne la suite d'état par lequel passe un nœud en particulier au fil d'un cycle complet d'un attracteur. Ce comportement est représenté par une suite binaire, à laquelle une astérisque est ajoutée pour souligner que le comportement se répète.

Exemple : 10011 notée 10011*.

Chaque bit de cette suite indique l'état du nœud à un pas de temps donné du cycle. La taille d'un comportement correspond au nombre de bits dans la suite binaire, qui est équivalent au nombre d'états différents qui compose l'attracteur lié.

Le comportement est également désigné par la suite comme étant la *musique* d'un nœud, comme si les bit étaient des notes de musique jouées par le nœud.

2.3.3.4 Point fixe commun

Une des particularités des FBS est de systématiquement produire *faux* si aucune des entrées n'est active, puisque alors la somme des poids entrants actifs est toujours de 0 et qu'elle doit être strictement supérieure à 0 pour que la fonction produise *vrai*. La conséquence pour les RBS est qu'ils possèdent toujours un point fixe sur l'état $\langle 0, \dots, 0 \rangle_E$.

CLASSES D'ÉQUIVALENCES (CE)

L'ensemble des nombres entiers est infini. Il existe donc une infinité de vecteurs de poids différents. Puisqu'ils suffisent pour décrire complètement une FBS, il existe ainsi une quantité illimitée de ces dernières et donc de RBS également. Cela pose un problème au regard de notre objectif, qui consiste entre autres à analyser exhaustivement les FBS et les RBS. Cependant, il est possible de regrouper les FBS et les RBS en un nombre fini de catégories, les Classes d'Équivalences (CE).

3.1 CLASSE D'ÉQUIVALENCE DES FBS

3.1.1 Définition

Une classe d'équivalence de FBS regroupe toutes celles qui partagent une même table de vérité.

En effet, malgré une infinité de vecteurs de poids possible, nombre d'entre eux produisent des sommes de même signe pour les mêmes configurations. La figure 8 présente un exemple d'un tel cas.

Entrées	x_1	x_0		x_1	x_0	
Poids	-1	2	Sortie	-2	5	Sortie
Configurations	0	0	0	0	0	0
	0	1	1	0	1	1
	1	0	0	1	0	0
	1	1	1	1	1	1

Figure 8 : Deux FBS définies par des vecteurs de poids différents, mais possédant la même table de vérité. Les deux FBS sont donc équivalentes ; elles font partie de la même classe d'équivalence.

3.1.2 Équivalence par permutations

En considérant un jeu de poids qui définit une FBS, si certains de ces poids sont intervertis, le jeu de poids ainsi obtenu est différent du premier et définit une autre FBS. Cette dernière, comme il est possible de le constater dans la figure 9, possède une table de vérité différente.

Entrées	x ₁	x ₀		x ₁	x ₀	
Poids	-1	2	Sortie	2	-1	Sortie
Configurations	0	0	0	0	0	0
	0	1	1	0	1	0
	1	0	0	1	0	1
	1	1	1	1	1	1

Figure 9 : Deux FBS définies par les mêmes poids ordonnés différemment, elles possèdent donc des tables de vérité différentes.

Cependant, les valeurs des poids ne sont pas modifiées, donc les signes des diverses sommes de poids restent inchangés. Ainsi, même si les deux FBS produites ne sont pas identiques, elles sont **équivalentes**.

Objectivement, il n'existe pas un ordre des entrées des FBS, c'est nous, humains, qui avons besoin de dire que telle entrée est la première et telle autre la suivante, *etc* . Si je considère une FBS, rien ne m'empêche de changer à tout moment l'ordre dans lequel je considère les entrées, aucun ordre n'est plus juste ou plus vrai qu'un autre. Finalement, tant que les valeurs des poids ne changent pas, le comportement de fond de la FBS reste le même.

De ce fait, des FBS composées des mêmes poids sont considérées comme équivalentes, quelle que soit la manière dont ces poids sont affectés aux entrées. Ces fonctions sont appelées des *permutations* les unes des autres en références aux permutations de leurs poids. Elles partagent la même table de vérité à permutation près et appartiennent donc à la même classe d'équivalence.

3.1.2.1 Nombre de permutations selon la dimension

Une permutation est l'échange des positions de deux poids ou plus. Plus le nombre de poids dans le vecteur est grand, donc plus la dimension courante est élevée, plus il existe des permutations possibles. Il est possible de calculer le nombre de permutations selon d . Formellement cela correspond au nombre de tirages sans remises et avec ordre de r éléments parmi n . La formule permettant de calculer le nombre de tirages de cette forme est présenté dans l'équation 3. Dans le cas des permutations de poids, cela revient à tirer tous les éléments, donc $r = n = d$ et la formule se simplifie en $d!$. Il y a donc 6 permutations possibles en dimension 3, 24 en dimension 4, *etc* .

$$\frac{n!}{(n-r)!} \rightarrow \frac{d!}{(d-d)!} \rightarrow d! \quad (3)$$

3.1.2.2 Notations des permutations

Une permutation est représentée par un vecteur d'entier contenant les indices i de chacun des poids p du vecteur de poids. De même que pour les autres vecteurs d'entiers, les vecteurs de permutation sont indicés de l'acronyme Prm afin de rappeler leur nature.

Un vecteur de permutation contient donc tous les entiers de 0 à $d - 1$. Illustré par la figure 10, l'indice j d'un indice de poids i dans le vecteur de permutation indique la nouvelle position du poids p_i une fois la permutation appliquée : il devient le poids p_j . La figure 11 présente d'autres exemples de permutations.

$$\langle 1_0, 0_1, 2_2 \rangle_{Prm} \Rightarrow p_0 \rightarrow p_1$$

Figure 10 : Présentation visuelle de l'application d'un vecteur de permutation sur un vecteur de poids. Une fois la permutation $\langle 1, 0, 2 \rangle_{Prm}$ appliquée, le poids p_0 devient p_1 puisque l'indice de valeur 0 se trouve à l'indice 1 dans le vecteur de permutation.

Indices	Poids	Permutation	Poids permutés
0	2	→ 0	2
1	4	→ 1	4
2	6	→ 2	6

Indices	Poids	Permutation	Poids permutés
0	2	↘ 2	6
1	4	↘ 0	2
2	6	↘ 1	4

Figure 11 : Exemple de permutation des poids en dimension 3. La permutation nulle $\langle 0, 1, 2 \rangle_{Prm}$ ne modifie pas le vecteur de poids, tandis que la permutation $\langle 2, 0, 1 \rangle_{Prm}$ transforme le vecteur de poids en $\langle 6, 2, 4 \rangle_P$.

3.1.3 Visualiser les classes d'équivalences

Il est possible, jusqu'en dimension 3, de visualiser graphiquement les différentes classes d'équivalence dans l'espace des poids. Prenons l'exemple de la dimension 2, présentée dans la figure 12.




Figure 12 : Espace des poids en dimension 2 dans la boule unité. Les différentes zones délimitées représentent les différentes classes d'équivalence de FBS. Les zones de même couleur sont équivalentes par permutation, comme le met en avant la ligne blanche. Pour chaque classe, la sortie de la table de vérité correspondante est rappelée. Les rayures blanches indiquent à quelle classe appartient l'axe lié, par exemple un point sur l'origine appartient à la classe $\langle 0, 0, 0, 0 \rangle_{Tv}$.

L'espace est divisé par plusieurs droites, dont les équations correspondent aux configurations d'une table de vérité de dimension 2. Deux droites se situent sur les axes, lorsque l'un des deux poids vaut zéro. Une troisième se trouve en diagonale, là où la somme des deux poids vaut zéro. Selon qu'un point se situe d'un côté ou de l'autre de ces droites, la FBS qu'il définit fera partie de telle ou telle classe d'équivalence.

Les droites elles-mêmes sont comprises dans les classes d'équivalence, puisque ces dernières sont définies par des inéquations sur les poids et non par les équations des droites directement. Cela vient de la définition des FBS qui indique qu'une somme des poids doit être strictement positive pour activer une FBS, donc qu'une somme nulle a le même effet qu'une somme négative.

Ces trois droites passent toutes par l'origine et définissent donc six cônes. Cependant, tous ces cônes ne sont pas des classes d'équivalence indépendantes ; il faut encore prendre en compte l'équivalence par permutation. En dimension 2 il n'existe qu'une permutation possible, en inversant les deux poids. Il est possible

représenter la délimitation entre ces deux permutations par une droite, telle qu'en chaque point les deux poids sont égaux, comme présenté dans la figure 12. Cela permet de regrouper les classes équivalentes par permutations et de constater qu'il n'existe bien que quatre classes d'équivalence différentes en dimension 2.

En dimension 3, présentée dans la figure 13, il existe trois plans de permutation : $x \leftrightarrow y$, $x \leftrightarrow z$ et $y \leftrightarrow z$. Ils définissent six zones équivalentes par permutations, chacune contenant une permutation de chacune des dix classes d'équivalence de dimension 3.




Figure 13 : Espace des poids en dimension 3 dans la boule unité. Les trois images montrent la même boule sous différents angles.

Les lignes de couleurs sont les intersections entre la surface de la boule et les plans dont les équations sont données dans la légende. Ces lignes sont en pointillées lorsqu'elles passent derrière un des plans visibles. Les surfaces sur la boule délimitées par ces lignes définissent les différentes classes d'équivalence. Les plans qui délimitent les classes d'équivalence forment des "pyramides" dont les bases sont les surfaces sur la boule, leurs pointes sont tournées vers l'origine.

Les classes équivalentes par permutations des poids sont mises en avant par les trois plans bleus-gris qui délimitent les six permutations possibles en dimension 3. Ces derniers sont vus de face dans la première image et de côté dans la seconde. La troisième image montre une des six tranches de la boule délimitées par les plans de permutation. Chacune de ces tranches contient une permutation des dix classes d'équivalence de FBS en dimension 3.

Il est possible de manipuler cette figure en 3D à l'adresse suivante : <https://www.geogebra.org/m/kgqbkhqk> ou en scannant le QR code.

3.2 CLASSES D'ÉQUIVALENCES DES RBS

3.2.1 Définition

Une classe d'équivalence de RBS regroupe ceux composés des mêmes classes d'équivalence de FBS ET qui expriment la même dynamique, donc le même graphe de transition, tels que ceux présentés dans la figure 14.




Figure 14 : Deux RBS de la même classe d'équivalence . Ils sont composés des mêmes classes d'équivalence de FBS et ont la même dynamique.

Ces deux critères sont nécessaires puisqu'un même ensemble de classe d'équivalence de FBS peut définir des RBS exprimant des dynamiques différentes. En effet, selon la FBS *concrète* sélectionnée pour représenter une classe d'équivalence, *i. e.* la permutation choisie, cette dernière associe l'état des nœuds du réseau à différentes entrées. Cela modifie la manière dont une même classe d'équivalence de FBS se comporte à partir du même état d'un réseau. La figure 15 présente un exemple d'un tel cas.

3.2.2 Équivalence par permutations

De la même manière que deux FBS peuvent être équivalentes par permutation de leurs poids/entrées, deux RBS peuvent être équivalents par permutation de leurs nœuds, ils appartiennent alors à la même classe d'équivalence.

Comme il est possible de le voir dans la figure 16, l'échange des nœuds semble modifier le graphe de transition. En réalité seul l'étiquetage des nœuds a été modifié. Les poids sont inchangés et les permutations des FBS utilisées sont certes différentes, mais sont cohérentes avec le changement imposé aux nœuds de sorte que les mêmes poids soient liés aux mêmes nœuds.




Figure 15 : Deux RBS composés des mêmes classes d'équivalence de FBS mais n'ayant pas la même dynamique. Dans le RBS de droite, la FBS du nœud A est permutée par rapport à son homologue dans le RBS de gauche. Il en résulte une dynamique différente, comme l'attestent les graphes de transition.




Figure 16 : Deux RBS composés des mêmes classes d'équivalence de FBS. Les dynamiques semblent différentes, cependant elles sont équivalentes par permutation des deux nœuds du réseau.

3.3 CHOIX DE MODÉLISATION : POIDS NULS

Tel que présenté dans le chapitre 2, un RBS de dimension d est composé de FBS de dimension d . En conséquence, tous les systèmes ainsi modélisés sont des systèmes où chaque élément interagit avec tous les autres. Cela ne correspond pas à la réalité du vivant : tous les éléments d'un système biologique n'entre pas nécessairement en relation.

Classiquement, les poids de valeur nulle sont considérés comme représentant des interactions sans effets, mais pour autant présentes. Cela apporte un inconvénient : il n'est pas possible de faire la différence avec le cas où deux éléments n'interagissent pas du tout. Hors, du point de vue de l'évolution, il est important de pouvoir faire cette distinction. Dans le premier cas, l'interaction sans effets forme un potentiel évolutif : il est possible au cours de l'évolution que cette dernière prenne de l'ampleur et finissent par contribuer à la dynamique du système. Tandis que dans le second cas, il n'existe aucune forme d'interaction, même s'il n'est pas impossible que les éléments concernés finissent par en développer une un jour. Afin donc de pouvoir faire la distinction entre ces deux cas, une interaction ineffective et une absence d'interaction, nous avons fait le choix de considérer que les poids nuls modélisent l'absence des arcs qui les portent.

Cette manière de faire n'empêche pas de représenter une interaction ineffective, il faut pour cela de lui donner un poids suffisamment faible en comparaison des poids donnés aux interactions effectives.

3.3.1 Impacts sur les classes d'équivalence de FBS

Le choix qu'un poids nul représente l'absence d'un arc correspond pour les FBS à l'absence de l'une des entrées. Les FBS contenant des poids nuls sont donc en réalité des FBS de dimension inférieure, projetées dans la dimension courante, comme l'illustre la figure 17.

Entrées	x_1	x_0		x_2	x_1	x_0	
Poids	2	-1	Sortie	2	0	-1	Sortie
Configurations	0	0	0	0	0	0	0
	0	1	0	0	0	1	0
	1	0	1	0	1	0	0
	1	1	1	0	1	1	0
				1	0	0	1
				1	0	1	1
				1	1	0	1
				1	1	1	1

Figure 17 : Table de vérité d'une FBS de dimension 2 et sa projection en dimension 3. Puisque le poids ajouté est nul, la sortie de la table de vérité reste la même que l'entrée liée à ce poids soit à 1 ou à 0. Afin de mettre en avant que la FBS reste la même après la projection, le poids nul ajouté est grisé, de même que les configurations où l'entrée liée à ce dernier est à 1.

Dans la suite de ce document, les FBS appartenant à la dimension courante, donc n'ayant aucun poids nul, seront désignée sous le terme d'*innées*. Tandis que celles des dimensions inférieures seront dites *projetées*.

Selon la définition des classes d'équivalence de FBS données dans le chapitre 3, une classe d'équivalence regroupe toutes les FBS qui partagent la même table de vérité (à permutation près). Cependant, les FBS projetées appartiennent en réalité à une dimension inférieure. En conséquence, nous considérons que même si elles partagent la même table de vérité que des FBS innées, les FBS projetées appartiennent à des classes d'équivalence différentes. *i.e.* elles ont le même comportement, mais ne sont pas issue de la même dimension.

Cette distinction peut être visualisée via un nouveau découpage de l'espace des poids selon les classes d'équivalence, tel que présenté par la figure 18.




Figure 18 : Espace des poids en dimension 2, découpé selon les classes d'équivalence de FBS. Les classes d'équivalence projetées sont hachurées.

Une conséquence de la distinction entre classe d'équivalence de FBS projetée et innée est d'augmenter le nombre de ces classes d'équivalence. Cela multiplie en conséquence le nombre de classes d'équivalence de RBS, puisqu'il existe alors davantage de compositions différentes de classes d'équivalence de FBS.

Un second effet des classes d'équivalence projetées est qu'elles n'ajoutent pas de nouvelles tables de vérité, il devient alors possible pour des classes d'équivalence de RBS de partager un même graphe de transition. Sans cela, chaque classe d'équivalence de RBS aurait un graphe de transition unique puisqu'elle regrouperait un ensemble unique de tables de vérité.

Deuxième partie

DÉVELOPPEMENTS THÉORIQUES ET MÉTHODOLOGIQUES SUR LES RBS

Les travaux conduits durant ma thèse, présentés dans la partie III, nécessitent comme base méthodologique principale de pouvoir analyser tous les différents RBS qu'il est possible d'obtenir.

Cette approche systématique permet d'embrasser toute la diversité des réseaux, là où des méthodes de constructions des réseaux par un cycle d'observations-essais-erreurs peuvent oublier des réseaux qui sont également des solutions viables [13] [12].

Obtenir l'ensemble de tous les RBS uniques pose les trois problèmes suivants :

- Comment obtenir l'ensemble de toutes les fonctions booléennes à signe uniques ?
- Comment, à partir des fonctions booléennes à signe, obtenir l'ensemble de tous les réseaux booléens à signe uniques ?
- Comment analyser l'ensemble des réseaux en un temps raisonnable et dans la limite de nos ressources de calculs ?

Ces problèmes sont compliqués ; ils mélangent trois domaines : les mathématiques, l'informatique et la logique. Les trois chapitres de cette partie présentent les développements théoriques et méthodologiques ayant constitués le cœur de ma thèse et qui se sont avérés nécessaires pour résoudre ces problèmes.

La problématique de l'énumération juste et complète des fonctions et des réseaux a déjà été abordée [15] [16] [17], mais dans le cadre des réseaux booléens à seuil. Les réseaux booléens à signe sont certes une sous-famille des réseaux booléens à seuil, mais l'absence du seuil les rends fondamentalement différents ([14] pages 160-161), nécessitant de développer nos propres méthodes.

[13] AMOR et al. « Formal Methods for Hopfield-Like Networks » (2013)

[12] GLADE et al. « Determination, Optimization and Taxonomy of Regulatory Networks : The Example of Arabidopsis thaliana Flower Morphogenesis » (2011)

[15] ELENA « Robustesse des réseaux d'automates booléens à seuil aux modes d'itération : application à la modélisation des réseaux de régulation génétique » (2009)

[16] MUROGA, TSUBOI et BAUGH « Enumeration of Threshold Functions of Eight Variables » (1970)

[17] OJHA « Enumeration of linear threshold functions from the lattice of hyperplane intersections » (2000)

[14] GLADE « Le Vivant Rare, Faible et Amorphe. Evolution depuis les Origines jusqu'à la Vie telle qu'elle nous Apparaît » (2022)

L'ÉNUMÉRATION DE TOUTES LES CLASSES DE FBS

Connaître l'ensemble des FBS d'une dimension donnée constitue une brique essentielle des travaux présentés dans ce manuscrit. C'est à partir de cet ensemble qu'il est ensuite possible d'obtenir l'ensemble complet des RBS uniques.

Précisément, l'objectif est d'obtenir un ensemble de FBS tel que chacune d'entre elles représente une classe d'équivalence différente et que toutes les classes d'équivalence de la dimension courante sont représentées.

Ce chapitre présente les deux approches développées durant ma thèse.

4.1 FBS CANONIQUE

Les FBS générées servent à énumérer des RBS qui sont ensuite analysés pour en établir les caractéristiques. Ces FBS doivent donc présenter des valeurs de poids appartenant aux mêmes ordres de grandeurs afin de ne pas falsifier les mesures qui seront effectuées ensuite sur les réseaux. Pour cette raison, les FBS retenues pour représenter chaque classe d'équivalence doivent être des FBS canoniques.

Une FBS est dite canonique si elle respecte les deux critères suivants, expliqués plus en détails dans les paragraphes suivants :

- Elle est minimale : composée de poids minimaux.
- Les poids sont triés par valeur décroissantes.

4.1.1 FBS minimale

Une FBS est dite minimale si la somme des valeurs absolues des poids qui la composent est minimale en comparaison des autres FBS de la même classe d'équivalence.

Cette définition permet de sélectionner une FBS ayant les plus petites valeurs de poids possibles. L'intention est de choisir, dans l'espace des poids, un point le plus proche possible de l'origine. Ainsi, les mesures basées sur les poids des FBS appartenant à des classes d'équivalence différentes seront comparables. Une mesure plus précise de la distance à l'origine serait d'utiliser la norme du vecteur des poids, cependant cela nécessiterait de sortir du domaine des entiers ce qui n'est pas possible pour tous les outils que nous utilisons, tel que ASP (cf. 6.4). La somme des valeurs absolues des poids permet d'approximer la norme en restant dans le domaine des entiers.

4.1.2 Poids triés

Chaque classe d'équivalence contient plusieurs FBS minimales, une par permutation. Imposer que les poids soient triés par valeurs décroissantes permet de ne sélectionner qu'une seule de ces permutations.

4.1.3 Unicité

La preuve n'est pas faite de l'unicité de la FBS canonique d'une classe d'équivalence pour toutes les dimensions. Cette propriété n'étant pas nécessaire pour nos travaux, nous nous sommes contentés de cette définition.

4.2 PREMIÈRE MÉTHODE : ÉNUMÉRATION DES POIDS

La méthode la plus triviale consiste à énumérer l'ensemble des vecteurs de poids possibles, limité à un certain intervalle de valeurs. Puis pour chacun de ces vecteurs, calculer la table de vérité correspondante et donc la classe d'équivalence à laquelle il appartient. La figure 19 illustre cette méthode.




Figure 19 : Discretisation de l'espace des poids en dimension 2. Chaque point représente un vecteur de poids entiers, leurs couleurs indiquent la classe d'équivalence dont ils font partie.

Cette méthode présente deux problèmes qui l'empêchent d'être effectivement applicable à toutes les dimensions. Le premier est l'explosion combinatoire : plus la dimension augmente, plus le nombre de vecteurs à évaluer augmente, comme le présente le tableau 3.

Dimension	Intervalle	Nombre de vecteurs
2	$[-2; 2]$	$5^2 = 25$
3	$[-3; 3]$	$7^3 = 343$
4	$[-4; 4]$	$9^4 = 6,561$
5	$[-5; 5]$	$11^5 = 161,051$

Tableau 3 : Nombre de vecteurs à énumérer et intervalle des poids minimum selon la dimension pour énumérer toutes classes d'équivalence de FBS. En dimension 2, avec l'intervalle prévu, les poids peuvent prendre 5 valeurs différentes. En dimension 3, 7 valeurs différentes *etc ...*

L'autre problème est le choix des bornes de l'intervalle. Il doit être suffisamment large afin de contenir au moins un point pour chaque classe d'équivalence de la dimension. Un intervalle trop réduit peut manquer des classes d'équivalence dont le volume est trop fin et passe au travers de la discrétisation de l'espace par des valeurs entières, tel que schématisé par la figure 20.




Figure 20 : Illustration d'une classe d'équivalence trop "fine" dans l'espace des poids. Avec cet intervalle, aucun points énumérés (en noirs) ne se trouve dans la classe d'équivalence délimitée par les droites. Les points bleus désignent les premiers points permettant d'obtenir des FBS de cette classe d'équivalence. Cette dernière n'est donc pas énumérée avec cet intervalle et l'ensemble de FBS généré est incomplet.

L'intervalle de recherche des poids initialement choisi était $[-d; d]$, avec l'intuition qu'il serait suffisant. Cependant, force a été de constater (empiriquement) qu'il devenait trop petit à partir de la dimension 5 (voir tableau 4).

Dimension	0	1	2	3	4	5	6
CE innées	1	2	4	10	36	224	3024
Intervalle minimum	$[-0; 0]$	$[-1; 1]$	$[-2; 2]$	$[-3; 3]$	$[-4; 4]$	$[-5; 5]$	$[-9; 9]$
CE cumulées	1	3	7	17	53	277	3301
Intervalle minimum	$[-0; 0]$	$[-1; 1]$	$[-2; 2]$	$[-3; 3]$	$[-4; 4]$	$[-6; 6]$	$[-10; 10]$

Tableau 4 : Nombre de classes d'équivalence innées et cumulées (innées + projetées) de FBS selon la dimension d . Tels que trouvés avec la méthode d'énumération des poids.

Si pour les faibles dimensions ($d < 5$), il est possible de vérifier manuellement que l'intervalle est suffisant pour trouver toutes les classes d'équivalence, au-delà, il est nécessaire d'augmenter graduellement l'intervalle, tant que de nouvelles classes d'équivalence sont trouvées. Cependant, cela n'offre pas la certitude que toutes les classes d'équivalence soient atteintes et donc énumérées. La seule indication soutenant que les intervalles présentés dans le tableau 4 sont suffisants, est l'égalité entre le nombre de classes d'équivalence cumulées en d et le nombre de classes

d'équivalence innées en d additionné du nombre de classes d'équivalence cumulées en $d - 1$. Par exemple en dimension 5 : $277 = 224 + 53$.

Il n'a pas été possible de déterminer une formule permettant de connaître pour une dimension donnée l'intervalle minimum requis, de même que pour connaître le nombre de classes d'équivalence de FBS et donc de RBS.

4.3 SECONDE MÉTHODE : ÉNUMÉRATION DES CONTRAINTES SUR LES POIDS

Le principe de cette méthode est d'abord introduit géométriquement, avant d'être formellement définie, via la visualisation des différents hyperplans définis par les configurations d'une table de vérité au sein de l'espace des poids. Tel que le montre la figure 21 pour la dimension 2, où les lignes noires pointillées correspondent aux hyperplans.




Figure 21 : Espace des poids divisé par les plans issus des configurations. $d = 2$

L'idée au cœur de cette méthode est d'exploiter le fait même sans connaître les différentes classes d'équivalence, les configurations, elles, sont connues et donc les hyperplans liés également. Il ne reste donc "plus qu'à" trouver tous les "cônes", c'est-à-dire toutes les zones de l'espace définies par ces plans. Ces dernières correspondent aux différentes classes d'équivalence de FBS.

Chaque zone de l'espace est définie par un ensemble de contraintes sur les sommes des poids, chaque contrainte indiquant si la zone concernée se situe d'un côté ou de l'autre d'un hyperplan.

Exemple : Si un plan est défini par l'équation $p_A = 0$, alors la contrainte est $p_A > 0$ ou $p_A \leq 0$, limitant la zone à l'un des côtés du plan.

Ces contraintes sont déduites des valeurs présentes dans la table de vérité des FBS de cette classe d'équivalence, les configurations indiquent les poids concernés et la valeur de sortie indique si leur somme est positive (> 0) ou négative (≤ 0). Il faut donc énumérer les contraintes pour former les ensembles qui définissent toutes les zones et donc toutes les classes d'équivalence de FBS.

Pour éviter de générer des ensembles qui ne définissent pas des FBS, des règles logiques sont appliquées au fil de l'énumération des contraintes pour permettre d'inférer les contraintes suivantes à partir de celles déjà énumérées.

Exemple : En dimension 2, si les contraintes $p_A > 0$ et $p_B > 0$ sont fixées, la somme des deux poids sera nécessairement positive et il est inutile d'énumérer la contrainte $p_A + p_B \leq 0$ qui mènerait à un ensemble insoluble comme le montre la figure 22.




Figure 22 : Exemple de contraintes incompatibles sur l'espace des poids. Les contraintes $p_A > 0$ en (1) et $p_B > 0$ en (2) délimitent chacune une moitié de l'espace. Leurs intersections donnent (3). (4) montre la zone délimitée par la contrainte $p_A + p_B \leq 0$, elle est incompatible avec (3) : leur intersection est nulle. Étant donné $p_A > 0$ et $p_B > 0$, la contrainte sur le plan $p_A + p_B = 0$ ne peut donc être que $p_A + p_B > 0$.

4.3.1 Définitions

Afin d'expliquer formellement les règles logiques appliquées aux contraintes, il est nécessaire d'introduire et de définir plusieurs notions : le *signe* d'une contrainte, son *niveau* et son *rang*. Celles-ci permettront d'établir entre les contraintes des relations de priorité et de dépendance.

4.3.1.1 Contraintes

Une contrainte sur le signe d'une somme de poids est notée C_X , X étant l'ensemble des entrées concernées tel que $X \subset \{x_0; \dots; x_{d-1}\}$. Dans le but de fluidifier la lecture, lorsque cela est possible les entrées sont notées par des lettres, en commençant par A pour x_0

Exemple : En dimension 3, X contient les trois entrées x_0, x_1 et x_2 . Une contrainte sur ces entrées sera notée C_{ABC} .

Il est dit de C_X qu'elle est *positive* (respectivement *négative*) si $p_{x_0} + \dots + p_{x_{d-1}} > 0$ (respectivement $p_{x_0} + \dots + p_{x_{d-1}} \leq 0$). C'est le *signe* de la contrainte. Une contrainte C_X dont le signe est connu sera notée $\mathcal{X}$ si elle est positive et $\neg\mathcal{X}$ si elle est négative.

Exemple : C_{AB} correspond à la contrainte sur le signe de la somme $p_A + p_B$. Si C_{AB} est positive alors $p_A + p_B > 0$ et elle est notée $\mathcal{AB}$. Si elle est négative elle est alors notée $\neg\mathcal{AB}$.

Les entrées des contraintes sont toujours ordonnées selon l'ordre alphabétique. Par exemple, la contrainte C_{BA} ne sera jamais rencontrée, tandis que C_{AB} oui. En conséquence, parce que les poids sont ordonnés par ordre décroissant (cf. 4.1.2), les entrées liées à des poids positifs sont toujours sur le côté gauche ($AB\dots$) et celles avec des poids négatifs sur le côté droit ($\dots CD$). Ces côtés sont par la suite appelés les *côtés positifs* et *négatifs* et regroupent les entrées selon le signe de leur poids. Pour une contrainte C_X , ces côtés sont respectivement notés Pos_X et Neg_X . Enfin, le côté de même signe que celui de la contrainte est appelé le *côté gagnant* et l'autre le *côté perdant*.

Exemple : En dimension 3, si le poids p_A est positif et les poids p_B et p_C sont négatifs (ou nuls), alors la contrainte C_{ABC} a pour côté positif A et pour côté négatif BC . Si la somme des trois poids est négative (ou nulle), alors BC est le côté gagnant et A le côté perdant.

4.3.1.2 Niveau

Le niveau L_{C_X} d'une contrainte C_X désigne le nombre d'entrées concernées par cette contrainte.

Exemple : La contrainte C_{AB} est de niveau 2 puisqu'elle concerne les deux entrées A et B .

4.3.1.3 Rang

Le rang d'une contrainte est utilisé pour définir un ordre sur les contraintes d'un même niveau.

Le rang R d'une contrainte C_X , noté R_{C_X} , est une valeur définie à partir des entrées de la contrainte. Chaque entrée x_i se voit assigner un rang R_{x_i} selon son indice $i \in [0; d-1]$ tel que :

$$R_{x_i} = d - i \quad (4)$$

Exemple : En dimension 2, les entrées A et B , respectivement d'indice 0 et 1 ont pour rang $R_A = 2 - 0 = 2$ et $R_B = 2 - 1 = 1$.

Ce rang est utilisé pour déterminer le rang de chaque contrainte défini comme étant la somme des rangs des entrées de cette dernière :

$$R_{C_X} = \sum_{x_i \in X} R_{x_i} \quad (5)$$

Exemple : En dimension 2, la contrainte C_{AB} a pour rang $R_{C_{AB}} = 2 + 1 = 3$, puisque $R_A = 2$ et $R_B = 1$.

4.3.1.4 Dépendances

Une contrainte dont le signe peut être utilisé pour aider à inférer celui d'une autre est appelée une dépendance de cette dernière.

Précisément, une contrainte C_X est une dépendance d'une contrainte C_Y si elle appartient au niveau précédent : $L_{C_X} = L_{C_Y} - 1$ et que toutes les entrées de X figurent dans Y : $X \subset Y$.

Exemple : Les contraintes C_A et C_B sont des dépendances de la contrainte C_{AB} . Elle appartiennent au niveau précédant celui de C_{AB} et toutes leurs entrées sont concernées par C_{AB} , comme le montre la figure 23.




Figure 23 : C_A et C_B sont des dépendances de C_{AB}

La figure 24 présente un exemple complet en dimension 3 regroupant toutes les notions qui viennent d'être définies.




Figure 24 : Arbre des dépendances en dimension 3. Une flèche entre deux contraintes indique que la contrainte au départ de la flèche est une dépendance de la contrainte à l'arrivée. Les contraintes sont classées selon leurs niveaux. Le chiffre en rouge sous chaque contrainte indique son rang.

4.3.2 Méthode

Puisqu'il existe des ensembles de contraintes insolubles, il n'est donc pas correct de simplement les énumérer tous. Afin d'éviter ces ensembles, lors de l'énumération d'une contrainte, les règles logiques détaillées ci-dessous sont appliquées pour déterminer si la contrainte doit être positive, négative ou si les deux signes sont possibles, le tout en utilisant les signes des contraintes déjà énumérées.

Les contraintes sont évaluées par ordre croissant de leur niveau et décroissant de leur rang.

Exemple : En dimension 3, $C_A, C_B, C_C, C_{AB}, C_{AC}, C_{BC} \dots$

4.3.3 Règles logiques

4.3.3.1 Ma supérieure l'a dit

Les contraintes sont énumérées de telle sorte que les poids soient ordonnés par valeur décroissante. De cette propriété émerge qu'au sein d'un même niveau de contraintes, si l'une d'entre-elle est négative, alors "les suivantes" le seront également. La suite de cette section détaille le fonctionnement de cette règle.

Étant donnée une contrainte négative $\neg X$, sans informations supplémentaires, il est possible de déduire qu'au moins la dernière entrée de X est liée à un poids

négatif, puisqu'il en faut au moins un pour que la somme des poids, et donc la contrainte, soit négative.

Exemple : Étant donnée la contrainte $\neg ABC$, puisqu'elle est négative, au moins un des poids parmi p_A, p_B, p_C est négatif. Plus précisément, parce que les poids sont ordonnés par valeurs décroissantes, alors au moins le dernier poids p_C est négatif.

Les contraintes *suivantes* de C_X sont toutes les contraintes C_Y du même niveau, donc portant sur le même nombre d'entrées, et de rang directement inférieur : $R_{C_Y} = R_{C_X} - 1$, telles qu'elles ne diffèrent que d'une seule entrée : $|X| = |Y| = |X \cap Y| + 1$.

$\cap$ est l'opérateur d'intersection de deux ensembles (ici X et Y).

Exemple : En dimension 2, la contrainte suivante de C_{AB} est C_{AC} , puisqu'elle appartient au même niveau, qu'une seule entrée est différente entre les deux et que leurs rang sont respectivement de 5 et de 4 comme il est possible de le voir dans la figure 24.

Donc, chaque contrainte suivante C_Y porte sur les mêmes entrées que C_X sauf pour une qui est remplacée par une entrée de rang inférieur. Cette dernière est donc liée à un poids de valeur inférieure puisque C_Y est de rang inférieur à C_X et que le rang est calculé à partir du rang des entrées, lui-même calculé selon l'indice des entrées qui sont triées par ordre décroissant des poids. En conséquence, la somme des poids de C_Y est toujours inférieure à celles des poids de C_X . De ce constat apparaît que si la somme des poids de C_X est négative, et que C_X est négative, alors toutes les suivantes C_Y sont négatives également. La figure 25 présente un exemple des relations de celle sorte entre contraintes.




Figure 25 : Relation d'inférence entre contraintes illustrant la règle "Ma supérieure l'a dit" pour chaque niveau de contrainte de la dimension 5. Une flèche entre deux contraintes implique que si la première est négative alors la seconde l'est également. Les nombres en rouge sont les rangs des contraintes, les contraintes alignées verticalement au sein du même niveau possèdent la même valeur de rang.

Ainsi, lorsqu'une contrainte est évaluée négative, toutes les contraintes suivantes sont directement inférées négatives et les suivantes des suivantes également *etc ...*

4.3.3.2 Être ou ne pas être ? Ça dépend.

Lorsque le signe d'une contrainte est évalué, il faut prendre en considération ses dépendances (4.3.1.4). Selon les signes de ces dernières, elles influenceront dans un sens ou dans l'autre le signe de la contrainte évaluée.

Si toutes les dépendances partagent le même signe, leurs influences se combinent et la contrainte évaluée hérite de ce signe.

Exemple : En dimension 3, si les dépendances de C_{ABC} : C_{AB} , C_{AC} et C_{BC} , sont positives, alors cette dernière est positive également. En effet, si l'un des poids p_A , p_B ou p_C est négatif et qu'il ne parvient pas à surpasser un seul des deux autres poids positifs, alors il ne peut pas surpasser la somme des deux.

Cependant, si les dépendances sont un mélange de positives et de négatives, une analyse supplémentaire est nécessaire pour déterminer si le signe de la contrainte évaluée peut être inféré ou non. Cette analyse consiste à chercher si, parmi les dépendances, l'influence de l'une d'entre elles annule celle d'une autre qui pourrait alors être ignorée. Cela pourrait mener à un nouvel ensemble de dépendances, qui ne contiendrait alors que des dépendances du même signe, permettant donc d'inférer le signe de la contrainte évaluée. Les figures 26 à 29 présente un exemple de cette analyse étape par étape.




Figure 26 : Exemple de l'inférence du signe d'une contrainte lorsque les dépendances sont un mélange de contraintes positives et de contraintes négatives. L'étape 1 présente l'état de départ : l'inférence du signe de C_{ABCD} depuis le signe de ses dépendances n'est pas possible puisqu'elles ne sont pas toutes du même signe.

Pour détecter ces cas, il est nécessaire de considérer les côtés positifs et négatifs des dépendances (4.3.1.1). Il faut considérer les dépendances par paires, C_X et C_Y , telles que l'une est positive et l'autre négative et telles qu'elles sont composées des mêmes entrées Z pour l'un des côtés : soit $Z = \text{Pos}_X = \text{Pos}_Y$, soit $Z = \text{Neg}_X = \text{Neg}_Y$.

Dans ces cas, Z est responsable de l'influence, positive ou négative, de la dépendance 1 l'ayant comme côté gagnant. Mais puisque le signe de Z reste le même et que C_X et C_Y sont de signe opposés, Z est également le côté perdant de l'autre dépendance 2 qui contient donc d'autres entrées W qui surpassent Z . Une fois toutes les entrées des dépendances combinées dans la contrainte évaluée, l'influence de




Figure 27 : L'étape 2 montre la séparation entre les côté positifs et négatifs des dépendances, avec en gris le côté perdant. Les dépendances $AB|C$ et $\neg AB|D$ forment une paire où $Z = AB$.

Z sur le signe de cette dernière sera surpassée par l'influence de ces autres entrées W . En conséquence et puisque Z porte l'influence de la dépendance 1 l'ayant comme côté gagnant, il est possible d'ignorer cette dépendance 1 pour l'inférence du signe de la contrainte.




Figure 28 : L'étape 3 montre que $\neg AB|D$ annule l'influence de $AB|C$ parce qu'elles partagent le même côté positif AB , mais ce côté est perdant dans $\neg AB|D$. La dépendance $AB|C$ est donc ignorable puisque son influence positive sur la contrainte C_{ABCD} , provenant de AB , est surpassée par l'influence négative de $\neg D$.

D'une manière générale, il est possible d'ignorer toutes les dépendances dont l'influence est annulée par une autre dépendance.




Figure 29 : L'étape 4 montre que puisque la dépendance $AB|C$ est ignorable, il ne reste que des dépendances négatives, il est donc possible d'inférer le signe de C_{ABCD} : négatif.

Après l'analyse des influences des dépendances, si l'ensemble des dépendances d'une contrainte est toujours un mélange de positives et de négatives, alors le

signe de la contrainte courante n'est pas inférable. Il faut alors considérer deux ensembles de contraintes, l'un où la contrainte est positive et l'autre dans lequel elle est négative. Ces deux ensembles mèneront donc à au moins deux classes d'équivalence différentes.

4.3.4 Limites

Si cette méthode semblait prometteuse à première vue, elle a vite rencontré des limites. En effet, force a été de constater que plus la dimension augmente, plus il devient nécessaire de raffiner les informations partielles connues pour en inférer de nouvelles et plus les règles logiques augmentent en complexité.

Exemple : La règle "Être ou ne pas être? Ça dépend" (4.3.3.2) est présentée sous une version simplifiée qui ne fonctionne que jusqu'en dimension 4. Pour que cette règle fonctionne en dimension 5, il devient nécessaire qu'elle prenne en compte davantage de contraintes que les dépendances du niveau directement inférieur. Pour atteindre la dimension 6, il devient nécessaire d'extraire à partir des contraintes de nouvelles informations, portant non pas sur le signe de tel ou tel poids ou somme de poids, mais sur les relations entre les poids, telles que $p_A > p_B + p_C$ sachant $p_A > 0$, $p_B > 0$ et $p_C > 0$.

Ces règles n'ont été définies que jusqu'en dimension 6, puisque systématiquement l'ensemble des classes d'équivalence obtenu est comparé avec celui obtenu par énumération des poids afin de détecter les erreurs et d'obtenir des indices permettant corriger les règles logiques appliquées. Or, non seulement il devient coûteux au-delà de la dimension 6 d'obtenir les classes d'équivalence de FBS via l'énumération des poids, mais il devenait évident qu'il ne serait pas possible d'obtenir un jeu de règles logiques commun à toutes les dimensions puisque chaque nouvelle dimension demande de complexifier plus encore les règles logiques et de tirer davantage d'informations à partir des contraintes dont le signe est déjà connus. De plus, sans l'appui de la méthode par énumération des poids, il faut une compréhension extrême du sujet pour découvrir les modifications à apporter aux règles et il n'est plus possible de confirmer le résultat.

Cette méthode ne nous a donc pas permis d'accéder à l'énumération des classes d'équivalence de FBS pour de plus hautes dimensions et de contourner le coût exponentiel de la méthode d'énumération des poids.

Cependant, quand bien même la difficulté de mise en œuvre est croissante avec la dimension, cette méthode fonctionne. Si elle ne s'est pas avérée salvatrice dans le contexte de nos travaux, elle pourrait toutefois s'avérer utile face à d'autres problématiques. Par exemple si l'objectif d'énumération est moins strict et tolère des fonctions qui ne sont pas des FBS. Elle peut également être employée pour obtenir une limite haute du nombre de classes d'équivalence de FBS.

Il pourrait aussi être possible de compléter cette méthode. Une idée serait d'injecter les ensembles de contraintes énumérées dans un solveur afin de vérifier pour chacune d'entre-elles si un jeu de poids existe et valide qu'elles décrivent bien une classe d'équivalence de FBS.

L'ÉNUMÉRATION DE TOUTES LES CLASSES DE RBS

Ce chapitre décrit dans l'ordre les différentes étapes et méthodes nécessaires pour obtenir l'ensemble de tous les RBS. De-même que pour les FBS, l'objectif est d'obtenir un ensemble tel que chaque réseau représente une des classes d'équivalence de la dimension et que toutes les dimensions soient représentées.

5.1 LE COÛT DE L'ÉNUMÉRATION

Le nombre de classes d'équivalence de FBS par dimension augmente exponentiellement. Il en est donc de même pour le nombre de RBS qu'il est possible de construire avec ces dernières, comme le montre le tableau 5.

Dimension	CE de FBS innées	CE de FBS cumulées	Classes de RBS
0	1	1	1
1	2	3	3
2	4	7	60
3	10	17	31199
4	36	53	3, 623, 481, 898
5	224	277	$< 10^{20}$
6	3024	3301	$< 10^{35}$

Tableau 5 : Nombre de classes d'équivalence de FBS et de RBS par dimension, obtenu par l'énumération des poids pour les FBS et par la méthode d'énumération des RBS présentée dans ce chapitre. Le nombre de classes d'équivalence de FBS cumulées correspond à la somme des classes d'équivalence innées et projetées. Le nombre de RBS en dimension 5 et 6 n'est pas précisément connu, la valeur indiquée est le maximum théorique obtenu par la formule 6

Au-delà de la dimension 4 nous ne pouvons qu'estimer le nombre de classes d'équivalence de RBS au moyen de la formule 6. Cette formule calcul le nombre théorique maximum de RBS qu'il est possible d'obtenir à partir du nombre NB_f de FBS dans la dimension d sans prendre en compte les différents filtrages présentés dans la suite de ce chapitre. Elle est obtenue en combinant et simplifiant les quatre formules permettant de connaître le nombre de combinaisons obtenues par tirage de r éléments parmi n , avec ou sans ordre et avec ou sans remises.

$$\frac{(NB_f + d - 1)!}{(NB_f - 1)!} * d!^{d-1} \quad (6)$$

Les ressources nécessaires pour énumérer tous les RBS augmentent donc rapidement avec la dimension. Les temps de calculs s'allongent démesurément, mais surtout la quantité de mémoire requise devient gigantesque. En conséquence, le

processus décrit dans cette section est plus complexe qu'il n'aurait paru nécessaire. Ce sont cependant ces spécificités qui permettent de réduire les besoins en mémoire et qui rendent accessible l'énumération des RBS dans des dimensions croissantes.

Les besoins en mémoire sont réduits de deux manières. Tout d'abord en travaillant à la volée : un réseau est généré, analysé, les résultats sont stockés puis ce réseau est oublié, les réseaux ne sont jamais stockés tous ensemble en mémoire. Ensuite et surtout, en divisant la génération d'un réseau en plusieurs étapes, détaillées dans ce chapitre et schématisées dans la figure 30.




Figure 30 : Schéma des étapes de génération des RBS

5.2 COMBINAISONS DE FBS

Pour construire un RBS il est nécessaire de connaître sa composition en classes d'équivalence de FBS. La première étape de la génération des RBS est donc d'énumérer toutes les combinaisons de classes d'équivalence de FBS à partir de l'ensemble des FBS canoniques qui les représentent. Par abus de langage ainsi que pour alléger le texte, le terme de FBS est utilisé dans la suite de cette section pour désigner les classes d'équivalence représentées par les FBS canoniques manipulées.

Une combinaison est un ensemble de d FBS. Chacune sera attribuée à l'un des nœuds du réseau selon son emplacement dans la combinaison.

Exemple : En dimension 2, une combinaison $\{f_1, f_2\}$ indique que le premier nœud reçoit la FBS f_1 et le second la FBS f_2 .

Il est important de noter qu'il est tout à fait possible que différents nœuds se voient attribuer la même FBS.

Exemple : La combinaison $\{f_1, f_1\}$ est parfaitement valide.

Cependant, toutes les combinaisons ne sont pas retenues puisque certaines sont équivalentes par permutations.

Exemple : Toujours en dimension 2, comme illustré dans la figure 31, à partir de deux FBS f_1 et f_2 seulement 3 combinaisons sont énumérées ($\{f_1, f_1\}$, $\{f_1, f_2\}$, $\{f_2, f_2\}$) et non 4, puisque les combinaisons $\{f_1, f_2\}$ et $\{f_2, f_1\}$ sont équivalentes.

Limiter dès la première étape l'apparition de doublons, quand bien même ces derniers seraient filtrés en fin de traitement, permet de limiter considérablement les besoins en mémoire puisque chaque combinaison de FBS mène à la génération de multiples réseaux.




Figure 31 : Exemple en dimension 2 des combinaisons générées à partir d'un ensemble fictif de deux FBS. Parmi les combinaisons équivalentes, une seule est retenue.

5.2.1 Ordre sur les classes d'équivalence de FBS

En exploitant un ordre sur les classes d'équivalence de FBS, il est possible d'obtenir toutes les combinaisons de FBS sans même énumérer celles équivalentes par permutation.

À partir de la table de vérité d'une FBS et de l'ordre sur les configurations défini dans la section 1.3.2, il est possible de déterminer un identifiant unique pour la classe d'équivalence représentée par cette FBS.

Pour cela, la suite binaire formée par la sortie de la table de vérité est simplement convertie en valeur décimale, comme illustré par la figure 32.

Entrées	1	0	
Poids	-1	2	Sortie
Configurations	0	0	0
	0	1	1
	1	0	0
	1	1	1

identifiant : 5
 $0101_2 = 5_{10}$

Figure 32 : Table de vérité représentant une FBS de dimension 2, définie par les poids $\langle 2, -1 \rangle_p$ et ayant le comportement $\langle 0, 1, 0, 1 \rangle_{TV}$. L'identifiant de cette classe de FBS est 5, qui est la valeur décimale de 0101_2 .

Puisque toutes les classes d'équivalence ont une table de vérité différente et que l'identifiant d'une classe est extrait de sa table de vérité, toutes les classes d'équivalence ont donc des identifiants différents.

Chaque classe étant identifiée par une valeur entière unique, il est possible de s'appuyer sur l'ordre entre les entiers pour obtenir un ordre entre les FBS.

5.2.2 Énumération des combinaisons

Un ensemble de combinaisons est ainsi créé, une pour chaque FBS, celle-ci se voyant attribuer le premier emplacement de la combinaison. Puis pour chaque autre emplacement, la FBS attribuée doit être supérieure ou égale, en terme d'identifiant, à la FBS de l'emplacement précédent. Les premiers nœuds reçoivent donc les FBS les plus basses et les derniers les FBS les plus hautes. La figure 33 illustre ce processus.




Figure 33 : Schéma des étapes de l'énumération des combinaisons de FBS avec l'ordre entre FBS.

En conséquence, aucune combinaison équivalente à une autre n'est générée. En reprenant l'exemple précédent, si f_1 est plus petite que f_2 , alors la combinaison $\{f_2, f_1\}$ ne peut pas être énumérée puisque si le premier emplacement est occupé par f_2 alors le suivant ne peut être occupée que par f_2 ou une fonction supérieure à f_2 . Dans ce cas, l'énumération invalide $\{f_2, f_1\}$ est avortée.

5.3 ARRANGEMENTS DES FBS

Une combinaison de FBS canoniques ne suffit pas pour définir un RBS. Il est nécessaire de connaître les FBS "concrètes" qui vont le former. C'est-à-dire quelle permutation est sélectionnée pour chacune des classes d'équivalence représentées par les FBS canoniques. Du point de vue du réseau, l'arrangement est ce qui indique quel nœud du réseau est relié à quelle entrée de la fonction. Pour le graphe cela indique les nœuds d'origine des arcs entrants du nœud porteur de la FBS.

Puisqu'un arrangement sélectionne une permutation, il est noté de la même manière : $\langle 0, 1, 2 \rangle_{\text{Perm}}$.

Une combinaison de FBS canoniques auxquelles sont appliqués leurs arrangements permet d'obtenir une matrice de poids. Une matrice de poids est la manière la plus succincte de noter la structure d'un RBS. La figure 34 présente l'équivalence entre une matrice de poids et un RBS.

À partir d'une combinaison de FBS canoniques, plusieurs RBS sont générés puisque pour chacune des FBS il faut énumérer les $d!$ arrangements possibles. Il en résulte qu'une seule combinaison de FBS canoniques permet d'énumérer jusqu'à $d!^d$ RBS différents si aucun d'entre-eux n'est un doublon. La figure 35 présente un exemple des 4 réseaux énumérables à partir d'une combinaison de FBS en dimension 2.

En théorie, il serait possible de se passer de cette notion d'arrangement en utilisant directement toutes les FBS minimales et non les canoniques. C'est-à-dire des représentantes de toutes les permutations de toutes les classes d'équivalence.




Figure 34 : Traduction d'un RBS depuis la forme d'une matrice de poids vers la forme de graphe.




Figure 35 : Les différents réseaux énumérables à partir d'une même combinaison de FBS canoniques en dimension 2. L'opérateur + symbolise l'application des arrangements aux FBS.

Cependant, cela aurait pour conséquence d'augmenter le nombre de combinaisons de FBS à énumérer. En pratique, cela accroît considérablement les besoins en mémoire lors de l'énumération et rend cette approche irréalisable au-delà de la dimension 3 avec les ressources à disposition de notre équipe. Introduire le concept des arrangements, combinés à l'ensemble réduit de combinaisons de FBS canoniques, permet d'étaler les besoins en mémoire au prix d'un peu plus de calculs et rend possible l'énumération des RBS de plus hautes dimensions. Cela peut aussi permettre l'énumération de sous-ensembles de RBS dans les grandes dimensions.

5.4 FILTRAGE DES RÉSEAUX DÉCONNECTÉS

Comme présenté dans la section 3.3, dans ce modèle des RBS, les poids ayant une valeur de 0 sont interprétés comme l'absence d'un arc. En conséquence, si un réseau possède suffisamment de poids à 0, il est possible qu'un ou plusieurs de ses nœuds soient entièrement déconnectés des autres, comme le présente la figure 36.




Figure 36 : Exemple de RBS de dimension 3 où les nœuds ne sont pas connectés. Les arcs grisés portent des poids d'une valeur de 0 ; ils n'existent donc pas dans ce modèle.

Un tel réseau ne fait pas partie de la dimension d puisqu'il s'agit en réalité de plusieurs réseaux de dimensions inférieures. Dans le cas de la figure 36, il ne s'agit pas d'un réseau de dimension 3, mais de deux réseaux, un de dimension 2 et un de dimension 1. Puisque ces réseaux n'appartiennent pas à la dimension d , ils ne doivent pas faire partie de l'ensemble final et sont donc filtrés.

En théorie des graphes, lorsque tous les nœuds forment un seul groupe, le graphe est dit connexe. Plusieurs algorithmes existent pour tester la connexité d'un graphe. Celui utilisé ici consiste à placer chaque nœud du réseau dans un groupe à part, puis à parcourir chaque arc du réseau l'un après l'autre et s'il relie deux groupes de nœuds différents, à les fusionner. À la fin du parcours, s'il n'y a plus qu'un seul groupe de nœuds alors le graphe est connexe. Les réseaux dont le graphe n'est pas connexe sont retirés de l'ensemble final.

5.5 FILTRAGE DES DOUBLONS

Tous les RBS énumérés à partir des combinaisons de FBS canoniques et des arrangements ne sont pas uniques. Certains sont équivalents entre eux par permutation de leurs nœuds : ils font donc partie de la même classe d'équivalence, tandis que d'autres sont directement identiques. Ces réseaux sont appelés des doublons. Plusieurs configurations peuvent mener à des doublons, les cas possibles sont les suivants :

- Plusieurs nœuds portent la même classe d'équivalence de FBS : selon les arrangements appliqués cela peut générer des réseaux équivalents par permutation des nœuds (figure 37).
- Une fonction possède le même poids sur différentes entrées : plusieurs arrangements différents vont générer des réseaux identiques (figure 38).
- Les deux cas en même temps, potentiellement sur différents groupes de nœuds, potentiellement plusieurs fois.




Figure 37 : Deux RBS équivalents par permutations de leurs nœuds. Les nœuds portent les mêmes classes d'équivalence de FBS et les arrangements appliqués sont différents, mais ils font partie de la même classe d'équivalence. Lorsque les nœuds de l'un des deux réseaux sont permutés, l'autre réseau est obtenu. Les flèches pointillées symbolisent cette permutation.




Figure 38 : Deux RBS identiques. Les arrangements appliqués sont différents, mais cela ne change pas le réseau final puisque la seconde FBS possède deux fois le même poids.

5.5.1 Réseau minimal

Parmi un ensemble de réseaux équivalents par permutation de nœuds, un seul doit être retenu. Comme nous n'avons pas perçu l'intérêt d'en conserver un plutôt qu'un autre, nous avons mis en place un critère arbitraire : conserver le réseau dit "minimal".

Un réseau *minimal* entre de tels réseaux est celui dont la matrice des poids est la plus "petite" selon une comparaison poids par poids avec l'ordre de lecture de gauche à droite et de haut en bas (figure 39).




Figure 39 : Ordre de lecture d'une matrice.

Lors de la comparaison de deux matrices, si un poids est plus petit que son homologue, la matrice correspondante est définie comme étant la plus petite des deux. La figure 40 illustre ce processus.




Figure 40 : Comparaison entre deux matrices de poids pour déterminer la minimale. Les poids sont comparés deux à deux selon l'ordre de gauche à droite et de haut en bas.


5.5.2 Filtrage par sélection des réseaux minimaux

Pour chaque réseau, lorsque des nœuds portent la même classe d'équivalence de FBS, des variants de ce réseau sont générés. Chaque variant explore une des différentes permutations possibles sur les nœuds en question. Les matrices de poids des variants sont ensuite comparées avec celle du réseau initial et ce dernier n'est conservé que s'il possède la matrice minimale. La figure 41 illustre ce processus.

Dans le cas où plusieurs groupes de nœuds portent des classes d'équivalence identiques (ex : $\{f_1, f_1, f_2, f_2\}$), toutes les combinaisons de permutations de ces groupes sont explorées.

① Génération des matrices avec permutation des nœuds **B** et **C**

$$\begin{array}{l} \langle 2, 1, -1 \rangle_P \\ \langle 2, -1, -2 \rangle_P + \\ \langle 2, -1, -2 \rangle_P \end{array} + \begin{array}{l} \langle 0, 2, 1 \rangle_{Prm} \\ \langle 1, 0, 2 \rangle_{Prm} \\ \langle 0, 2, 1 \rangle_{Prm} \end{array} = \begin{bmatrix} 2 & -1 & 1 \\ -1 & 2 & -2 \\ 2 & -2 & -1 \end{bmatrix}$$



② Comparaison des matrices

$$\begin{array}{c} [2, -1, 1, -1, 2, -2, 2, -2, -1] \\ \begin{array}{c} \uparrow \\ 2 = 2 \\ \downarrow \end{array} \quad \begin{array}{c} \uparrow \\ -1 < 1 \\ \downarrow \end{array} \\ [2, 1, -1, 2, -1, -2, -1, -2, 2] \end{array} \quad M_1 < M_2$$

③ La matrice M_1 du réseau est bien la minimale. Le réseau est conservé.

Figure 41 : Processus d'évaluation d'un réseau ayant deux nœuds portant la même classe d'équivalence de FBS. Si le réseau est le minimal parmi les versions permutes alors il est conservé.

5.5.3 Filtrage des réseaux identiques

Enfin, tous les réseaux générés à partir d'une même combinaison de FBS canoniques sont comparés. Si deux réseaux sont identiques, tels que dans la figure 38, un seul des deux est conservé, au hasard puisqu'ils sont identiques.

TECHNIQUES ET OUTILS LOGICIELS : PARALLÉLISME ET MÉLANGE DE PARADIGMES

Les études que nous avons menées sur les RBS ont levé une question importante : comment obtenir l'ensemble des RBS d'une dimension donnée ? Précisément, comment obtenir **un seul** RBS représentant de **chaque** classe de RBS différente.

Répondre à cette question fût à la fois un défi théorique et technique.

Théorique d'une part : comment qualifier les problèmes que nous percevons dans notre processus d'énumération des réseaux ? Comment se convaincre qu'un aspect ne nous a pas échappé ? Que nous n'obtenons pas des réseaux en trop : invalides ou en doubles ? Que nous n'éliminons pas des réseaux valides ?

Technique d'autre part, puisque les outils logiciels nécessaires à nos travaux sont les seuls moyens à notre disposition pour observer nos sujets d'étude. Or, de la qualité de ces outils dépend directement notre compréhension théorique. Lorsque cette dernière évolue, il est souvent nécessaire que les outils évoluent également. Ainsi, tout au long de ma thèse, ces derniers ont dû être modifiés, corrigés et mis à jour.

À cela s'ajoute l'ampleur des données que nous voulons analyser, dans un effort sans fin de monter en dimension pour étoffer nos observations. De ce fait découle la nécessité de disposer d'outils performants et les moins gourmands possibles en ressources. Ainsi, il est devenu rapidement nécessaire de pouvoir paralléliser nos calculs.

Cependant, le développement de logiciels parallèles est coûteux, en temps, en rigueur et en connaissance technique. Il peut être très facile d'introduire des erreurs qui prendront des semaines à être identifiées et résolues. À cela s'ajoute le temps nécessaire pour calibrer l'orchestration des traitements afin de tirer le maximum de performance des machines de calculs à disposition. De tels logiciels deviennent vite très complexes. Les modifier est à la fois chronophage et fastidieux.

Nous avons donc d'un côté des spécifications logicielles très mouvantes du fait de l'évolution de nos connaissances théoriques et, de l'autre, des contraintes de performances qui rendent le code complexe et spécifique, donc difficile à maintenir et à remanier.

La conjonction de ces contraintes a forcé, pour réussir ce grand écart, l'émergence d'une architecture logicielle abstraite. À tel point qu'il est devenu nécessaire de prendre le temps de séparer cette architecture dans une bibliothèque logicielle à part : *Java-Parallel-Pipeline* (JPP), présentée en détails dans la première partie de ce chapitre.

Cette bibliothèque est rapidement devenue un point central, permettant de d'interopérer nos outils, dont certains sont issus d'un paradigme de programmation différent : la programmation logique par contraintes ; présentée dans la seconde partie de ce chapitre.

6.1 LE CHOIX DU LANGAGE JAVA

J'utilise principalement le langage Java dans les travaux de cette thèse. Au regard des performances de calcul recherchées, certains pourraient s'interroger sur ce choix pour développer nos outils. Il est vrai que le langage C++ semble à première vue plus adapté pour tirer les plus grandes performances de nos stations de calculs, d'autant plus que cela mettrait à notre disposition des outils éprouvés tels que OpenMP et MPI pour paralléliser et distribuer nos calculs.

Si les performances offertes par Java ne valent pas celles de C++ pour le calcul intensif, elles restent cependant très correctes et même très bonnes en comparaison des langages plus vastement utilisés en recherche tels que Python ou MatLab. Java vient également avec ses avantages, le premier étant bien sur la portabilité du code, mais également une certaine simplicité de développement en comparaison avec C++.

Cependant, d'autres raisons plus spécifiques ont pesé dans ce choix :

- Durant les années précédant ma thèse, plusieurs outils avaient déjà été développés en Java au sein de l'équipe. Cela pour permettre de les intégrer aisément avec d'autres outils, existants ou à-venir. Il était donc plus aisé au début de ma thèse de continuer à développer en Java afin de pouvoir utiliser ces bases de code existantes.
- Java est l'un des langages les plus enseignés et de nombreux étudiants de divers niveaux d'étude ont été et seront amenés à utiliser ou à étendre ces outils durant leur stage (voir section [6.2.5](#)). Le fait que la plupart de ces étudiants soient déjà familiers du langage offre un gain de temps précieux.
- Java est le langage avec lequel je suis personnellement le plus efficace. Étant le développeur principal de ces outils, il est essentiel que je maîtrise le langage utilisé.

6.2 JAVA-PARALLEL-PIPELINE (JPP) : UN OUTIL POUR FAIRE DES OUTILS

Java-Parallel-Pipeline (JPP) est une bibliothèque logicielle permettant de bâtir des chaînes de traitements de données, appelées des *Pipelines*, dont l'exécution est automatiquement parallélisée et orchestrée. L'objectif de JPP est de rendre accessibles et maintenables des traitements parallélisés, même pour des personnes non familières avec la programmation concurrente.



Le guide utilisateur et la documentation technique de JPP sont disponibles à l'adresse suivante : <https://rsegretain.gitlab.io/jpp/>.

6.2.1 Fonctionnement

Une métaphore parlante pour comprendre le fonctionnement de JPP est celle d'une usine pratiquant le travail à la chaîne. Cette usine imaginaire contient différents ateliers les uns à la suite des autres pour transformer et/ou assembler différents produits en d'autres. Chacun de ces ateliers doit être opéré par un ouvrier pour traiter un produit.

Dans le cadre de JPP, les produits sont les données, les ouvriers représentent les threads de calculs, un atelier est appelé un *Processeur* et correspond à une étape du traitement et enfin l'usine correspond à un pipeline.

6.2.1.1 Thread

Au cœur d'un pipeline, se trouve un ensemble de threads qui se répartissent et accomplissent les calculs nécessaires à l'exécution de celui-ci. Ces threads sont créés avec le pipeline et servent pour toutes ses exécutions ; ils ne disparaissent que lorsque ce dernier est arrêté.

6.2.1.2 Processeur

Pour construire un pipeline, la première étape est d'identifier les différentes étapes du traitement puis, pour chacune d'entre-elles, de développer un processeur capable de l'effectuer.

Un processeur JPP comporte trois éléments : le type des données qu'il requiert en entrée, le type des données produites en sortie et le code utilisateur nécessaire à la transformation de l'un en l'autre. L'exécution d'un processeur consiste à consommer une "unité" de données d'entrée pour la transformer en une "unité" de donnée de sortie à l'aide du code qu'il contient. Typiquement, le traitement d'une liste de données effectuée au sein d'une boucle dans un code linéaire formera un proces-

seur. Chaque exécution de ce dernier, avec en entrée l’une des données de la liste, correspond à une itération de la boucle dans le code linéaire.

6.2.1.3 Architecture d’un pipeline

Pour former le squelette d’un pipeline, il faut décrire l’ordre des processeurs.

Exemple : Illustré par la figure 42, le processeur A est le premier, il génère des données pour le processeur B, lui-même suivi par les processeurs C et D et enfin le processeur E agrège les données de C et D et fournit le résultat final.




Figure 42 : Exemple de la division d’un traitement en plusieurs étapes. Chaque étape devient un processeur du pipeline.

Il est également nécessaire de décrire la manière dont les processeurs s’enchaînent. C’est-à-dire comment les données sortantes d’un processeur sont remises au suivant.

Exemple : Illustré par la figure 43, le processeur A génère 6 données à chaque fois qu’il est exécuté. Est-ce que ces données sont fournies une par une au processeur B ? Par lots de taille fixe ? Toutes d’un coup ? Est-ce qu’elles sont sauvegardées en mémoire ? Est-ce que certaines sont filtrées ? Doivent-elles être traitées par différents processeurs selon certaines conditions ?

6.2.1.4 Déroulement d’une exécution

La métaphore de l’usine peut introduire dans l’esprit du lecteur certaines préconceptions qui ne s’appliquent pas dans le cadre de JPP et il est essentiel de préciser ces points pour comprendre la force de JPP.

Premièrement, le nombre de threads qu’il est possible d’utiliser en parallèle dans un ordinateur est limité par le nombre de cœurs de CPU disponibles. En conséquence, lors de l’exécution d’un pipeline JPP, il n’y a pas un thread attribué pour chaque processeur comme il pourrait y avoir un ouvrier par atelier. Au lieu de cela, chaque thread détermine régulièrement selon les besoins et les données disponibles le processeur qu’il exécutera ensuite.




Figure 43 : Exemple du passage des données entre deux processeurs JPP. (1) les données produites par le processeur A sont transmises une par une au processeur B, chacune d'entre elle donne lieu à une exécution du processeur B. (2) les données sont transmises par lot de 3, chaque lot donne lieu à une exécution du processeur B. (3) les données sont transmises d'un seul bloc, le processeur B n'est exécuté qu'une seule fois.

Deuxièmement, il n'y a pas de limite au nombre de threads par processeur : il peut y avoir plusieurs threads exécutant en même temps le même processeur, chacun travaillant sur des données différentes.

Ces deux points, illustrés dans la figure 44, soulignent la souplesse d'action des threads lors de l'exécution d'un pipeline. C'est ce qui leur permet de s'adapter et d'exécuter les processeurs nécessaires dans le pipeline au gré des transits de données entre ces derniers. Ainsi, la somme des comportements individuels des threads permet, par émergence, de maximiser automatiquement l'utilisation des ressources de calcul de l'ordinateur.




Figure 44 : Illustration de l'ordonnancement des exécutions des processeurs dans un pipeline disposant de deux threads. L'ordonnancement est donné selon un temps logique indiqué par les chiffres. Ces derniers sont en rouge ou bleu pour indiquer lequel des deux threads exécute le processeur en question. Le nombre attribué à une donnée indique le temps logique de sa génération. Les threads se répartissent à la volée sur les processeurs selon les données disponibles. Les deux threads peuvent donc exécuter le même processeur en parallèle sur des données différentes, comme le processeur B au temps 2.

6.2.2 Modularisation du code

Comme présenté dans la section 6.2.1.2, un processeur JPP ne contient que trois éléments : le type des données en entrées et en sortie et le code de transformation, rien de plus. Les processeurs ne sont donc pas liés à un pipeline en particulier, ils ne dépendent ni du pipeline ni des processeurs qui les précèdent ou qui les suivent. Les processeurs sont donc des modules indépendants, au sens où ils n'ont pas d'interdépendances directes. Néanmoins, ils peuvent toujours présenter des dépendances communes telles que des structures de données spécifiques au traitement.

Cette modularisation, imposée par JPP, offre deux avantages. Le premier est la réutilisation : un même processeur peut être utilisé dans plusieurs pipelines. Il est donc très rapide de construire un nouveau pipeline si tout ou une partie des processeurs requis existent déjà. Le second avantage porte sur la maintenance et l'évolution du code : les processeurs étant indépendants, la modification du code de l'un n'impacte pas le code des autres. De plus, la modification d'un processeur ne requiert pas de modifier l'orchestration de l'exécution des traitements puisque cet aspect est presque entièrement automatisé par JPP.

6.2.3 Gestion de l'utilisation de la mémoire

Lorsqu'une donnée est transmise à un processeur, elle est stockée dans une file d'attente le temps qu'un thread s'en empare et l'utilise pour exécuter le processeur. Il existe le risque qu'un processeur produise énormément de données et sature la mémoire en stockant ces dernières dans les files d'attente des processeurs suivants. Deux mécanismes sont mis en place dans JPP pour réguler ce problème. Le premier est automatique et autoadaptatif, il s'agit de l'ordre dans lequel les threads sélectionnent les processeurs à exécuter. Plus un processeur est profond, c'est-à-dire proche de la sortie des données du pipeline, plus il sera prioritaire.

Exemple : Illustré par la figure 45, entre deux processeurs qui se suivent, les threads priorisent l'exécution du second plutôt que de se répartir équitablement entre les deux et d'accumuler des données entre eux. Le premier n'est exécuté que lorsque cela est nécessaire pour alimenter en données le second.

En conséquence, même si un processeur produit des grands volumes de données il ne peut pas saturer la mémoire, à moins bien entendu qu'une unique exécution de ce dernier produise déjà trop de données. Ce dernier cas nécessiterait probablement de diviser le processeur concerné en plusieurs ou à repenser le découpage global du traitement.

Le second mécanisme, désactivé par défaut, consiste à limiter le nombre de threads pouvant exécuter un même processeur en parallèle. Sans cette limite, dans le cas où seul un processeur gros producteur de données est exécutable, tous les threads débiterait alors en même temps une exécution de ce processeur, menant à une saturation de la mémoire, comme illustré dans la figure 46. Il est préférable que certains threads ne fassent rien et attendent pendant que d'autres threads, en nombre limité donc, exécute le processeur en question pour fournir les données nécessaires à l'exécution des processeurs suivants.




Figure 45 : Exemple comparant l'utilisation de la mémoire entre deux modes d'ordonnancement : la répartition équitable entre les processeurs et la priorité pour les pipelines plus profonds. Pour simplifier l'exemple, les pipelines ne disposent que d'un seul thread. L'exécution du premier pipeline échoue : avec la répartition équitable des threads, le processeur A produit trop de données et sature la mémoire au temps 5. L'exécution du second pipeline parvient à écouler les données produites par le processeur A grâce à la priorité en profondeur et atteint le pas de temps 10 sans saturer la mémoire.




Figure 46 : Exemple de limitation du nombre de thread par processeur. Dans le premier pipeline, sans limite, au temps 1 les deux threads débutent une exécution du processeur A, menant à une saturation de la mémoire. Dans le second pipeline, le processeur A est limité, un seul thread peut l'exécuter en même temps. Au temps 1 seul le thread 1 l'exécute tandis que le thread 2 est inactif. Puis les deux threads exécutent le processeur B pour consommer les données produites par le processeur A. La mémoire n'est pas saturée.

6.2.4 Synchronisation

Certains traitements peuvent posséder des sections qui ne peuvent pas être parallélisées ou d'autres particularités qui les rendent inadaptés au fonctionnement en flux de données de JPP.

Exemple : Un processeur qui nécessite de disposer de l'ensemble des données produites par les processeurs qui le précèdent avant de pouvoir s'exécuter.

Pour palier à ces problèmes, JPP dispose d'un système permettant de retenir les données en amont d'un processeur tant qu'un évènement défini ne s'est pas produit. L'évènement en question peut être soit un évènement déclenché par le code utilisateur, soit un évènement déclenché par JPP. À l'heure où je rédige ces lignes, JPP n'offre que deux types d'évènements. Le premier signale que le pipeline démarre une nouvelle exécution. Le second indique qu'un processeur a fini de traiter ses données : il ne sera plus utilisé durant l'exécution courante du pipeline. La figure 47 présente un exemple de synchronisation.




Figure 47 : Exemple de retenue de données en attente d'un évènement. Le processeur A est le premier du pipeline et a quatre données à traiter. Le processeur B doit attendre la fin du processeur A pour commencer son traitement. Il y a donc une file d'attente entre les deux processeurs. Cette dernière est débloquée au temps 4 lorsque A a terminé, B peut alors débiter ses exécutions.

6.2.5 Les usages de JPP dans l'équipe

6.2.5.1 Traitements sur les FBS et les RBS

L'usage premier de la bibliothèque JPP au sein de l'équipe est naturellement la génération et l'analyse des FBS et des RBS, puisque ce sont ces traitements à l'origine qui ont nécessité la création de JPP.

Deux stagiaires que j'ai co-encadrés, Rémy Défossez et Ai-Ling Nguyen Bonnet, ont étudié le sujet des distances entre les RBS, leur robustesse et leur évolutivité (détaillé dans le chapitre 8). Ils ont grandement bénéficié de l'architecture modulaire de JPP en réutilisant plusieurs modules déjà développés afin de bâtir leurs propres pipelines. Cela leur a permis de ne pas avoir à trop se plonger dans les détails techniques, leur offrant ainsi un gain de temps considérable.

6.2.5.2 Intégration à *NetworkDesigner*

Mon directeur de thèse, Nicolas Glade, développe depuis plusieurs années un logiciel nommé *NetworkDesigner* (NWD). Il permet la conception graphique de ré-

seaux d'automates de divers types (réseaux de Thomas [5], réseaux de Hopfield [7] *etc* ...). NWD offre ensuite la possibilité d'une part d'analyser ces réseaux (par exemple leurs dynamiques) et d'autre part, si les réseaux conçus ne sont que partiels, d'inférer à l'aide de programmation logique par contraintes l'ensemble des réseaux complets qui correspondent.

Durant l'été 2021, Florian Birkner, alors étudiant en M1 Phelma à l'INP de Grenoble, a effectué un stage ayant pour objectif de prototyper l'intégration JPP au sein de NWD. Florian a ainsi pu développer un système de scripts, lus par NWD, qui génère un pipeline JPP sur des RBS. L'objectif à terme serait de permettre dans NWD de concevoir graphiquement des pipelines JPP afin de paralléliser les analyses effectuées sur les réseaux.

[5] THOMAS « On the Relation Between the Logical Structure of Systems and Their Ability to Generate Multiple Steady States or Sustained Oscillations » (1981)

[7] HOPFIELD « Neural networks and physical systems with emergent collective computational abilities. » (1982)

6.3 FILTRAGE DES RBS

L'ensemble des RBS est vaste et il n'est pas possible de les étudier un à un. Il est arrivé à de multiples occasions que des questions telles que celle présentée dans la figure 48 se posent concernant les RBS.




Figure 48 : Capture d'écran d'un message de mon directeur de thèse Nicolas Glade : "*@remi.segretain j'imagine qu'il n'existe pas de réseau $d=3$ capable de ça ?*".

Afin de pouvoir répondre aisément à ces questions, j'ai mis en place un système de filtrage des RBS, selon des critères portant sur leur structure et leurs dynamiques. Ce système permet de limiter un pipeline aux seuls réseaux qui rentrent dans les critères spécifiés. Ces critères sont inscrits dans un fichier à part. Ce système offre plusieurs avantages :

- En contraignant les réseaux à respecter certaines caractéristiques, il devient possible d'explorer des réseaux de plus hautes dimensions puisque le volume de réseaux à analyser est alors réduit.

- Les critères sont spécifiés indépendamment des pipelines, il est donc possible de réutiliser facilement ces derniers pour répondre à diverses interrogations sans avoir à les modifier.
- La gestion des données gagne en qualité : en conservant le fichier contenant les critères aux côtés des données générées, les conditions de génération de ces dernières sont plus précises.

Les critères respectent la grammaire définie par les règles suivantes :

- 1 : Constraint → FieldId : Type : Rule
- 2 : FieldId → Regex("[a-zA-Z_]+")
- 3 : Type → digit | string
- 4 : Rule → NOT(Rule) | (Rule) OR (Rule) | (Rule) AND (Rule) | TypedRule
- 5 : TypedRule → DigitRule | StringRule
- 6 : StringRule → Regex
- 7 : DigitRule → Operator DigitValue
- 8 : Operator → < | > | = | <= | >=
- 9 : DigitValue → Regex("\d+(\.\d+)?")

- 1 : Une contrainte concerne un champ FieldId d'un type Type et est définie par une règle Rule.
- 2 : Le nom d'un champ ne peut contenir que des underscores et des lettres de 'A' à 'Z', minuscules ou majuscules.
- 3 : Le type d'un champ peut être soit un nombre, soit une chaîne de caractères.
- 4 : Une règle peut être composée de sous-règles, assemblées avec les trois opérateurs logiques : NON, ET et OU.
- 5 : Une règle ne peut s'appliquer qu'à un type de champ, soit elle concerne des nombres, soit une chaîne de caractères.
- 6 : Une règle concernant une chaîne de caractères est définie par une Regex.
- 7 : Une règle sur un nombre est définie par un opérateur et un nombre DigitValue, le nombre désigné par le champ sera "inséré" à gauche de l'opérateur lors de l'application de la règle.
- 8 : Les opérateurs acceptés sont : <, >, =, <= et >=
- 9 : Un nombre dans une règle peut être un entier ou un flottant.

Une fois que les noms des champs sont liés dans le code aux variables correspondantes, les fichiers de contraintes peuvent être édités librement. Une contrainte par ligne. Ainsi pour un même pipeline, il est possible d'obtenir des ensembles de réseaux complètement différents via différents critères, comme dans les exemples suivants.

Exemple : Le critère suivant sélectionne les réseaux présentant les attributs de taille 6 ou plus : "Size_A : digit : >= 6".

Exemple : Le critère suivant "Music : string : 10011" sélectionne les réseaux dont un nœud produit la musique 10011*.

6.4 PROGRAMMATION LOGIQUE PAR CONTRAINTES

Les langages tels que Java, C, Python *etc* ... font partie de la famille des langages dits impératifs : c'est-à-dire qu'ils décrivent la méthode, l'algorithme, à mettre en œuvre pour résoudre un problème. Ils décrivent le *comment*.

Il existe d'autres familles de langages, fondés sur des paradigmes de programmation différents. La programmation logique par contraintes fait partie du paradigme de la programmation déclarative. Avec ces langages, un programme ne décrit pas une méthode, il décrit plutôt à *quoi* doivent se conformer les solutions et quelles sont les contraintes qu'elles doivent respecter. C'est ensuite un solveur qui à partir de cette description va rechercher s'il existe zéro, une ou plusieurs solutions.

Certains problèmes sont particulièrement bien adaptés à être résolus de cette manière.

Exemple : Avec le langage ASP (introduit dans la section suivante), le jeu du Sudoku peut être résolu en moins de dix lignes de codes (<https://lucas.bourneuf.net/blog/asp-tuto.html#resoudre-ou-generer-des-sudoku-meme->

Il en faudrait bien plus avec un langage impératif!

Dans le cadre des RBS, la programmation en ASP s'est avéré particulièrement utile pour implémenter la génération des FBS par la méthode d'énumération des poids ainsi que pour nos travaux sur l'extension des réseaux, présentés dans le chapitre 8.

6.4.1 Answer Set Programming (ASP)

[18] GEBSER et al. « Potassco : The Potsdam Answer Set Solving Collection » (2011)

Le langage qui nous avons utilisé est *Answer Set Programming* (ASP) [18]. Je ne m'attarderais pas ici à en faire une présentation rigoureuse, je n'introduirais que les notions nécessaires à la compréhension de l'utilisation que nous avons eu de ce langage. Voici cependant deux excellentes ressources pour découvrir ce domaine :

- Un tutoriel très complet et accessible, en français, par Lucas Bourneuf : <https://lucas.bourneuf.net/blog/asp-tuto.html>
- Le site de Potassco de l'université de Potsdam, à l'origine du langage, qui regroupe et présente divers outils et ressources essentielles : <https://potassco.org/>

6.4.2 Architecture modulaire

Pour résoudre un problème en ASP, la description de ce dernier n'est pas toujours suffisant, il peut être nécessaire de préciser les données initiales.

Exemple : Dans le cas du Sudoku, la seule description des règles du jeu donnera comme solutions toutes les grilles possibles (précisément : 6 670 903 752 021 072 936 960 grilles 9x9). Pour résoudre une grille en particulier, il faut également fournir les valeurs qui préremplissent cette dernière.

Ainsi, lors d'une exécution ASP, deux éléments sont typiquement donnés au solveur : le module décrivant les caractéristiques générales du problème et un module contenant les données spécifiques du cas courant. Chaque module étant concrètement un fichier contenant du code ASP.

Selon la facette du sujet des RBS que nous étudions à un moment donné, les spécifications précises du problème varient. En conséquence, le code ASP utilisé doit être adapté. Afin de minimiser les modifications de code à apporter, au lieu de réunir les caractéristiques générales du problème dans un seul module, ces dernières sont séparées en plusieurs modules distincts. Selon les notions qu'ils définissent, ces modules peuvent dépendre d'un ou plusieurs autres comme le montre la figure 49.




Figure 49 : Modules ASP définissant diverses notions autour des RBS. Les modules au-dessus dépendent des modules en dessous.

Cette architecture permet, lors de la résolution d'un problème en particulier, de n'utiliser que les modules strictement nécessaires ce qui permet d'économiser des ressources de calcul.

6.4.3 Intégration

Une fois les modules descriptifs des divers problèmes développés, pour spécifier une exécution ASP, il suffit de produire un module spécifique précisant les données du problème courant et les modules descriptifs requis.

Cette architecture permet de facilement automatiser des exécutions ASP depuis un autre langage, dans notre cas depuis Java, en produisant ce module spécifique sous la forme d'un fichier temporaire. Ce dernier devient en quelque sorte une "requête" ASP, comme on pourrait requêter une base de données.

Il devient donc possible d'intégrer des sous-traitements, spécifiés dans le paradigme de la programmation déclarative, au sein d'autres traitements en programmation impérative. Ainsi plusieurs des processeurs JPP que nous avons créés servent uniquement à formuler des requêtes ASP et à en récupérer les solutions trouvées.

Troisième partie

ÉTUDE DE L'ÉVOLUTION DES RBS ET DES RELATIONS ENTRE LEUR STRUCTURE ET LEUR DYNAMIQUE

L'objectif des travaux de cette thèse est d'étudier au travers du modèle des réseaux booléens à signe les systèmes biologiques et la manière dont ils évoluent. Ils se positionnent dans le cadre général de l'étude des origines du vivant et de la reprogrammation cellulaire. L'intention est de nourrir les réflexions et d'apporter de nouvelles indications sur la manière dont les systèmes biologiques ont traversé l'évolution et sont devenus ce qu'ils sont aujourd'hui.

Dans un premier temps, le chapitre 7 présente nos travaux sur les relations entre la structure et la dynamique des RBS. Pour cela nous étudions la complexité de différents aspects de la structure d'un réseau et comment ils sont corrélés avec la complexité des comportements ainsi que différentes autres caractéristiques de la dynamique que nous observons.

Dans un second temps, le chapitre 8 présente deux approches complémentaires développées pour étudier l'évolution des RBS. La première pose un cadre permettant d'analyser des ensembles de RBS afin d'étudier leur robustesse et évolutivité. La seconde étudie l'ajout de nouveaux éléments dans un système et la manière dont ces derniers les intègrent, sans que cela ne bouleverse leur structure et leur dynamique.

Intuitivement, il semble cohérent qu'un système qui exprime un comportement complexe possède lui-même une structure complexe. C'est effectivement ce que nous avons observé dans nos travaux sur les Réseaux Booléens à Seuil [1] : seuls les réseaux présentant la plus grande complexité structurelle sont capables des comportements les plus complexes. Cependant, nous avons également observé que ces réseaux ne sont pas limités aux seuls comportements complexes, ils sont capables d'exprimer des comportements de toutes complexités.

Nous nous sommes interrogés sur l'utilisation de cette complexité structurelle. Dans les cas où cette dernière ne permet pas des comportements complexes, est-elle réallouée dans d'autres caractéristiques ? Est-ce qu'elle permet à des comportements plus simples d'être plus robustes à des perturbations de l'état du réseau ? De sa structure ? Aux deux ? Pourrait-elle permettre à plusieurs comportements différents de coexister dans le même réseau ? La figure 50 présente schématiquement ces idées.

Dans ce chapitre, je présente nos travaux, tâchant de répondre à ces questions, sur l'étude des relations entre la structure et la dynamique des RBS.

La première partie introduit les mesures de complexité que nous utilisons. La deuxième partie présente les résultats obtenus.

Ces travaux ont fait l'objet d'une publication en 2021 dans la conférence BioInformatics and BioEngineering (BIBE) [4]. Ils sont présentés ici dans une version approfondie et corrigée.

[1] CHRISTEN et al. « On Computing Structural and Behavioral Complexities of Threshold Boolean Networks » (2019)

[4] SEGRETAINE et al. « Who Plays Complex Music? On the Correlations Between Structural and Behavioral Complexity Measures in Sign Boolean Networks » (2021)




Figure 50 : Schéma des trois caractéristiques de la dynamique d'un réseau : la complexité, la robustesse et la multi-attractivité. Les trois réseaux et leur graphe de transition représentent chacun une des catégories de dynamique. Les arcs colorés mettent en avant les attracteurs et les bassins d'attraction d'intérêt. En haut se trouvent les réseaux capables d'un comportement complexe, ce qui se traduit par un attracteur occupant la majorité du graphe de transition. En bas à gauche les réseaux capables de plusieurs comportements différents. Enfin en bas à droite les réseaux possédant un comportement robuste. L'exemple présente une robustesse aux erreurs d'états : l'attracteur possède un grand bassin d'attraction, en cas d'erreur l'état du réseau a toutes les chances de revenir à terme dans l'attracteur.

7.1 MESURER LA COMPLEXITÉ DES RBS

7.1.1 Rareté des FBS

Une des propositions que nous avons faites est de rapporter la complexité d'une classe d'équivalence de FBS à sa rareté, c'est-à-dire la difficulté de la trouver en tirant au hasard des points dans l'espace des poids. L'idée est de lier la complexité d'un objet au coût requis pour le produire. Un objet simple est peu coûteux à produire. En conséquence, à investissement égal, il sera beaucoup plus répandu qu'un objet complexe et donc coûteux à produire.

Exemple : Dans l'Univers, l'or est un élément rare. Il nécessite pour être produit que de la matière se rassemble, devienne une étoile en démarrant une réaction de fusion nucléaire et que la masse de cette dernière se situe dans le bon intervalle pour qu'elle finisse sa vie en supernova est que de l'or soit alors fusionné. L'or est donc bien plus complexe que d'autres éléments comme le fer par exemple, fusionné dans n'importe quelle étoile.

7.1.1.1 Mesure du volume des classes d'équivalence dans l'espace des poids

Pour mesurer le volume de chaque classe d'équivalence de FBS, l'ensemble des points de coordonnées entières de l'espace des poids sont énumérés, dans la limite de certaines valeurs des poids. Puis pour chaque point, la classe d'équivalence de FBS à laquelle il appartient est déterminée. Le nombre de point que contient chaque classe d'équivalence est compté et le volume estimé de ces dernières est obtenu en comparant leurs nombres de points au nombre total de points énumérés, comme l'illustre la figure 51.

Remarque : Le volume mesuré d'une classe d'équivalence n'est qu'une estimation de la proportion de l'espace qu'elle occupe, puisque ce dernier est infini. Les classes d'équivalence étant définies par des plans qui passent tous par l'origine, ils ne délimitent pas des zones finies de l'espace. Le volume d'une classe d'équivalence est donc en réalité infini.

7.1.1.2 FBS de dimensions inférieures

Cette définition de la rareté cause un effet de bord qui semble à première vue contre-intuitif. Les classes d'équivalence de FBS projetées ont, selon cette définition, une complexité bien supérieure à celles des classes d'équivalence de la dimension du réseau. En effet, puisque les classes d'équivalence des dimensions inférieures ne contiennent que des points situés sur les axes, ceux ayant une ou plusieurs coordonnées à zéro, ces classes d'équivalence ont donc un volume infiniment plus faible et sont donc bien plus rares.

Il paraît étrange que des fonctions traitant moins d'entrées soient plus complexes. Cela fait cependant sens du point de vue de la biologie et de l'évolution. Il est difficile pour un élément plongé dans un système biologique de n'avoir strictement aucune interaction d'aucune sorte (physique, chimique *etc*) avec certains de ses voisins. Il est encore plus difficile pour un tel élément, s'il joue un rôle vital, d'être maintenu au fil de l'évolution.




Figure 51 : Décompte du nombre de point de l'espace contenu dans chaque classe d'équivalence de dimension 2 afin d'estimer leurs volumes. Les poids sont limités à des valeurs comprises entre -7 et 7 , l'espace compte donc 225 points, répartis entre les sept classes d'équivalence. Chaque couleur de point dénote une classe d'équivalence différente.

La mesure de la rareté des classes d'équivalence des dimensions inférieures est un défaut de notre méthode : le choix de l'intervalle des valeurs des poids détermine directement le volume donné aux axes ainsi qu'à l'origine, puisque seuls les points de coordonnées entières sont énumérés.

Exemple : Le volume de l'unique classe d'équivalence de dimension 0 contient toujours un unique point : l'origine. Le volume mesuré de cette classe d'équivalence est donc toujours : $\frac{1}{\text{Nombre de points}}$. Dans l'exemple de la figure 51 où 225 points sont énumérés, le volume mesuré de la classe d'équivalence est donc de $\frac{1}{225} \approx 0.44$.

Le volume de ces classes d'équivalence devrait être en théorie infiniment proche de zéro, leur donnant ainsi une rareté quasi-infinie.

7.1.2 Centralité des RBS

Un RBS, comme défini dans le chapitre 2, n'est pas défini seulement par les FBS qui le composent, mais également par la manière dont ces dernières sont assemblées. Si la rareté des FBS mesure la complexité des composants d'un réseau, il est également nécessaire de s'intéresser à la complexité de leur assemblage, afin d'obtenir une vue d'ensemble de la complexité structurelle d'un RBS. C'est ce que nous réalisons au travers de la centralité.

La centralité est une mesure issue du domaine de la théorie des graphes qui permet de mesurer "l'importance" d'un nœud dans un graphe. La centralité se mesure nœud par nœud et il n'existe donc pas de "centralité" d'un réseau. Cependant, par

abus de langage, c'est ainsi que nous nommons la mesure que nous introduisons, calculée à partir des valeurs de centralité des nœuds d'un réseau.

Il existe de nombreuses définitions de la centralité d'un nœud, chacune adaptée à mesurer un aspect ou des graphes particuliers, selon ce qui est considéré comme "important".

Dans notre contexte, les systèmes biologiques, ce qui nous importe est de mesurer l'influence de chacun des nœuds sur les autres et, à l'échelle du réseau, de mesurer sa sensibilité :

- Est-ce que la modification de l'état d'un nœud entraîne de grandes répercussions sur le reste du réseau ? Au bout de combien de temps ?
- Est-ce qu'il existe un nœud "chef d'orchestre" ? Ou bien est-ce que tous les nœuds sont égaux et se coordonnent pour piloter l'état du réseau ?

Afin de répondre à ces questions, nous définissons deux mesures de la centralité d'un nœud. Toutes deux se fondent sur l'influence d'un nœud sur les autres selon les poids de ses arcs sortants.

La première, initialement présentée dans [2], est fondée sur la probabilité qu'un nœud influence au moins un autre nœud du réseau, lui-même inclus, au travers de tous les chemins possibles. La "centralité" d'un réseau est alors la probabilité qu'au moins un nœud influence un autre nœud, ce qui correspond au produit des centralités de chaque nœud.

[2] SEGRETAINE et al. « A Methodology for Evaluating the Extensibility of Boolean Networks' Structure and Function » (2021)

La seconde évalue la répartition de l'influence entre les nœuds. Elle repose pour cela sur l'influence finale de chaque nœud une fois que celle-ci a été homogénéisée dans le réseau selon les poids des arcs.

7.1.2.1 Chemin d'influence

Nous définissons un chemin, par lequel un nœud A influence un nœud B, comme une suite d'arc partant de A et allant à B, qui ne passe jamais deux fois par le même arc, mais qui peut passer plusieurs fois par le même nœud, y compris le nœud B. Cela permet de mesurer toute l'influence, y compris les "échos" indirects faibles.

Pour calculer la centralité d'un nœud, il est nécessaire de calculer la probabilité d'influence de chaque chemin qui en part ainsi que, par conséquence, la probabilité d'influence de chacun des arcs qui composent ces chemins.

Pour chaque arc Arc_{ij} partant du nœud n_i et allant au nœud n_j , la probabilité PI qu'il influence n_j est calculée en comparant la valeur absolue de son poids p_{ij} à celle des poids de tous les arcs entrants sur n_j . La figure 52 présente un exemple et la formule suivante détaille le calcul :

$$PI(\text{Arc}_{ij}) = \frac{|p_{ij}|}{\sum_{k=1}^d |p_{kj}|} \quad (7)$$




Figure 52 : Exemple des probabilités d'influence des arcs entrants sur un nœud. La somme des valeurs absolues des poids est égale à 4, l'influence de l'arc a est donc de $2/4 = 0.5$ et celles de b et c de $1/4 = 0.25$.

Remarque : C'est parce que la mesure de centralité est basée sur cette probabilité d'influence des arcs, elle-même fondée sur la comparaison des différentes valeurs des poids, qu'il est important que les FBS utilisées pour la génération des RBS soient minimales telles que défini dans la section 4.1.1. Une FBS non minimale pourrait présenter des variations importantes de ses poids, faussant ainsi la mesure. Sans cela, il ne serait pas possible de comparer les réseaux sur la base de leur centralité. L'utilisation des FBS minimales assure que la centralité est calculée dans les mêmes conditions pour tous les réseaux.

La probabilité d'influence PI d'un chemin Chemin_{ij} du nœud n_i au nœud n_j est le fruit de la propagation de l'influence de nœud en nœud à chaque étape de

simulation. Son calcul est donc fondé sur le produit des probabilités de chacun des arcs qui composent le chemin, comme le présente la formule suivante :

$$PI(\text{Chemin}_{ij}) = \sqrt[L_{ij}]{\prod_{\text{Arc} \in \text{Chemin}_{ij}} PI(\text{Arc})}, \text{ avec } L_{ij} \text{ la longueur du chemin. (8)}$$

Dans cette formule, nous exprimons la probabilité d'influence d'un chemin comme une probabilité moyenne qui peut être comparée à celle des autres chemins. C'est la raison pour laquelle nous utilisons la moyenne géométrique : chaque FBS le long du chemin reçoit un nombre variable d'arcs entrants, par conséquent, à chaque étape l'influence d'un arc sur un nœud peut être normalisé par un nombre différent de poids. La figure 53 présente un exemple du calcul de la probabilité d'influence d'un chemin.




Figure 53 : Exemple de calcul de la probabilité d'influence du chemin en rouge entre les nœuds A et B. Les influences de chacun des arcs du chemin sont multipliées entre elles, puis le produit est normalisé par la longueur du chemin, ici 3.

Puisqu'il peut exister plusieurs chemins différents entre deux nœuds, comme le montre l'exemple de la figure 54, la probabilité globale PI_{ij} que n_i influence n_j doit les prendre tous en compte. Nous calculons donc PI_{ij}^I comme l'union successive* des probabilités d'influence de ces chemins :

* : notée $\cup$

$$PI_{ij} = \left(\bigcup_{\text{Chemin} \in \text{Chemins}_{ij}} PI(\text{Chemin}) \right). \quad (9)$$

Où Chemins_{ij} est l'ensemble des chemins depuis le nœud A vers le nœud B.

La centralité $\mathcal{C}_i$ d'un nœud n_i étant la probabilité qu'il influence au moins un nœud, lui-même inclus, cette dernière regroupe toutes les probabilités PI_{ik} que le nœud n_i influence le nœud n_k quelque soit k .

$$\mathcal{C}_i = \left(\bigcup_{k=1}^d PI_{ik} \right). \quad (10)$$

Finalement, nous utilisons la centralité $\mathcal{C}_i$ de chaque nœud n_i pour calculer la centralité $\mathcal{C}_R$ du réseau R comme suit :

$$\mathcal{C}_R = \prod_{i=1}^d \begin{cases} \mathcal{C}_i & \text{si } \mathcal{C}_i > 0 \\ 1 & \text{sinon} \end{cases} \quad (11)$$




Figure 54 : Exemple de la probabilité globale que le nœud A influence le nœud B. Il existe trois chemins de A vers B, l'union de leurs probabilités respectives donne la probabilité globale.

Les nœuds ayant une centralité de zéro (*i.e.* les nœuds qui sont des lecteurs purs, leur état n'étant jamais lu par aucun autre nœud, eux-inclus) sont *de facto* exclus du calcul de la centralité du réseau.

Remarque : La principale limite de cette mesure est que les centralités des nœuds ont tendance à converger vers la borne maximale : 1. Cela vient des unions successives des probabilités d'influence de tous les chemins partant d'un nœud.

7.1.2.2 Répartition de l'influence

La répartition de l'influence est une autre méthode que nous proposons pour mesurer la complexité de l'assemblage d'un réseau. Cette mesure est fondée sur les mêmes éléments que la centralité par chemin d'influence : l'influence des arcs sur un nœud. Elle a pour objectif de lever la limite de la centralité en apportant davantage d'informations sur les nombreux réseaux pour lesquels cette centralité sature à 1.

L'intention de cette mesure, comme son nom l'indique, est d'exprimer la répartition de l'influence dans le réseau, elle pose la question suivante : où se situe l'influence dans le réseau ? Est-elle concentrée sur un seul nœud comme dans le réseau de gauche de la figure 55 ? Ou bien est-elle répartie équitablement dans tout le réseau comme dans le réseau de droite ?

Le calcul de la répartition de l'influence dans un réseau se fonde donc sur les probabilités PI qu'ont chacun des Arc_{ij} d'influencer leurs nœuds cibles telles que calculées dans la formule 7. La figure 56 présente le réseau utilisé comme exemple pour illustrer les différentes étapes du calcul de la répartition d'influence.

Pour chaque nœud n_i , nous définissons son influence directe, dite de degré 0 et notée $Influence_0$, calculée à partir des probabilités d'influence de ses arcs sortants, selon la formule suivante :

$$Influence_0(n_i) = \frac{\sum_{k=1}^d PI(Arc_{ik})}{d} \quad (12)$$




Figure 55 : Exemple de répartition de l'influence dans des réseaux. Dans le réseau de gauche, le nœud A est le seul à posséder des arcs sortants, il concentre donc toute l'influence du réseau. Dans le réseau de droite, les deux nœuds ont le même nombre d'arcs avec les mêmes valeurs de poids, ils influencent donc autant le réseau l'un que l'autre.




Figure 56 : RBS de dimension 4. Les arcs portent deux valeurs, en noir leur poids et en rouge leur probabilité d'influence.

Puisque pour chaque nœud, la valeur finale recherchée est la proportion d'influence qu'il détient, la valeur d'influence directe est normalisée par la dimension d du réseau afin que la somme des influences directes de tous les nœuds soit toujours égale à 1. La figure 57 illustre cette normalisation.




Figure 57 : Influences directes des nœuds (en rouge), calculées à partir des probabilités d'influence de leurs arcs sortants. Le calcul pour le nœud A est en bleu, il possède trois arcs sortants ayant chacun une probabilité d'influence de 0.5, son influence directe est égale à la somme de leurs influences, divisée par la dimension.

L'influence directe permet ensuite de calculer pour chaque nœud son influence "indirecte" de degré 1. Elle correspond à la somme des influences de degré 0 de chacun des nœuds que lui-même influence, modulée par les probabilités d'influence des arcs utilisés pour influencer ces nœuds. L'influence indirecte est définie par la formule suivante et illustrée dans la figure 58 :

$$\text{Influence}_1(n_i) = \sum_{k=1}^d \text{Influence}_0(n_k) * \text{PI}(\text{Arc}_{ik}) \quad (13)$$




Figure 58 : Influences indirectes des nœuds (en bleu), calculées à partir des influences directes (en rouge). Le calcul pour le nœud C est en vert, il influence les nœuds B et D, donc son influence de degré 1 est égale à la somme des produits des influences de degré 0 des nœuds B et D avec respectivement $\text{PI}(\text{Arc}_{CB})$ et $\text{PI}(\text{Arc}_{CD})$, qui sont les probabilités d'influence des arcs reliant C à B et C à D.

L'influence est ensuite diffusée dans le réseau. Pour chaque nœud, son influence de degré N est calculée à partir des influences de degré N – 1 :

$$\text{Influence}_N(n_i) = \sum_{k=1}^d \text{Influence}_{N-1}(n_k) * \text{PI}(\text{Arc}_{ik}) \quad (14)$$

Cette diffusion est opérée jusqu'à ce que les valeurs d'influence convergent (à ϵ près). L'objectif est d'obtenir l'influence du réseau à l'état stationnaire. Cela correspond à l'état stationnaire d'une réaction couplée à de la diffusion. Le tableau 6 montre la succession des valeurs d'influence des nœuds au fil de la diffusion.

Nœud	A	B	C	D
degré 0	0.375	0.125	0.375	0.125
degré 1	0.4375	0.1875	0.1875	0.1875
degré 2	0.40625	0.21875	0.28125	0.09375
...	...	...	...	...
degré N	$0.444(\frac{4}{9})$	$0.222(\frac{2}{9})$	$0.222(\frac{2}{9})$	$0.111(\frac{1}{9})$

Tableau 6 : Tableau des influences des nœuds, du degré 0 jusqu'à N, pour le réseau des figures 56-58.

L'influence stable (de degré N) mesure donc pour chaque nœud la proportion d'influence sur le réseau qu'il détient. Nous souhaitons en tirer une mesure à l'échelle du réseau : la répartition de l'influence RepInf. Elle correspond au nombre minimum de nœuds nécessaires pour cumuler la moitié, donc la majorité, de l'influence du réseau.

Pour obtenir cette valeur, les nœuds sont triés par influence stable décroissante. Puis, en partant du début de cette liste, la proportion de chaque nœud nécessaire pour atteindre parfaitement 50% de l'influence est additionnée. Puisque les nœuds les plus influents sont comptés en premiers, la valeur obtenue est bien le nombre minimum de nœud nécessaire pour obtenir la moitié de l'influence. La figure 59 présente un exemple de cette méthode.




Figure 59 : Répartition de l'influence du réseau des figures 56-58. La moitié de l'influence se situe dans 1.25 nœuds.

La valeur de répartition de l'influence d'un réseau est nécessairement comprise entre 0.5 et $d/2$, comme l'illustre la figure 60. Au minimum, un seul nœud concentre toute l'influence, il suffit alors d'un demi-nœud pour obtenir la majorité de l'influence. Au maximum, les nœuds se répartissent équitablement l'influence et il faut donc exactement la moitié des nœuds pour obtenir la moitié de l'influence.




Figure 60 : Exemples de la répartition de l'influence dans des cas aux bornes. Au minimum, un seul nœud concentre toute l'influence, la valeur de répartition est donc de 0.5. Au maximum la répartition est parfaite, la moitié de l'influence se situe dans la moitié des nœuds donc la valeur de répartition est de $d/2$.

Afin de faciliter la comparaison de cette mesure entre les dimensions ainsi qu'avec la mesure de centralité par chemin d'influence, nous considérons la valeur RepInfN de répartition de l'influence normalisée entre 0 et 1, définie selon formule suivante :

$$\text{RepInfN} = \frac{\text{RepInf} - 0.5}{\frac{d}{2} - 0.5} \quad (15)$$

Dans la figure 59 La valeur de répartition de l'influence du réseau est donc de 0.5 une fois normalisée dans l'intervalle [0; 1].?????

7.1.3 Complexité du comportement

Pour l'étude de la dynamique d'un système biologique, tous les éléments de ce système ne sont pas nécessairement pertinents, observés et observables. Il nous semble donc approprié dans ce contexte d'analyser séparément les comportements de chacun des nœuds d'un réseau afin que nos résultats, établis sur l'ensemble des réseaux possibles, soient plus aisément transposables à des observations réalisées sur des systèmes biologiques concrets.

Le comportement d'un nœud, comme défini dans la section 2.3.3.3, correspond à la suite binaire formée par la succession des états traversés par le nœud lorsque l'état du réseau se situe dans un attracteur donné (la dynamique d'un réseau pouvant présenter plusieurs attracteurs, un même nœud peut présenter plusieurs comportements différents selon l'attracteur dans lequel se situe l'état du réseau). Dans la suite de cette section, le comportement d'un nœud est désigné sous le terme de *musique*, comme si le nœud jouait une musique binaire dont les notes sont les différents états qu'il traverse.

Nous rapportons la complexité d'un comportement à la complexité de Kolmogorov [19] de la séquence binaire représentant une musique. Cette mesure correspond à trouver la taille du plus petit programme capable de générer la chaîne de caractères considérée. Cependant, la complexité de Kolmogorov est difficile à évaluer pour les courtes chaînes de caractères telles que les musiques des nœuds. En effet, la longueur maximum que peut atteindre une musique est de $2^d - 1$ *, soit 7 en dimension 3, 15 en dimension 4 etc .

Nous utilisons donc la méthode CTM-BDM (*Coding Theorem Method* et *Block Decomposition Method*) [20] [21] qui permet d'obtenir une limite haute de la complexité de Kolmogorov pour des courtes chaînes de caractères. La méthode CTM consiste à énumérer l'ensemble des machines de Turing de dimension 5 puis à les simuler pour compter combien d'entre-elles produisent telle ou telle chaîne de caractères. La méthode BDM consiste à trouver pour une chaîne de caractères l'ensemble des sous-blocs de caractères qui la compose, puis à évaluer la complexité de chacun des sous-blocs à l'aide de l'évaluation fournie par la méthode CTM. Enfin les complexités de ces blocs sont combinées pour obtenir la complexité de la chaîne de caractères initiale. La formule de la complexité calculée avec la méthode CTM-BDM est la suivante :

$$\text{BDM}(s) = \sum_{b \in B(s)} (\text{CTM}(b) + \log_2(n(b))) \quad (16)$$

Où s est la séquence évaluée, $B(s)$ est l'ensemble des sous-blocs de s , $\text{CTM}(b)$ est la complexité du sous-bloc b et $n(b)$ est le nombre d'occurrences de b dans s .

Une musique est notée de la manière suivante : 10011^* pour représenter que 10011 est un motif qui se répète dans le temps. Cependant, puisque 10011^* dénote un cycle, elle est équivalente à 00111^* , 01110^* , 11100^* ou 11001^* . Lorsque la dynamique d'un réseau est évaluée, il n'existe pas un point de départ en particulier. Il n'est pas possible de se contenter d'en choisir un au hasard, puisque cela risque de biaiser l'évaluation de la suite binaire par la méthode BDM : les sous-blocs ne seraient pas les mêmes entre les cinq motifs. Il est cependant nécessaire de commencer quelque part, ne serait-ce que pour stocker la suite en mémoire.

[19] KOLMOGOROV « Three approaches to the quantitative definition of information » (1968)

* : -1 parce que les RBS présentent systématiquement un point fixe sur l'état 0^d (voir section 2.3.3.1).

[20] SOLER-TOSCANO et al. « Calculating Kolmogorov Complexity from the Output Frequency Distributions of Small Turing Machines » (2014)

[21] ZENIL et al. « A Decomposition Method for Global Evaluation of Shannon Entropy and Local Estimations of Algorithmic Complexity » (2018)

Pour palier à ce problème, la séquence s est répétée, telle que $s^2 = s + s$. s^2 est utilisée pour la décomposition en sous-blocs. L'ensemble des sous-blocs $B(s)$ d'une séquence s de longueur n est alors définie de la manière suivante :

$$B(s) = \bigcup_{i=1}^n \left(\bigcup_{j=0}^{n-1} s_{[j;j+i[}^2 \right) \quad (17) \quad \bigcup \text{ désignant ici l'union successive des ensembles.}$$

La figure 61 présente un exemple de cette décomposition pour $s = 10011$.




Figure 61 : Décomposition en sous-blocs de la musique 10011*. Le motif 10011 est répété pour éviter les effets aux bords. Les sous-blocs recherchés sont tous les blocs de la taille 1 à la taille de la longueur de la musique, ici 5.

7.2 RÉSULTATS

Nous avons exploré exhaustivement toutes les classes d'équivalence de RBS de dimension 3. En dimension 4, nous en avons échantillonné 1 %.

Les résultats contiennent les mesures suivantes pour chaque musique de chaque nœud de chaque RBS :

- La centralité par chemins d'influence.
- La répartition de l'influence.
- La rareté moyenne des FBS du RBS.
- La complexité du comportement selon la méthode CTM-BDM.
- L'arité : la moyenne du nombre d'arcs entrants sur chaque nœud.
- Le nombre d'attracteurs dans le graphe de transition.
- La taille du bassin d'attraction de l'attracteur à l'origine de la musique.
- La robustesse de l'attracteur : le nombre d'états dans le bassin d'attraction, mais pas dans l'attracteur lui-même.

Les résultats sont présentés sous la forme d'histogrammes 2D tels que ceux de la figure 62. Un tuple de résultat correspond à la musique produit par un nœud pour un attracteur donné. Les musiques liées aux points fixes sur l'état $\langle 0, \dots, 0 \rangle_E$, commun à tous les RBS, ne sont pas incluses.




Figure 62 : Explication des histogrammes 2D utilisés pour présenter les résultats. Ces histogrammes permettent de croiser trois mesures différentes. Deux mesures forment les axes et la troisième est présentée sous la forme d'une moyenne pour chacune des classes de l'histogramme. Les valeurs de ces moyennes sont données par la couleur des points et l'échelle de couleurs dans la légende. La taille des points indique le nombre de musiques observées dans chaque classe. En bas à droite se trouvent les histogrammes des moyennes et des écarts-types (SD), ils permettent d'estimer l'ampleur des variations de la troisième mesure au sein de chaque classe.

Il est important pour l'analyse de ces histogrammes de garder à l'esprit les points suivants :

- Les couleurs indiquent des valeurs moyennes et peuvent donc dissimuler beaucoup de diversité de réseaux. Les histogrammes des moyennes et des écarts-types, en bas à droite de chaque histogramme 2D, permettent d'évaluer cette diversité.

Exemple : Si l'histogramme des écarts-types ne présente qu'un seul pic proche de zéro, alors tous les réseaux possèdent une valeur de la mesure très proche de la moyenne indiquée par la couleur du point. Dans le cas contraire, la moyenne peut cacher des valeurs très dispersées et il est plus difficile de tirer des conclusions solides.

- En dimension 4, nous considérons un échantillonnage, il faut donc interpréter avec prudence les observations sur les catégories à faible effectif. De plus, des cas rares peuvent ne pas être représentés, une absence de points ne signifie donc pas toujours qu'il n'existe aucun réseau dans la classe de l'histogramme considérée.

Exemple : Ce n'est que dans le dernier échantillonnage sur des dizaines effectués en dimension 4 que pour la première fois, nous avons obtenus une musique de taille 13.

7.2.1 Arité

Il n'est pas possible d'étudier de la même manière que les autres mesures les liens entre l'arité et la dynamique d'un réseau, c'est-à-dire les caractéristiques des graphes de transition : complexité dynamique, nombre d'attracteurs *etc* ... En effet, les différentes valeurs d'arité ont pour origine l'introduction des FBS projetées (les FBS des dimensions inférieures) lors de l'énumération des RBS (cf. section 3.3). Or, ces FBS projetées partagent toutes leur table de vérité avec une des FBS innées. En conséquence, tous les RBS incluant des FBS projetées ont un graphe de transition identique à celui d'un autre RBS composé uniquement de FBS innées. L'utilisation des FBS projetées n'introduit donc pas de nouveaux graphes de transition, de nouvelles dynamiques. Il n'est donc pas possible de dire que telle caractéristique de la dynamique est contrainte par telle valeur d'arité. Il est par contre possible d'observer si les différents types de dynamique sont également réalisables par des RBS d'arité faible.

7.2.1.1 Comportements complexes et arité

Les comportements les plus complexes ne semblent pas pouvoir être obtenues avec des RBS d'arité moyenne faible. Les figures 63 et 64 montrent en A que les RBS avec les comportements les plus complexes présentent tous une forte arité moyenne si ce n'est une arité moyenne maximale, en dimension 3 comme en dimension 4.

Cependant, si les comportements complexes semblent impliquer une forte arité moyenne, l'inverse n'est pas vrai : la figure 63 permet d'observer en B que des RBS de forte arité moyenne sont observables pour toutes les valeurs de complexités de comportement.

Une explication possible de la forte arité moyenne des RBS de haute complexité dynamique est que les comportements les plus complexes sont réalisables seulement avec des FBS apparues avec la dimension courante : des FBS auxquelles il n'est donc pas possible de retirer un poids, tel que nous le faisons avec les FBS projetées dont au moins un des poids vaut zéro. Les comportements les plus complexes sont aussi les plus longs (produits par un grand attracteur). Ils ne sont donc pas réalisables par des RBS de dimension inférieure puisque ces derniers ne disposent pas de suffisamment d'états. L'information nouvelle ici est que ce n'est pas uniquement grâce aux états supplémentaires disponibles que les nouveaux comportements complexes deviennent réalisables, mais également grâce aux nouvelles FBS qu'il est possible d'obtenir avec l'ajout d'une dimension. Dans le cas contraire, il serait possible d'observer des comportements complexes avec de faibles valeurs d'arité. Ces comportements complexes nécessitent donc pour être obtenus d'exploiter tout le potentiel structurel accessible dans la dimension.




Figure 63 : Histogrammes 2D en dimension 3 en haut et 4 en bas de la **complexité du comportement** et de la **rareté des fonctions**, colorés selon l'**arité moyenne**. Les RBS énumérés incluent les FBS projetées et innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.

7.2.1.2 Multi-attractorité et arité

L'arité ne semble pas affecter la multi-attractorité des RBS.

En observant la figure 64, il serait tentant, en regardant les points en B, d'en tirer que les RBS ayant le plus grand nombre d'attracteurs possèdent l'arité moyenne la plus faible. Il faut cependant rappeler qu'il n'existe pas de graphes de transition qui n'apparaissent qu'avec une arité moyenne faible. Il existe donc nécessairement des RBS d'arité moyenne maximale présentant eux-aussi des graphes de transition avec un grand nombre d'attracteurs.

Il est effectivement possible de le vérifier en s'attardant sur la valeur minimale d'arité moyenne présente dans l'histogramme de dimension 3 en C. Cette dernière vaut 2 tandis que le minimum global de l'arité moyenne est de 0,667 (cf. tableau 7).

Les RBS de 8 attracteurs en dimension 3 sont donc aussi bien des réseaux d'arité moyenne faible que des réseaux d'arité moyenne forte dont la moyenne vaut 2, comme il est possible de le constater en consultant les données brutes correspondantes.

Remarque : L'histogramme de dimension 4 étant issu d'un échantillonnage, il n'est pas possible de vérifier les données brutes de la même manière puisque rien ne garantit que tous les RBS de dimension 4 qui appartiendraient à cette classe de l'histogramme aient été analysés.

Une multi-attractorité forte implique nécessairement des petits attracteurs, de faible complexité dynamique. Ces derniers n'exigent donc pas nécessairement des fonctions de la dimension courante comme les comportements complexes. Il semble ainsi cohérent que la multi-attractorité ne soit pas affectée par les variations d'arité.

	Cpx. Réseau	Rareté	RI	Arité
Minimum	0.0	0.670303	0.0	0.667
Maximum	0.999987	0.999974	1.0	3.0
Moyenne	0.210392	0.835598	0.562943	2.45814
Variance	0.012451	0.006897	0.080077	0.166855
Écart-type	0.111584	0.083048	0.282979	0.408479
	Nb. A	Cpx. Comp.	Taille A	Taille BA
Minimum	2.0	2.514277	1.0	1.0
Maximum	8.0	267.746661	6.0	7.0
Moyenne	3.028105	6.31997	1.359365	3.590327
Variance	1.116252	114.095758	0.377065	4.231316
Écart-type	1.056528	10.681562	0.614056	2.057016

Tableau 7 : Résumé des différentes mesures effectuées lors de l'énumération de tous les RBS de dimension 3 incluant les FBS projetées.




Figure 64 : Histogrammes 2D en dimension 3 en haut et 4 en bas de la **complexité du comportement** et du **nombre d'attracteurs**, colorés selon l'**arité moyenne**. Les RBS énumérés incluent les FBS projetées et innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.

7.2.1.3 Impact de l'arité sur la rareté et la répartition de l'influence

Les histogrammes de la figure 65 permettent d'observer que les fonctions les plus rares ne sont possibles qu'avec une faible arité, tandis que les fonctions les plus courantes sont présentes dans les RBS d'arité maximale. Cela est lié à la manière dont est mesurée la rareté des fonctions. Une arité faible indique que la plupart des FBS sont projetées, elles sont donc mesurées comme étant particulièrement rares (cf. section 7.1.1.2). Cela se retrouve dans le corrélogramme de la figure 67 : l'arité est presque totalement inversement corrélée à la rareté.




Figure 65 : Histogrammes 2D en dimension 3 en haut et 4 en bas de l'arité et de la rareté des fonctions, colorés selon la répartition moyenne de l'influence. Les RBS énumérés incluent les FBS projetées et innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.

L'histogramme de la figure 66 montre que la répartition de l'influence est globalement plus élevée avec une arité forte et à l'inverse qu'une arité faible semble la limiter. Cette tendance se retrouve également dans le corrélogramme de la figure 67.




Figure 66 : Histogrammes 2D en dimension 3 en haut et 4 en bas de l'arité et de la répartition de l'influence, colorés selon la rareté moyenne des FBS. Les RBS énumérés incluent les FBS projetées et innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.

L'influence de l'arité sur les mesures de rareté et de répartition de l'influence est très importante. Il est donc très difficile de tirer des conclusions sur l'impact de ces deux dernières sur d'autres aspects des RBS. **Afin de pouvoir les étudier sans avoir à se soucier de l'influence de l'arité, tous les résultats de ce chapitre présentés à partir de la section 7.2.3** sont issus de l'énumération des RBS composés seulement des FBS innées.




Figure 67 : Corrélogramme des mesures effectuées en dimension 3 sur les RBS incluant les FBS projetées et innées. Au croisement de deux mesures, la taille et l'intensité de la couleur du point indique la force de la corrélation et la couleur, bleue ou rouge, indique respectivement si cette corrélation est positive ou négative. Toutes les p-values sont au moins inférieures à 10^{-6} à l'exception de la corrélation entre l'arité et le nombre d'attracteurs (2.43×10^{-3}).

7.2.2 Centralité par chemins d'influence

[4] SEGRETAİN et al. « Who Plays Complex Music? On the Correlations Between Structural and Behavioral Complexity Measures in Sign Boolean Networks » (2021)

Après avoir publié la première version de ces résultats [4], il s'est avéré que les calculs de la centralité par chemins d'influence souffraient d'une erreur d'implémentation. La correction de cette dernière révèle que le défaut de cette mesure (cf. remarque à la fin de la section 7.1.2.1) est en réalité plus important qu'escompté et que quasiment tous les RBS saturent à 1. Une correction devrait être soumise à bioRxiv.

L'histogramme de la figure 68 présente les résultats de cette centralité croisée avec l'arité. Il est possible d'observer que la très grande majorité des RBS présente une centralité de 1. L'échelle de taille des points est logarithmique, les petits points, bien que plus nombreux, ne représentent qu'une petite fraction des RBS. De plus, les seuls cas où la valeur de centralité est inférieure à 1 sont ceux où l'arité n'est pas maximale. Les RBS n'incluant que des FBS innées ne présentent donc aucune diversité de centralité.

La centralité par chemin d'influence ne peut donc pas être directement utilisée pour analyser les RBS. Cependant, le principe sur lequel elle se base (influence des arcs selon leurs poids) n'est pas perdu, puisque c'est également celui qu'exploite la mesure de répartition de l'influence. C'est donc cette dernière uniquement que nous utilisons dans les résultats qui suivent pour qualifier la complexité des arrangements des RBS.




Figure 68 : Histogrammes 2D en dimension 3 en haut et 4 en bas de l'arité et de la centralité par chemins, colorés selon la rareté moyenne des FBS. Les RBS énumérés incluent les FBS projetées et innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1‰ des RBS.

Note : À partir de ce point, tous les résultats présentés dans ce chapitre sont issus de l'énumération des RBS n'incluant que les FBS innées. Cela permet de ne pas se soucier de l'influence de l'arité sur la rareté et la répartition de l'influence.

7.2.3 Rareté et répartition de l'influence

La rareté et la répartition de l'influence sont peu corrélées. Le corrélogramme de la figure 70 l'indique clairement : la corrélation est de -0.075 . Les histogrammes de la figure 69 suggèrent tout au plus, en examinant les zones A sans points, que les faibles valeurs de répartition d'influence ne sont pas compatibles avec les valeurs extrêmes de rareté.

Le fait que ces deux mesures soient dissociées est un point positif puisqu'elles ont pour but de mesurer deux aspects différents de la structure des RBS : la complexité des composants pour la rareté et la complexité de l'assemblage pour la répartition de l'influence. Dans le cas contraire, il serait difficile d'analyser les rôles distincts de l'un et de l'autre sur les comportements des RBS.




Figure 69 : Histogrammes 2D en dimension 3 en haut et 4 en bas de la **rareté des FBS** et de la **répartition de l'influence**, colorés selon la **taille moyenne des attracteurs**. Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.




Figure 70 : Corrélogramme des mesures effectuées en dimension 3 sur les RBS n'incluant que les FBS innées. Au croisement de deux mesures, la taille et l'intensité de la couleur du point indique la force de la corrélation et la couleur, bleue ou rouge, indique respectivement si cette corrélation est positive ou négative. Toutes les p-values sont au moins inférieures à 10^{-6} à l'exception des corrélations entre la répartition d'influence et le nombre d'attracteurs : 2.25×10^{-5} pour une corrélation de 0.028 ; ainsi qu'entre cette première et la taille du bassin d'attraction : 1.02×10^{-2} pour une corrélation de -0.0167 .

7.2.4 Complexité dynamique

7.2.4.1 *Complexité dynamique et taille de l'attracteur*

La complexité d'un comportement est presque entièrement déterminée par la taille de l'attracteur qui le produit. La corrélation entre les deux est de 0.986 (fig. 70).

Cela est parfaitement visible dans les histogrammes de la figure 71 (également dans les figures 72 et 73) où toutes les classes d'un même taille d'attracteur partagent la même complexité dynamique. Ainsi, la taille de l'attracteur et la complexité dynamique partagent les mêmes relations avec les autres mesures.

7.2.4.2 *Complexité dynamique et taille du bassin d'attraction*

La taille d'un bassin d'attraction mesure le nombre d'états qui forment l'attracteur ainsi que ceux qui y mènent. Par définition, un bassin d'attraction est donc au moins aussi grand que l'attracteur qu'il contient. Ce dernier définit donc la taille minimum du bassin.

Les histogrammes de la figure 71 illustrent cela par le triangle que forment les points. La taille de ces derniers permet également d'observer que c'est bien seulement le minimum du bassin d'attraction qui est fixé : il existe aussi bien des grands bassins d'attraction contenant un petit attracteur que contenant un grand attracteur. Ainsi la corrélation entre la complexité dynamique et la taille du bassin d'attraction n'est pas aussi forte qu'avec la taille de l'attracteur : 0.392 (fig. 70).




Figure 71 : Histogrammes 2D en dimension 3 en haut et 4 en bas de la **taille de l'attracteur** et de la **taille du bassin d'attraction**, colorés selon la **complexité moyenne des comportements**. Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.

7.2.4.3 Complexité dynamique et répartition de l'influence

La corrélation entre la complexité dynamique et la répartition de l'influence est faible : 0.0774 (fig. 70). Les histogrammes de la figure 72 montrent néanmoins que plus la complexité dynamique augmente, plus le minimum de répartition d'influence est élevé : il n'y a pas de point sous les courbes A. Par exemple en dimension 4, il faut au moins 0.6 de répartition d'influence pour un comportement de complexité 1000.

Autre observation, dans les zones B, les comportements les plus complexes ne sont jamais trouvés dans des RBS de répartition d'influence maximale.




Figure 72 : Histogrammes 2D en dimension 3 en haut et 4 en bas de la **complexité du comportement** et de la **répartition de l'influence**, colorés selon la **taille moyenne des attracteurs**. Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.

7.2.4.4 Complexité dynamique et rareté

Les liens entre la complexité dynamique et la rareté sont semblables à ceux entre cette première et la répartition d'influence. La corrélation est de même ordre : 0.104 (fig. 70); et plus la complexité dynamique croît, plus le minimum de rareté est grand (nettement plus visible en dimension 4) : il n'y a pas de point sous les lignes A.

Il est de même possible d'observer dans l'histogramme de dimension 4 de la figure 73 un plafonnement de la rareté, il n'y a pas de points au-dessus de la ligne B : les comportements les plus complexes n'apparaissent pas avec les fonctions les plus rares. Cependant, cela peut être dû à l'échantillonnage, puisque ce phénomène n'apparaît pas dans l'histogramme de dimension 3.




Figure 73 : Histogrammes 2D en dimension 3 en haut et 4 en bas de la **complexité du comportement** et de la **rareté des FBS**, colorés selon la **taille moyenne des attracteurs**. Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.

7.2.5 Multi-attractivité

La multi-attractivité caractérise la capacité d'un RBS à produire plusieurs comportements différents, donc à présenter plusieurs attracteurs dans son graphe de transition. Cette section présente les différents liens observés entre le nombre d'attracteurs et les autres mesures.

7.2.5.1 Multi-attractivité et répartition de l'influence

Le corrélogramme de la figure 70 indique une très faible corrélation de la multi-attractivité avec la répartition de l'influence : 0.028. Cependant, les histogrammes de la figure 74 suggèrent par l'absence de point au-dessus des courbes A qu'il existe un lien entre le nombre d'attracteurs et le minimum de répartition d'influence : plus le nombre d'attracteurs est grand et plus le minimum de la répartition d'influence augmente.




Figure 74 : Histogrammes 2D en dimension 3 en haut et 4 en bas de la **répartition de l'influence** et du **nombre d'attracteurs**, colorés selon la **taille moyenne des attracteurs**. Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.

7.2.5.2 Multi-attractorité et rareté

Il existe une petite corrélation entre la rareté et la multi-attractorité : 0.173 (fig. 70). Les histogrammes de la figure 75 montrent par l'absence de point au-dessus des courbes A, tout comme pour la répartition de l'influence, que la multi-attractorité semble liée au minimum de la rareté. En dimension 3, à partir de 6 attracteurs, il n'y a plus de RBS de rareté minimale, la rareté la plus basse atteinte est de 0.68, puis de 0.72 pour 7 attracteurs et 0.77 pour 8 attracteurs. En dimension 4, le même constat peut être observé à partir 6 attracteurs. Il faut toutefois garder en tête que les résultats en dimension 4 sont issu d'un échantillonnage, certaines classes de cet histogramme qui semblent vides contiennent peut-être des RBS qui n'ont pas été énumérés.




Figure 75 : Histogrammes 2D en dimension 3 en haut et 4 en bas de la **rareté** des FBS et du **nombre d'attracteurs**, colorés selon la **répartition moyenne de l'influence**. Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.

7.2.5.3 Multi-attractorité et complexité dynamique

La complexité d'un comportement est majoritairement liée à la taille de l'attracteur. Puisque le nombre d'états d'un RBS est limité, il est logique que la multi-attractorité soit inversement corrélée avec la complexité dynamique, la taille de l'attracteur, la taille du bassin d'attraction et la robustesse (fig. 70). Les histogrammes des figures 76 et 77 illustrent clairement que plus le graphe de transition d'un RBS contient d'attracteurs, plus ces derniers sont petits ainsi que leurs bassins d'attraction et moins les comportements qu'ils produisent peuvent être complexes.




Figure 76 : Histogrammes 2D en dimension 3 en haut et 4 en bas de la **complexité du comportement** et du **nombre d'attracteurs**, colorés selon la **taille moyenne des attracteurs**. Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.




Figure 77 : Histogrammes 2D en dimension 3 en haut et 4 en bas de la **taille de l'attracteur** et de la **taille du bassin d'attraction**, colorés selon le **nombre moyen d'attracteurs**. Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.

7.2.6 Robustesse

La robustesse est définie ici comme étant le nombre d'états d'un bassin d'attraction qui ne font pas partie de l'attracteur. C'est une robustesse aux erreurs de dynamique. Si l'état d'un RBS est perturbé, plus le comportement est robuste selon cette définition et plus il y a de chance que l'état atteint à cause de l'erreur reste dans le même bassin d'attraction. Le RBS retournera à terme dans l'un des états du comportement interrompu par l'erreur.

Cette définition de la robustesse est basique, ces résultats n'étant initialement pas pensés afin d'étudier cet aspect. Elle ne considère par exemple pas du tout le cas d'un attracteur occupant l'ensemble des états du graphe de transition. Un tel comportement est très robuste aux erreurs dynamiques : l'erreur ne fera pas quitter le bassin d'attraction ; cependant cette définition lui prête une robustesse nulle. De plus, l'hypothèse est faite que ne pas quitter le bassin de l'attracteur est suffisant. Il est pourtant possible que même si l'organisme représenté par le RBS reste dans le même comportement, l'erreur de dynamique lui fasse atteindre un point du comportement inadapté à son contexte de viabilité.

7.2.6.1 Robustesse, taille du bassin d'attraction et nombre d'attracteurs

La robustesse compte le nombre d'états qui mènent à un attracteur sans en faire partie. De par cette définition, il est logique que la robustesse soit positivement corrélée avec la taille du bassin d'attraction (0.952) et négativement corrélée avec le nombre d'attracteurs (−0.613) (fig. 70). Respectivement, car plus le bassin d'attraction est grand et plus il peut contenir d'états hors attracteurs et parce que plus il y a d'attracteurs dans le graphe de transition et moins il y a d'états "disponibles" pour former des grands bassins d'attraction.

Les histogrammes de la figure 78 illustrent très bien ces corrélations.




Figure 78 : Histogrammes 2D en dimension 3 en haut et 4 en bas de la **taille du bassin d'attraction** et du **nombre d'attracteurs**, colorés selon la **robustesse moyenne**. Obtenu par un échantillonnage de 1% des RBS de la dimension 4 n'incluant que les FBS innées.

7.2.6.2 Robustesse et répartition de l'influence

Il ne semble pas exister de lien entre la répartition de l'influence et la robustesse ou avec la taille des bassins d'attraction.

La corrélation entre cette première et la robustesse est de -0.0585 (fig. 70). L'histogramme de la figure 79 l'illustre : les RBS se répartissent de manière semblable sur les différentes valeurs de répartition d'influence quelle que soit la valeur de robustesse.

Dans les histogrammes de la figure 80, pour une même complexité dynamique, il n'y a pas de variation de la taille des bassins d'attraction au fil de la variation de la répartition d'influence. La corrélation calculée entre ces deux mesures est de -0.0167 (fig. 70).




Figure 79 : Histogramme 2D en dimension 4 de la **robustesse** et de la **répartition de l'influence**, colorés selon la **rareté moyenne des FBS**. Obtenu par un échantillonnage de 1% des RBS de la dimension 4 n'incluant que les FBS innées.




Figure 80 : Histogrammes 2D en dimension 3 en haut et 4 en bas de la **complexité du comportement** et de la **répartition de l'influence**, colorés selon la **taille moyenne des bassins d'attraction**. Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.

7.2.6.3 Robustesse et rareté

La robustesse est légèrement négativement corrélée avec la rareté : -0.159 (fig. 70). L'histogramme de la figure 79 permet effectivement d'observer que plus la robustesse augmente et plus la rareté diminue.

Cette corrélation se retrouve aussi avec la taille des bassins d'attraction : -0.119 (fig. 70). Cependant, les histogrammes de la figure 81 en zones A montrent que cette corrélation concerne surtout les petits attracteurs.




Figure 81 : Histogrammes 2D en dimension 3 en haut et 4 en bas de la **complexité du comportement** et de la **rareté des FBS**, colorés selon la **taille moyenne des bassins d'attraction**. Les RBS énumérés n'incluent que des FBS innées. L'histogramme de dimension 4 est le résultat d'un échantillonnage de 1% des RBS.

7.3 SYNTHÈSE DES RÉSULTATS

La centralité par chemins d'influence n'est pas adaptée, elle sature à 1 pour tous les RBS (section 7.2.2). La mesure de la répartition d'influence, fondée sur le même principe, est utilisée à la place pour qualifier la complexité des arrangements.

L'arité impacte les deux mesures de complexité structurelle : la répartition d'influence et la rareté (section 7.2.1.3). Afin d'étudier les liens entre ces deux mesures et les différents types de comportement, il est nécessaire de ne pas inclure dans l'énumération des RBS les FBS projetées responsables des variations d'arité.

Les deux mesures de la complexité structurelle ne sont pas liées entre elles (section 7.2.3). Cela permet d'étudier séparément leurs contributions aux différents types de comportement présentés en introduction de ce chapitre : complexes, multiples, robustes.

7.3.1 Comportements complexes

Les comportements les plus complexes n'apparaissent qu'en exploitant toute la connectivité offerte par la dimension courante : l'arité ne peut être faible. Ils nécessitent également d'exploiter toutes les dynamiques que les FBS de la dimension de travail peuvent explorer (section 7.2.1.1).

Seuls les RBS possédant au minimum des niveaux élevés de répartition d'influence et de rareté des FBS présentent les comportements les plus complexes (sections 7.2.4.3 et 7.2.4.4).

7.3.2 Multi-attractorité

Les mêmes critères se retrouvent pour la multi-attractorité : elle requiert des niveaux minimums de répartition d'influence et de rareté (sections 7.2.5.1 et 7.2.5.2). Il est important de rappeler que si les comportements complexes ou multiples nécessitent une forte répartition d'influence et des FBS rares, cela n'est pas vrai dans l'autre sens. Un RBS avec de telles caractéristiques ne présentera pas nécessairement des comportements complexes ou de la multi-attractorité.

Contrairement aux comportements complexes, une arité faible n'empêche pas la multi-attractorité (section 7.2.1.2).

7.3.3 Robustesse

La robustesse telle que définie ici n'est que faiblement corrélée aux mesures de complexité structurelles. Seul la rareté des fonctions semble l'influer négativement et uniquement dans le cas de petits comportements (section 7.2.6). *cependant cette mesure de robustesse n'est pas dingue*

ÉTUDIER L'ÉVOLUTION DES SYSTÈMES BIOLOGIQUES

L'une des grandes questions en biologie est celle de l'évolution : comment un système biologique a-t-il évolué en un autre ? Quelles sont les formes intermédiaires qu'il a adopté dans sa lignée ? Quelles évolutions sont possibles et lesquelles ne le sont pas ? Quels mécanismes fondamentaux la contraignent ?

Un système, surtout s'il est complexe, ne peut évoluer trop brusquement. Un ajout aveugle peut modifier l'ensemble de son fonctionnement, brisant alors la précieuse fonction biologique qui le maintient en vie. L'évolution ne peut donc se faire le plus souvent que petit à petit [22] : un système ne peut faire table rase de ce qu'il est pour se réinventer complètement de façon systématique.

[22] PAGEL, O'DONOVAN et MEADE « General statistical model shows that macroevolutionary patterns and processes are consistent with Darwinian gradualism » (2022)

Les questions qui se posent alors sont les suivantes :

- Comment est-ce que les systèmes biologiques parviennent à rester à la fois viables, robustes et évolutifs face aux perturbations et aux mutations ? Comment sont-ils donc capables de modifier les structures qui les composent et par conséquent les dynamiques associées, pour suivre les contraintes de viabilité de leurs environnements, qui elles aussi évoluent avec le temps ?
- Retrouve-t-on une structure, des motifs, des stratégies, communes aux différents réseaux qui parviennent à évoluer ?

Ce chapitre présente les méthodes que nous avons développées pour étudier l'évolution des RBS. Dans ce contexte de réflexions autour de l'évolution, les RBS sont un bon objet théorique pour représenter à la fois la structure de systèmes biologiques (des ribosomes par exemple) et leur dynamique associée (leur fonction biologique), trop complexes à étudier directement.

Une première partie présente la manière dont nous comparons des réseaux et comment cela nous permet d'étudier leur robustesse et leur évolutivité. Ces travaux ont été réalisés par deux étudiants stagiaires que j'ai co-encadré : Rémy Défossez en 2021 alors en L3 à l'ENS Paris, puis Ai-Ling Nguyen Bonnet en 2022-23, en M1 à Centrale Supélec Paris (stage long de césure : 6 mois).

La seconde partie présente ensuite notre étude d'un type précis d'évolution : l'extension, soit la capacité des RBS à être étendus en structure vers la dimension supérieure tout en conservant à la fois leur structure initiale et leur dynamique.

8.1 FORMALISER L'ÉVOLUTION

Note : Cette section présente les travaux menés par Rémy Défossez lors de son stage encadré par Nicolas Glade, Sergiu Ivanov et moi-même.

Pour injecter les concepts évolutifs dans le modèle des RBS, il est nécessaire d'établir une sélection de notions décrivant le processus évolutif. Ce travail se concentre sur trois notions : la *robustesse*, l'*évolutivité* et la *viabilité*. La robustesse est ici la résistance d'un système aux mutations, ce qui est important pour une lignée afin de ne pas s'éteindre toute seule. L'évolutivité est la capacité d'un système à changer de dynamique en un minimum de mutations, ce qui est une qualité nécessaire pour s'adapter à un environnement changeant. La viabilité est la contrainte exercée par l'environnement physico-chimique (en particulier, mais éventuellement aussi social) sur les systèmes.

8.1.1 Robustesse et évolutivité

La capacité d'un système à évoluer dépend de deux qualités : il faut qu'il soit suffisamment stable au cours de sa lignée pour que celle-ci puisse survivre, mais il doit également être capable de s'adapter rapidement aux modifications de son environnement ou d'améliorer sa propre capacité de survie. Ces deux qualités, robustesse et évolutivité, sont nécessaires à la survie à long terme du système, que celui-ci représente le réseau génétique d'une cellule ou un écosystème. Même si ces deux qualités semblent *a priori* antagonistes, il a été montré qu'elles peuvent être réconciliées [23]. Ce sont donc ces deux concepts que nous utiliserons pour qualifier le rapport d'un système à l'évolution.

[23] WAGNER « Robustness and evolvability : a paradox resolved » (2007)

Les définitions communément acceptées de la robustesse et de l'évolutivité en biologie théorique sont les suivantes :

- Un système biologique est dit robuste si sa dynamique est conservée après une mutation dans sa structure.
- Un système biologique est dit évolutif si des mutations de sa structure peuvent induire une grande diversité de dynamiques.

Il est entendu ici que la structure d'un système biologique correspond à la matrice d'interaction de nos RBS et que la dynamique, la fonction biologique, correspond au graphe de transition. En revanche, il n'est pas nécessairement évident de comprendre ce qu'est formellement une mutation et ce que signifie « conserver la dynamique ». Ces deux notions demandent de pouvoir comparer des RBS, il est donc nécessaire de définir des distances sur l'espace des réseaux.

8.1.2 Définition des distances

8.1.2.1 Distance structurelle de Hamming

La structure d'un RBS est entièrement contenue dans sa matrice de poids. La manière la plus simple de mesurer la distance structurelle entre deux réseaux est de calculer la distance de Hamming entre leurs matrices de poids puisque ces dernières définissent leurs structures. Cela correspond à comparer les valeurs absolues des poids deux à deux et de faire la somme de leurs différences.

Pour deux réseaux R et R' de dimension d , la distance structurelle de Hamming $HSTR(R, R')$, illustrée par la figure 82, est définie par la formule suivante :

$$HSTR(R, R') = \sum_{i=1}^d \sum_{j=1}^d |\text{Arc}_{ij} - \text{Arc}'_{ij}| \quad (18)$$




Figure 82 : Exemple de calcul de la distance structurelle de Hamming entre deux RBS de dimension 2. Les poids colorés diffèrent entre R et R' , la somme de ces différences donne la distance structurelle de Hamming entre les deux réseaux.

La valeur ainsi obtenue indique le nombre de mutations sur les valeurs des poids qui serait nécessaire pour passer d'un réseau à l'autre, avec le postulat qu'une mutation correspond à incrémenter ou décrémenter un poids de 1.

8.1.2.2 Distance structurelle sur les chemins

La distance structurelle de Hamming ne fait aucune distinction entre les arcs, ils sont tous traités de la même manière. Pourtant, certains arcs peuvent être plus importants que d'autres au regard de la connectivité du réseau. La modification de la valeur d'un poids impacte différemment le réseau selon l'arc dont le poids est modifié.

Nous proposons donc une seconde mesure de distance structurelle, prenant en compte l'importance des arcs. Afin de définir cette dernière, nous fixons les deux critères suivants, illustrés dans la figure 83, pour comparer deux à deux les arcs de deux réseaux de même dimension :

- Si les deux arcs portent des poids équivalents, le plus important est celui le plus impliqué dans la connectivité de son réseau.
- Si les deux arcs sont également connectés, le plus important est celui dont le poids est le plus élevé en valeur absolue.




Figure 83 : Exemples de l'importance d'un arc dans la connectivité d'un réseau. Les arcs en rouge sont plus importants que les arcs en bleu. Dans R_1 , l'arc rouge est le seul à relier les deux moitiés du réseau, tous les chemins entre les nœuds de gauche et de droite passent donc par cet arc tandis que l'arc bleu ne relie que le nœud D à lui-même. Dans R_2 , les deux arcs colorés ont des positions similaires, mais l'arc rouge ayant un poids plus important, en valeur absolue, les chemins qui l'empruntent ont plus d'influence que ceux qui empruntent l'arc bleu.

Afin d'établir le rôle d'un arc dans la connectivité d'un réseau, nous réutilisons les notions d'influence d'un arc et d'un chemin, introduites avec la mesure de centralité par chemin dans la section 7.1.2.1. La définition de l'influence d'un arc est rappelée ci-dessous :

$$PI(\text{Arc}_{ij}) = \frac{|p_{ij}|}{\sum_{k=1}^d |p_{kj}|} \quad (19)$$

Nous utilisons toutefois dans ce cas une définition différente d'un chemin et de son influence. Un chemin d'un nœud n_i à un nœud n_j ne peut emprunter qu'une seule fois chaque nœud et non pas chaque arc comme précédemment. Les chemins

formant des cycles ne sont pas admis. L'influence d'un chemin est définie comme le produit des influences des arcs qu'il emprunte :

$$PI(\text{Chemin}_{ij}) = \prod_{\text{Arc} \in \text{Chemin}_{ij}} PI(\text{Arc}) \quad (20)$$

Ainsi, lorsque le poids porté par un arc est modifié, l'influence de chaque chemin empruntant cet arc est impactée. La distance entre deux RBS est alors définie comme étant la somme des différences entre les influences des chemins reliant les mêmes nœuds. Tous les RBS ne possédant pas la même structure, si un RBS présente un chemin qui n'existe pas dans l'autre, toute l'influence de ce chemin est ajoutée à la somme. Pour deux réseaux R et R' de dimension d , la distance structurelle sur les chemins $CSTR(R, R')$ est donnée par la formule suivante :

$$\begin{aligned} CSTR(R, R') = & \sum_{C_R \in \text{Chemins}(R) \cap C_{R'} \in \text{Chemins}(R')} |PI(C_R) - PI(C_{R'})| \\ & + \sum_{C_R \in \text{Chemins}(R) \setminus \text{Chemins}(R')} PI(C_R) \\ & + \sum_{C_{R'} \in \text{Chemins}(R') \setminus \text{Chemins}(R)} PI(C_{R'}) \end{aligned} \quad (21)$$

8.1.2.3 Distance dynamique de Hamming

Afin de pouvoir mesurer la distance entre les dynamiques de deux RBS, leurs graphes de transition, il est d'abord nécessaire de pouvoir mesurer la distance entre deux états. La distance de Hamming H entre deux états E et E' de même dimension d mesure le nombre de bits à inverser pour passer de l'un à l'autre, comme l'illustre la figure 84. Elle est définie par la formule suivante :

$$H(E, E') = \sum_{i=1}^d |E_i - E'_i| \quad (22)$$




Figure 84 : Illustration de la distance dynamique de Hamming entre deux états. L'état $\langle 0,0 \rangle_E$ est distant de 1 avec les états $\langle 0,1 \rangle_E$ et $\langle 1,0 \rangle_E$ et de 2 avec l'état $\langle 1,1 \rangle_E$.

La distance dynamique de Hamming $HDYN$ entre deux RBS R et R' de dimension d est la somme des différences entre les états successeurs de chaque état E , donnés par la fonction $\text{Succ}_R(E)$ pour un réseau R . Elle est définie par la formule suivante :

$$HDYN(R, R') = \sum_{E \in \text{Etats}_d} H(\text{Succ}_R(E), \text{Succ}_{R'}(E)) \quad (23)$$

8.1.2.4 Distance dynamique sur les attracteurs

De même que la distance structurelle, la distance dynamique de Hamming présente des inconvénients de par sa simplicité. Elle ne prend pas en compte les attracteurs, alors que ce sont eux qui définissent les comportements que nous étudions. De ce point de vue, cela peut mener à des distances incohérentes, telle que l'illustre la figure 85.




Figure 85 : Exemple de trois graphes de transition différents. GT_1 et GT_2 possèdent les mêmes attracteurs, mais diffèrent sur leurs bassins d'attraction. Pourtant, selon la distance dynamique de Hamming, GT_1 est plus proche de GT_3 qu'il ne l'est de GT_2 .

Nous introduisons donc une seconde mesure de la distance dynamique, fondée sur les attracteurs et les critères suivants :

- Entre deux graphes de transition, une différence sur les attracteurs augmente davantage leur distance qu'une même différence sur les bassins d'attraction.
- Entre deux attracteurs de même taille, modifier celui avec le plus grand bassin d'attraction augmente la distance davantage.

Il est donc nécessaire de pouvoir mesurer la distance entre deux attracteurs. Nous re-utilisons pour cela la distance de Hamming sur les états, afin de comparer deux à deux les états qui composent ces attracteurs. Cependant, un attracteur est un cycle d'état : il n'a pas de début ou de fin. Il faut donc calculer la distance entre deux attracteurs en considérant tous les débuts possibles : la distance minimale sera retenue. La distance D_{Attr} entre deux attracteurs A et B de même taille est définie par la formule suivante :

$$D_{Attr}(A, B) = \min_{1 \leq j \leq |A|} \left(\sum_{i=1}^{|A|} H(A_{i+j}, B_i) \right) \quad (24)$$

Il faut cependant également prendre en compte le cas où un attracteur est plus grand que l'autre. Dans cette situation, nous faisons le choix d'ajouter l'état nul à l'attracteur le plus court, autant de fois que nécessaire pour l'amener à la taille du plus grand attracteur. Cela donne la formule modifiée suivante, pour $|A| > |B|$:

$$D_{Attr}(A, B) = \min_{1 \leq j \leq |A|} \left(\sum_{i=1}^{|B|} H(A_{i+j}, B_i) + \sum_{i=|B|+1}^{|A|} H(A_{i+j}, 0) \right) \quad (25)$$

Finalement, pour établir une mesure entre deux graphes de transition, nous mesurons pour chaque état E , les différences entre les attracteurs auxquels ils mènent éventuellement. Ces attracteurs sont donnés à partir de la fonction $\text{Attr}_R(E)$ pour un réseau R . Cela donne la distance dynamique CYCLE, définie entre deux RBS R et R' de dimension d selon la formule suivante :

$$\text{CYCLE}(R, R') = \sum_{E \in \text{Etats}_d} D_{\text{Attr}}(\text{Attr}_R(E), \text{Attr}_{R'}(E)) \quad (26)$$

Cette distance remplit bien nos deux critères de construction : si seul le bassin d'attraction est modifié, seuls les états déplacés produiront une différence, tandis que si l'attracteur change, tous les états du bassin produiront une différence. En outre, si un attracteur est modifié, le coût de la modification est proportionnel à la taille du bassin d'attraction.

8.2 ROBUSTESSE ET ÉVOLUTIVITÉ : EXPLORATION DU PAYSAGE DES RÉSEAUX

Note : Je présente dans cette section les données et figures par Ai-Ling Nguyen Bonnet lors de son stage encadré par Sergiu Ivanov, Nicolas Glade et moi-même. J'ai assisté Ai-Ling pour la mise au point de la méthode et l'utilisation des outils logiciels requis.

8.2.1 Méthodologie

Nous souhaitons calculer, entre tous les RBS d'une dimension donnée, la distance structurelle et dynamique de Hamming ainsi que la distance dynamique sur les attracteurs.

Remarque : La distance structurelle sur les chemins n'a pas été calculée par manque de temps dans le stage d'Ai-Ling.

La formule suivante donne, à partir du nombre de RBS, le nombre de paires de réseaux dont il faut calculer les distances :

$$\text{NbPaires} = \frac{\text{NbRBS} * (\text{NbRBS} - 1)}{2} \quad (27)$$

En dimension 2, il n'y a que 60 RBS, donc 1770 paires de réseaux, cela ne pose pas de difficultés. En revanche, en dimension 3 il y a 31199 RBS, ce qui donne 486 673 201 paires de réseaux. Il n'est pas possible en JPP de les énumérer en une seule étape sans rencontrer des congestions de la mémoire : nous sommes dans le cas décrit dans la section 6.2.3. Afin de contourner ce problème, puisque JPP traite les tâches avec une priorité en profondeur, il est nécessaire de fragmenter en plusieurs étapes la génération des paires, tel qu'illustré dans la figure 86.

C'est pour cette raison que le schéma de la figure 87 présente deux étapes d'énumération des paires d'indices des RBS. La première ne génère pas directement les paires d'indices, mais des paires de bornes d'indices. C'est la seconde étape qui, à partir des bornes, énumère les paires finales d'indices. La dernière étape récupère alors deux RBS via les indices fournis et peut ensuite en calculer les différentes distances.

Cette méthode de fragmentation de l'énumération des tâches, ici adaptée aux paires de réseaux, peut potentiellement s'appliquer dans d'autres situations pour juguler l'utilisation de la mémoire. Ce qui est un des problèmes à régler pour énumérer tous les réseaux de plus haute dimension ($d > 5$) avec la méthode décrite dans le chapitre 5.




Figure 86 : Schéma de la fragmentation de l'énumération des tâches dans un pipeline JPP. Dans le premier cas, la tâche initiale génère trop de tâches concrètes ce qui saturer la mémoire. Dans le second cas, avec la fragmentation, puisque les tâches des processeurs les plus profonds sont prioritaires, les premières tâches concrètes générées sont exécutées avant que les suivantes ne soient énumérées.




Figure 87 : Schéma du pipeline JPP permettant de calculer les distances entre tous les RBS jusqu'en dimension 3. Pour des dimensions supérieures, le stockage des RBS en mémoire risque de ne pas être possible.

8.2.2 Résultats

8.2.2.1 Corrélations entre distances

Les corrélations entre la distance structurelle et dynamique de Hamming et dynamique sur les attracteurs sont présentées dans le tableau 8.

Corrélation selon d	HSTR & HDYN	HSTR & CYCLE	HDYN & CYCLE
Dimension 2	0.685	0.345	0.643
Dimension 3	0.872	0.328	0.436

Tableau 8 : Tableau des corrélations selon la dimension, entre la distance structurelle de Hamming (HSTR), la distance dynamique de Hamming (HDYN) et la distance dynamique sur les attracteurs (CYCLE). Elles sont toutes très significatives ; la plus haute p-value est de l'ordre de 10^{-50} et toutes les autres sont inférieures à 10^{-200} .

Les valeurs très faibles des p-values indiquent que ces corrélations sont fiables. La corrélation la plus importante se situe entre la distance structurelle et la distance dynamique de Hamming : 0.685 en dimension 2 et 0.872 en dimension 3. Elle peut s'interpréter de la manière suivante : une petite différence dans la structure implique une petite différence dans la dynamique. Autrement dit, les modifications de la dynamique sont proportionnelles aux modifications de la structure.

Cette proposition est moins vraie au regard de la corrélation entre la distance structurelle de Hamming et la distance dynamique sur les attracteurs. Cette dernière est moins importante : 0.345 en dimension 2 et 0.328 en dimension 3. Ce qui est attendu, puisqu'à la différence de la distance dynamique de Hamming, où toutes modifications de la dynamique sont sur un même pied d'égalité, une modification de la structure peut ne pas impacter la distance sur les attracteurs (par exemple si les mêmes états restent liés aux mêmes attracteurs), ou au contraire engendrer une différence très importante (par exemple si deux attracteurs fusionnent).

Les corrélations entre distances sont également représentées visuellement. La figure 88 présente les matrices des distances entre tous les RBS des dimensions 2 et 3. Plus les carrés autour des diagonales sont marqués et jaunes, plus les réseaux proches selon la distance structurelle de Hamming le sont également selon la distance représentée par la couleur.

La figure 89 présente sous la forme d'histogrammes 2D les croisements entre les trois distances pour tous les RBS des dimensions 2 et 3. La forte corrélation entre la distance structurelle et la distance dynamique de Hamming est bien visible dans les deux histogrammes de gauche.




Figure 88 : Matrices des distances en dimension 2 à gauche et 3 à droite. Dans chacune d'entre-elles, les RBS sont regroupés selon la distance structurelle de Hamming. La couleur de chaque carré indique la distance qui sépare les deux RBS concernés. Dans le cas de la dimension 3, puisqu'il existe 31199 RBS, la résolution requise pour afficher toutes les distances individuellement serait trop importante. En conséquence, la couleur d'un carré est le résultat de la moyenne des distances entre 100 RBS. Les trois distances calculées sont la distance structurelle (HSTR), la distance dynamique de Hamming (HDYN) et la distance dynamique sur les attracteurs (CYCLE).




Figure 89 : Histogrammes 2D en dimension 2 en haut et en dimension 3 en bas, croisant la distance structurale de Hamming, la distance dynamique de Hamming et la distance dynamique sur les attracteurs. La couleur et la taille des points indiquent le nombre de paires de réseaux par classe des histogrammes.

8.2.2.2 Métagraphe des RBS

En disposant des distances entre tous les RBS d'une dimension, il est possible de visualiser l'espace des réseaux de cette dernière en le dotant d'une topologie. En choisissant de désigner comme voisins des RBS suffisamment proches selon une ou plusieurs distances, il est possible de construire un graphe des réseaux.

Dans un tel graphe, les sommets représentent les RBS, un arc entre deux sommets indique que ces RBS sont voisins. Puisque les RBS sont eux-mêmes des graphes, nous appelons *métagraphe* ce graphe des réseaux. La figure 90 en présente un exemple.

Deux RBS sont dit voisins si la distance structurelle et la distance dynamique qui les séparent sont inférieures ou égales à des seuils donnés. La formule suivante définit l'ensemble $\text{Voisins}(R)$: les voisins d'un RBS R , selon la distance structurelle de Hamming, une distance dynamique donnée D_{dyn} et les seuils ϵ et δ :

$$\text{Voisins}(R) = \{R' \mid \text{HSTR}(R, R') \leq \epsilon, D_{\text{dyn}}(R, R') \leq \delta\} \quad (28)$$

Un métagraphe qui ne prend en compte que la distance structurelle est appelé un *métagraphe structurel*. Les voisins ne sont alors définis que par rapport au seuil ϵ .

Par la suite, la distance dynamique considérée sera systématiquement précisée, ainsi que les valeurs données aux seuils ϵ et δ .





Figure 90 : Métagraphe structurel des 60 RBS de dimension 2. Dans cet exemple, deux RBS sont reliés s'ils sont distants de 1 selon la distance structurelle de Hamming ($\epsilon = 1$). Les numéros sur les nœuds sont les identifiants attribués à chaque RBS.


La figure 91 compare le métagraphe structurel de la figure 90 avec des métagraphes plus *restreints*. Ils prennent en compte le seuil $\delta = 1$ dans la figure 91a et $\delta = 0$ dans la figure 91b. Les arcs en rouge dans les métagraphes structurels mettent en valeur les arcs qui n'existent pas dans les métagraphes restreints associés. Ainsi, la figure 91a permet d'identifier les mutations structurelles qui engendrent des modifications de la dynamique.

Exemple : Les RBS 25 et 54 (91a en haut) sont distincts d'une seule mutation structurelle, mais sont éloignés en dynamique d'au moins 2, ils ne sont donc plus reliés dans le métagraphe restreint.

Le métagraphe restreint à $\delta = 0$ (91b) permet quant à lui d'identifier des clusters de RBS qui conservent exactement la même dynamique. Ces derniers correspondent aux RBS construits à partir de compositions alternatives contenant des classes d'équivalence de FBS projetées.



(a) Métagraphe structurel ($\epsilon = 1$) et métagraphe restreint ($\epsilon = 1, \delta = 1$)



(b) Métagraphe structurel ($\epsilon = 1$) et métagraphe restreint ($\epsilon = 1, \delta = 0$)

Figure 91 : Métagraphes des RBS de dimension 2 avec la distance dynamique de Hamming. Les arcs rouges dans les métagraphes structurels (à gauche) sont ceux qui n'existent pas dans les métagraphes restreints (à droite) à cause de l'ajout du seuil δ . Les numéros sur les nœuds sont les identifiants attribués à chaque RBS.

8.2.2.3 Étude de la robustesse

À partir d'un métagraphe structural, il est possible de calculer la robustesse de chaque RBS aux modifications structurales. La robustesse d'un RBS mesure la proportion de voisins qui présente une dynamique identique ou proche de la sienne, selon un seuil δ . Elle est définie par la formule suivante :

$$\text{Robustesse}(\mathbf{R}) = \frac{|\mathbf{R}' \in \text{Voisins}(\mathbf{R}), D_{\text{dyn}}(\mathbf{R}, \mathbf{R}') \leq \delta|}{|\text{Voisins}(\mathbf{R})|} \quad (29)$$

Puisque la robustesse est une proportion, elle est toujours comprise dans l'intervalle $[0; 1]$. Une robustesse de 1 signifie que tous les voisins présentent une dynamique similaire à δ près. À l'inverse, une robustesse de 0 montre que la dynamique du RBS n'est pas conservée dans son voisinage.

La figure 92 présente l'évaluation de la robustesse avec $\delta = 0$ sur le métagraphe structural de seuil $\epsilon = 1$. Ce couple de valeurs pour ϵ et δ permet de considérer les voisins directs. Les RBS en jaunes ont une robustesse maximale et ceux en violets une robustesse minimale.

Dans cet exemple, le groupe de quatre RBS jaunes est particulièrement robuste, selon le RBS considéré, la dynamique persiste malgré plusieurs mutations. La plupart des RBS sur l'extérieur ne sont pas robustes (violets) : toute mutation modifie leur dynamique.




Figure 92 : Métagraphe des RBS de dimension 2 avec $\epsilon = 1$, coloré selon la robustesse. Cette dernière est calculée avec $\delta = 0$ selon la distance dynamique de Hamming.

Les figures 93 et 94 présentent les robustesses moyennes obtenues selon toutes les valeurs possibles de ϵ et de δ , d'abord pour la distance dynamique de Hamming puis pour la distance dynamique sur les attracteurs.

Dans le cas de la distance dynamique de Hamming (figure 93), il est possible d'observer que la robustesse moyenne devient maximale dès que δ devient supérieur à ϵ . C'est-à-dire que tous les voisins structurels sont δ -proches du réseau d'origine. C'est la conséquence de la forte corrélation entre la distance structurelle et la distance dynamique de Hamming, il n'est pas possible d'obtenir une différence de dynamique de plus de $\epsilon + 1$.




Figure 93 : Tableau des robustesses moyennes des RBS de dimension 2 selon les différentes valeurs de ϵ pour le métatagraphe structurel et de δ pour la robustesse, avec la distance dynamique de Hamming.

Dans le cas de la distance dynamique sur les attracteurs (figure 94), cet effet est bien moins net et ne se retrouve qu'à partir de valeurs de δ bien plus hautes. Ce qui est cohérent, puisqu'une seule modification de la structure peut engendrer un changement bien plus important de la dynamique selon la distance sur les attracteurs.




Figure 94 : Tableau des robustesses moyennes des RBS de dimension 2 selon les différentes valeurs de ϵ pour le métatagraphe structurel et de δ pour la robustesse, avec la distance dynamique sur les attracteurs.

8.2.2.4 Étude de l'évolutivité

Afin de définir l'évolutivité, il est nécessaire de définir deux notions intermédiaires : le coût d'un chemin d'évolution et le coût d'une évolution.

Un chemin d'évolution est défini comme une suite finie de réseaux $(R_0; \dots; R_k)$ où R_0 est appelé le *réseau de départ* et R_k le *réseau d'arrivée*.

Une évolution est définie comme un couple de réseaux $(R \rightarrow R')$, où R est le réseau de départ et R' le réseau d'arrivée. Le chemin d'évolution désigne donc une trajectoire dans l'espace des réseaux, tandis qu'une évolution désigne une transformation d'un réseau en un autre, indépendamment du chemin choisi. Les notions de *coût de chemin d'évolution* (CC) et de *coût d'évolution* (CE) ont pour but de traduire la difficulté ou la rareté d'une certaine évolution d'un système biologique. Nous devons donc définir deux fonctions, le coût d'un chemin et le coût d'une évolution.

Dans le cadre des métagraphes, un chemin d'évolution est une suite finie de réseaux, telle que deux réseaux consécutifs sont voisins. Le coût d'un chemin d'évolution est défini comme étant la longueur du chemin de R_0 à R_k :

$$CC(R_0; \dots; R_k) = k \quad (30)$$

Le coût d'une évolution est alors le coût minimal d'un chemin allant du réseau de départ au réseau d'arrivée, défini par la formule suivante :

$$CE(R \rightarrow R') = \begin{cases} \min_{c \in \text{Chemins}(R \rightarrow R')} CC(c) & \text{si } \text{Chemins}(R \rightarrow R') \neq \emptyset \\ +\infty & \text{sinon} \end{cases} \quad (31)$$

Dans la section 8.1.1, nous avons informellement défini l'évolutivité comme la capacité d'un système biologique à atteindre de nouvelles dynamiques avec de petites évolutions. Pour calculer l'évolutivité d'un système, il est donc nécessaire de considérer l'ensemble des réseaux. Les évolutions faisant varier la dynamique doivent être mises en valeur et à l'inverse, les évolutions coûteuses sont dévalorisées. Nous définissons donc l'évolutivité d'un réseau R selon la formule suivante :

$$\text{Evolutivité}(R) = \text{moyenne}_{R' \in d} \left(\frac{D_{\text{dyn}}(R, R')}{CE(R, R')} \right) \quad (32)$$

Les évolutions impossibles sont prises en compte, puisque s'il n'existe pas de chemin de R à R' alors $CE(R \rightarrow R') = \infty$, le terme correspondant dans le calcul de la moyenne est alors nul.

La figure 95 présente les valeurs d'évolutivité obtenues pour les RBS de dimension 2, avec $\epsilon = 1$, $\delta = 1$ et la distance dynamique de Hamming.




Figure 95 : Métagraphes des RBS de dimension 2 avec $\epsilon = 1$, $\delta = 1$, coloré selon l'évolutivité. La distance dynamique considérée est celle de Hamming. Les réseaux entourés sont commentés dans le texte.

Le réseau entouré en rose est le plus évolutif, il fait partie des moins robustes, identifiés dans la figure 92. Il peut sembler surprenant que parmi les moins robustes ce soit lui le plus évolutif, puisqu'il n'apparaît pas comme le plus central dans le métagraphe. Son évolutivité doit provenir davantage de sa dynamique, qui est probablement éloignée de la majorité des autres dynamiques.

Les réseaux entourés en rouge, identifiés comme les plus robustes dans la figure 92 font ici partie des moins évolutifs. Puisque leurs voisins directs conservent leur comportement, ils doivent atteindre des réseaux plus éloignés pour trouver des comportements différents. Il ne faut cependant pas opposer évolutivité et robustesse [23] : un facteur important à prendre en compte est la connectivité du groupe de réseaux robustes. Un réseau central, au sein d'un cluster de RBS partageant une même dynamique, est certes très robuste, mais via ses voisins, il a potentiellement également un accès indirect à de nombreuses dynamiques différentes, à de multiples chemins d'évolution.

Exemple : Les réseaux entourés en orange, robustes dans la figure 92, sont également très bien connectés, ils se retrouvent donc également parmi les plus évolutifs de la figure 95.

[23] WAGNER « Robustness and evolvability : a paradox resolved » (2007)

8.3 ÉVALUER L'EXTENSIBILITÉ DE LA STRUCTURE ET DE LA FONCTION DES RBS

Les systèmes biologiques évoluent par mutations de leurs éléments. Ces mutations peuvent prendre différentes formes : modification, suppression, ajout, réarrangement d'un élément. Nous nous intéressons ici particulièrement à l'extensibilité, soit la capacité pour un réseau d'étendre ses comportements lors de l'ajout d'éléments structurels.

Il est important de bien comprendre que nous voulons seulement étendre les comportements des réseaux : ajouter et non pas modifier. La question précise que nous posons est la suivante : Comment est-ce qu'un réseau parvient, par l'extension de sa structure, à faire évoluer sa dynamique, afin que le réseau obtenu conserve un sous-réseau structurellement semblable à celle du réseau initial et dont les comportements étendent les comportements initiaux sans les altérer ?

Les travaux présentés dans cette section tirent leurs origines de l'histogramme de la figure 96, réalisé dans le cadre de nos travaux sur les Réseaux Booléens à Seuil [1], qui présente les relations entre leur complexité structurelle et leur complexité dynamique. L'objectif est d'explorer davantage ce dont sont capables les réseaux de diverses valeurs de complexité structurelle, d'étudier si cette complexité peut être "investie" dans de l'évolutivité. L'idée étant alors d'ajouter une dimension à l'histogramme de la figure 96 qui indiquerait cette évolutivité.

[1] CHRISTEN et al. « On Computing Structural and Behavioral Complexities of Threshold Boolean Networks » (2019)




Figure 96 : Histogramme 2D de la complexité dynamique et structurelle des Réseaux Booléens à Seuil de dimension 4. La couleur des points indique le nombre de couples $\{M, R\}$, où M représente une musique et R le réseau capable de la jouer sur l'un de ses nœuds. Au plus un point est jaune, au plus il contient de couples.

C'est avec le modèle des RBS que nous avons effectué cette étude. Pour des raisons pratiques, nous nous sommes restreint à l'exploration de l'ajout d'un seul nouveau nœud aux RBS. Puisque nous énumérons exhaustivement tous les RBS d'une dimension, l'ajout d'un nœud créé déjà un nombre conséquent d'extensions à explorer (cf. section 8.3.3). L'intérêt d'une exploration exhaustive est de pouvoir

inclure toute la diversité structurelle et dynamique des RBS et d'étudier systématiquement leurs relations.

Nos observations tirées de l'histogramme de la figure 96, à savoir que les comportements les plus complexes requièrent des structures complexes tandis que ces dernières peuvent produire des comportements de toutes complexités, nous mènent à formuler les hypothèses suivantes :

- Les réseaux les plus à même d'être étendus seraient ceux présentant un surplus de complexité structurelle par rapport à la complexité du comportement qu'ils présentent. Cette "réserve de complexité" permettrait à ces réseaux d'accéder à davantage de chemins évolutifs : ils sont viables sans être "trop" spécialisés et pourrait donc évoluer à moindre coût.
- Les réseaux de grande complexité structurelle et capables de comportements complexes seraient peu extensibles : le moindre changement ayant trop d'impact sur leurs fonctionnements finement sélectionnés.
- À l'inverse, les réseaux trop simples ne pourraient pas devenir des réseaux complexes capables de comportements complexes : les modifications nécessaires ne pouvant être obtenues en une seule extension.

Note : Les travaux présentés dans cette section ont fait l'objet d'une publication [2] et d'une présentation dans le cadre de la conférence Complex Networks 2020.

[2] SEGRETAINE et al. « A Methodology for Evaluating the Extensibility of Boolean Networks' Structure and Function » (2021)

8.3.1 Définition de l'extension d'un RBS

Afin de formuler précisément notre définition formelle de l'extension d'un réseau, il est nécessaire d'introduire les éléments suivants :

- d : la dimension du réseau initial.
- R_1 : le RBS initial, composé de d nœuds.
- n_i : le nœud i de R_1 qui présente le comportement considéré ($i \in [1; d]$).
- M_1 : la séquence binaire décrivant le comportement produit par n_i .
- M_k : la séquence binaire décrivant l'extension souhaitée du comportement.
- R : le RBS étendu, composé de $d + 1$ nœuds.
- M : la séquence binaire décrivant le comportement du nœud n_i de R .

Ces éléments sont liés entre eux par les contraintes logiques suivantes :

- M est la concaténation de M_1 et M_k : $M = M_1 + M_k$.
- R contient un sous-réseau R'_1 tel que :
 - R'_1 est composé de d nœuds.
 - R'_1 et R_1 partagent la même structure :

$$\forall \text{Arc}_{n_i \rightarrow n_j} \in R_1, \exists ! \text{Arc}'_{n_i \rightarrow n_j} \in R'_1. \text{ Avec } i, j \in [1; d].$$

$\exists !$ signifie : "il existe un unique".

- R'_1 et R_1 partagent la même composition de FBS :

$$\forall f_i \in R_1, \exists ! f'_i \in R'_1, f_i \equiv f'_i. \text{ Avec } i \in [1; d].$$

Où $\equiv$ signifie l'appartenance à la même classe d'équivalence (cf. chapitre 3).

- Les poids des arcs de R'_1 doivent être égaux ou supérieurs à ceux de R_1 :

$$\forall p_{n_i \rightarrow n_j} \in R_1, \exists ! p'_{n_i \rightarrow n_j} \in R'_1, p_{n_i \rightarrow n_j} \leq p'_{n_i \rightarrow n_j}. \text{ Avec } i, j \in [1; d].$$

Ces contraintes sont résumées dans le schéma de la figure 97 et dans la figure 98 qui présente l'exemple d'un RBS de dimension 2 étendu de deux manières différentes.




Figure 97 : Schéma des contraintes de l'extension d'un réseau.

8.3.2 Méthodologie

Il existe un très grand nombre de quadruplets $\{R_1, M_1, R, M\}$. En pratique, il n'est pas possible en un temps de calcul raisonnable et avec la quantité de mémoire RAM à notre disposition de les énumérer pour vérifier s'ils respectent les contraintes détaillées précédemment.

[24] CORBLIN et al. « Automatic Inference of Regulatory and Dynamical Properties from Incomplete Gene Interaction and Expression Data » (2012)

Afin de contourner ce problème, nous avons implémenté le problème de l'extension sous une forme particulière : centrée sur les instances de RBS. Tous les couples $\{R_1, M_1\}$ sont énumérés puis, selon la dimension, toutes les extensions M_k possibles sont tentées. Pour cela, nous utilisons un ensemble de modules ASP (cf. section 6.4, [24], [25], [26]) qui implémentent les contraintes de l'extension. Ils infèrent pour un triplet $\{R_1, M_1, M_k\}$ l'ensemble des RBS R correspondants.

[25] VUONG et al. « A Logical Constraint-based Approach to Infer and Explore Diversity and Composition in Thresholded Boolean Automaton Networks » (2017)

En parallèle de l'extension des RBS, les mesures suivantes sont calculées :

[26] CHEVALIER et al. « Synthesis of Boolean Networks from Biological Dynamical Constraints using Answer-Set Programming » (2019)

- La centralité par chemin d'influence des RBS R_1 et R , présentée dans la section 7.1.2.1.
- La rareté des FBS de R_1 et de R , présentée dans la section 7.1.1.
- La complexité des comportements M_1 et M , présentée dans la section 7.1.3.
- La taille des attracteurs de M_1 et de M .
- La taille des bassins d'attraction de M_1 et de M .
- Le nombre d'attracteurs de R_1 et de R .

Dans les résultats, les deux mesures de complexité structurelle : la centralité et la rareté ; sont agrégées ensemble de la manière suivante :

$$\text{Complexité}(R) = \prod_{i=1}^d \begin{cases} \text{Rareté}(f_i) \times \text{Centralité}(n_i) & \text{si Centralité}(n_i) > 0 \\ 1 & \text{sinon} \end{cases}$$

Cette suite de traitements est réalisée à l'aide de la bibliothèque JPP présentée dans le chapitre 6. Le pipeline dédié à l'inférence des réseaux étendus et à leur analyse est présenté par le schéma de la figure 99.




Figure 98 : Exemple d'extension d'un RBS de dimension 2. En haut le réseau R_1 de dimension 2 avec son graphe de transition. Le comportement considéré est celui du nœud A en rouge : $M_1 = 10^*$. Il est étendu par le suffixe $M_K = 1$. L'extension de R_1 mène à 48 possibilités, 2 d'entre-elles sont présentées. En bas : deux RBS R avec leurs graphes de transition respectifs. Les nœuds et arcs ajoutés par l'extension sont en gris afin de mettre en avant la conservation de la structure de R_1 . Le comportement du nœud A dans les deux RBS R respecte la contrainte $M = M_1 \cdot M_K$ puisque $M = 101^*$.




Figure 99 : Schéma du pipeline en charge de calculer d'une part l'extension des RBS et d'autre part les mesures permettant de les analyser.

8.3.3 Résultats de l'extension

Nous avons utilisé la méthode décrite ci-dessus pour calculer les extensions de tous les RBS de dimension 2 vers les RBS de dimension 3.

Ces résultats sont les premiers obtenus sur les RBS durant ma thèse. Malheureusement, à cause des bouleversements engendrés par la pandémie de Covid-19, ils n'ont pas pu être traités comme nous l'aurions souhaité.

Principalement, d'importantes erreurs méthodologiques et logicielles ont été corrigées depuis les calculs de ces résultats, corrections dont ils n'ont donc pas bénéficié. Deux de ces erreurs les impactent fortement :

- Une erreur d'implémentation du calcul de la centralité par chemin d'influence (cf. section 7.2.2).
- Une méthode de filtrage des doublons insuffisante lors de l'étape d'énumération des RBS. De nombreuses classes d'équivalence de RBS sont représentées plusieurs fois, menant aux chiffres erronés présentés dans le tableau 9. La méthode actuelle de filtrage des doublons est présentée dans la section 5.5.

d	FBS	RBS	$\{R_1, M_1, M\}$	R
2	7	101	96×10^3	777216
3	17	206×10^3	$[180 \times 10^6; 32 \times 10^9]$	$[1.5 \times 10^9; 280 \times 10^9]$
4	47	76×10^9	??	??

Tableau 9 : Nombres connus de FBS, RBS, triplet $\{R_1, M_1, M\}$ et de RBS étendus R par dimension d lors des calculs de l'extension. Les intervalles de valeurs sont des estimations fondées sur l'extension des RBS de dimension 2 vers 3.

En conséquence, les conclusions tirées de ces résultats ne peuvent être considérées comme valides. Seule une reprise de ces calculs, en intégrant les corrections de ces erreurs, pourrait permettre de juger de leur justesse. Une telle reprise demanderait toutefois un temps de développement trop important pour la réaliser dans les délais impartis. Cependant, le développement méthodologique pour obtenir ces résultats n'est absolument pas perdu, il a notamment permis les résultats présentés dans le chapitre 7.

Sans les analyser en détail, il me semble néanmoins pertinent d'inclure les figures 100 et 101, produites à partir des résultats de l'extension, afin de donner un aperçu du potentiel de cette méthode.




Figure 100 : Histogramme 3D présentant les 777216 quadruplets $\{R_1, M_1, R, M\}$ résultants de l'extension des RBS de dimension 2 vers les RBS de dimension 3. L'axe bleu mesure la complexité structurelle de R_1 , l'axe vert la complexité dynamique de M_1 et l'axe en profondeur la complexité dynamique de M . La couleur des points indique la moyenne de complexité structurelle des R présents dans cette classe de l'histogramme. La taille des points, en échelle logarithmique, indique le nombre de R recensés dans cette classe. L'histogramme 2D en haut de la figure correspond à la "face avant" de l'histogramme 3D, il présente le croisement de la complexité structurelle et de la complexité dynamique des RBS de dimension 2.




Figure 101 : Projections 1D des trois axes de l'histogramme 3D de la figure 100. Les multiples fréquences présentes dans chaque classe de ces histogrammes 1D résultent de la projection des classes de l'histogramme 3D. Pour chaque série de projections en ligne, la taille et la couleur des points représentent les moyennes de mesures additionnelles pour chaque classe de l'histogramme 3D. Le croisement de ces projections permet de mieux suivre les corrélations entre les mesures présentes.

8.4 SYNTHÈSE

Nous présentons dans ce chapitre différentes méthodes et mesures pour étudier l'évolution et explorer le paysage des réseaux, représenté dans la figure 102. Les mesures de distance permettent de qualifier les évolutions internes à une dimension et l'extension explore les évolutions inter-dimensions.




Figure 102 : Schéma du *paysage des réseaux*. Les couches représentent les différentes dimensions, chacune représente l'espace des RBS de cette dimension. Ces espaces sont métrés par la distance structurale de Hamming. Chaque point représente un RBS, sa couleur symbolise sa dynamique. Deux points de la même couleur représentent donc deux RBS différents structurellement, mais qui présentent la même dynamique. Une flèche pleine représente l'évolution par extension, tandis qu'une flèche pointillée représente une évolution par mutation : la modification de la valeur d'un poids.

Les résultats présentés illustrent les méthodes développées et ouvrent la voie à des études sur des sujets plus précis. Nous sommes ici restreint aux basses dimensions puisque nous analysons l'ensemble des RBS de chaque dimension et que la taille de cet ensemble croît exponentiellement avec la dimension.

Une étude sur un sujet spécifique pourrait atteindre de plus hautes dimensions, en se limitant à un ensemble contraint de réseaux qui, par exemple, présenteraient une dynamique précise, où qui contiendraient des modules structurels particuliers. Cela permettrait de réduire l'étude aux réseaux correspondant à une population précise de systèmes biologiques. Je pense ici au cas du réseau de morphogenèse florale d'*Arabidopsis thaliana* dont il a été trouvé dans [12] qu'il existe une population de 532 réseaux booléens à seuil différents respectant les connaissances biologiques énoncées par Mendoza *et al* [11]. Parmi ces 532 réseaux, lesquels sont plus robustes ? Lesquels sont les plus évolutifs ? Les plus extensibles ?

Il serait informatif de prendre aussi en considération les mesures de complexités et les résultats présentés dans le chapitre 7. Ce point sera davantage développé dans la conclusion.

[12] GLADE et al. « Determination, Optimization and Taxonomy of Regulatory Networks : The Example of *Arabidopsis thaliana* Flower Morphogenesis » (2011)

[11] MENDOZA et ALVAREZ-BUYLLA « Dynamics of the Genetic Regulatory Network for *Arabidopsis thaliana* Flower Morphogenesis » (1998)

CONCLUSION

I'm still standin'! Yeah! Yeah! Yeah!

CONCLUSION

Les travaux menés durant cette thèse ont construit les fondations nécessaires à l'utilisation du modèle des RBS pour étudier globalement les systèmes biologiques.

Théoriquement d'abord, au travers des différentes mesures proposées qui permettent d'évaluer la complexité structurelle, pour la rareté des fonctions et la répartition de l'influence, et la complexité dynamique pour la complexité de Kolmogorov des chaînes binaires représentant les musiques des nœuds.

Méthodologiquement ensuite, grâce aux définitions des classes d'équivalence de FBS et de RBS et à la méthode d'énumération d'ensembles de RBS contenant un unique représentant de chaque classe. Le problème de l'énumération de toutes les classes d'équivalence de FBS d'une dimension donnée reste néanmoins un problème ouvert. L'approche par énumération des poids se heurte à l'explosion combinatoire ainsi qu'au choix des bornes de l'intervalle de recherche. Tandis que l'approche par énumération des contraintes est limitée par la complexité croissante des règles à appliquer pour inférer le signe des contraintes. Une méthode à étudier, approchant le problème géométriquement, pourrait être de déterminer toutes les régions de l'espace délimitées par l'ensemble des hyperplans définis par les configurations d'une table de vérité de dimension d (par exemple le plan défini par $p_A + p_B = 0$ pour la configuration $\langle 0, 1, 1 \rangle_{\text{Cfg}}$ en dimension 3).

Technologiquement enfin, puisqu'il est possible à l'aide de la bibliothèque JPP, de bâtir aisément des chaînes de traitements parallélisées pour analyser ces ensembles de RBS. Les différents modules développés, par moi-même ainsi que par les étudiants stagiaires encadrés, forment à présent une boîte à outils éprouvée qui ouvrent la voie à de futurs travaux.

L'étude menée sur les relations entre la structure et la dynamique des RBS confirme, comme observé dans [1] sur les réseaux booléens à seuil, que les comportements les plus complexes requièrent une structure complexe. Avec toutefois la précision supplémentaire que cette complexité structurelle doit émaner à la fois de la rareté des composants, mais également de la manière dont ils sont assemblés.

[1] CHRISTEN et al. « On Computing Structural and Behavioral Complexities of Threshold Boolean Networks » (2019)

Concernant les autres types de dynamiques analysées, c'est-à-dire la multi-attractivité et la robustesse, ces travaux ne permettent pas d'affirmations aussi nettes. Ils demandent à être poursuivis et approfondis.

Une première voie possible serait de n'étudier que des sous-ensembles des RBS, respectant certaines caractéristiques. Par exemple, pour étudier la multi-attractivité, il faudrait ne retenir que les RBS présentant au moins un certain nombre d'attracteurs. Le système de filtres, présentés en fin du chapitre 6, pourrait permettre d'obtenir de tels sous-ensembles à partir de l'ensemble complet des RBS. Ce type d'approche, grâce au nombre réduit de réseaux étudiés, aurait en plus l'avantage de pouvoir inclure des réseaux de plus hautes dimensions, qui représentent probablement mieux les systèmes biologiques réels.

Analyser les RBS de plus hautes dimensions n'est toutefois pas directement possible. L'énumération des RBS, telle qu'elle fonctionne actuellement, nécessiterait,

[20] SOLER-TOSCANO et al. « Calculating Kolmogorov Complexity from the Output Frequency Distributions of Small Turing Machines » (2014)

[21] ZENIL et al. « A Decomposition Method for Global Evaluation of Shannon Entropy and Local Estimations of Algorithmic Complexity » (2018)

pour générer les RBS de dimension supérieure à 4, une fragmentation supplémentaire des tâches similaire à celle présentée dans la section 8.2.1. Cela permettrait de dompter l'explosion combinatoire liée à la montée en dimension. De plus, certaines mesures peuvent nécessiter une adaptation. C'est le cas notamment de la complexité dynamique, celle-ci repose sur la méthode CTM-BDM [20] [21] qui en l'état est limitée à l'évaluation de la complexité des chaînes de caractères d'une taille maximale de 12. Or, dès la dimension 4, certaines musiques dépassent ce maximum. Afin d'étudier la complexité des comportements des RBS de plus haute dimension, il serait nécessaire soit de trouver une mesure alternative, soit de reprendre les travaux ayant abouti à la méthode à CTM-BDM et de les amener à pouvoir prendre en compte des chaînes de caractères plus longues.

Une seconde voie pour poursuivre l'étude des liens entre la structure et la dynamique serait de la croiser avec les mesures de distances présentées dans le chapitre 8. Cela permettrait d'établir une taxonomie des réseaux et de répondre aux questions suivantes : Est-ce que des réseaux proches en structure ou en dynamique sont également proche en termes de complexité structurelle et dynamique ? Les réseaux possédant les mêmes types de dynamiques sont-ils similaires structurellement ?

Les travaux présentés sur l'évolutivité et la robustesse des réseaux nécessitent davantage d'analyses. Les données récoltées n'ont été que peu fouillées à ce jour. Il faudrait également réaliser ces travaux au moins en dimension 3, la dimension 2 étant tout de même très limitée par le faible nombre de réseaux et de dynamiques différentes. Il est aussi nécessaire d'étudier les liens qui pourraient exister entre l'évolutivité, la robustesse et les complexités structurelles et dynamiques. Il faut pour cela commencer par reproduire l'étude de l'extension des RBS, une fois les modules logiciels dédiés mis à jour avec les derniers développements méthodologiques et technologiques. Cela permettrait de tester notre hypothèse que les réseaux les plus complexes d'une dimension sont également ceux qui s'étendent le moins facilement, tous les éléments qui les composent étant trop finement interconnectés, en ajouter un nouveau perturberait nécessairement le réseau.

ÉVOLUTION ARTIFICIELLE

Une approche différente pour étudier l'évolution au travers des RBS serait de construire un simulateur d'évolution artificielle. Le principe serait de simuler des populations de réseaux au travers de très nombreuses générations, afin ensuite de pouvoir ensuite étudier toute la lignée ayant abouti à un système.

L'idée d'un tel simulateur vient de mon intérêt pour le domaine de la vie artificielle, qui a formé je pense le point d'ancrage initial m'ayant fait m'intéresser à la recherche et, *in fine* amené à faire une thèse. Je pense en particulier au livre de Jean-Philippe Rennard [27]. Il n'est donc pas surprenant que ce sujet *émerge* dans ma thèse, adapté au monde des RBS. Cette adaptation se trouve ici dans l'échelle de la simulation. À la différence des simulations de vie artificielle, la simulation des individus, les réseaux, serait ici effectuée à très gros grain, puisque l'intention est de pouvoir enchaîner rapidement les générations. Il s'agit donc d'un algorithme génétique. Seul le comportement des réseaux serait simulé, pas à pas, dans un environnement, sans aucune interaction entre les individus. Cet environnement serait défini par deux facteurs :

[27] RENNARD *Vie Artificielle - Où la biologie rencontre l'informatique* (2002)

- Un niveau de bruit ambiant qui perturbe les états des réseaux, pour représenter des événements extérieurs à chaque réseau.
- Une condition de viabilité (critère de sélection), sous la forme d'un comportement cible, défini comme viable et vers lequel les réseaux devraient donc tendre pour survivre.

Régulièrement, les réseaux déterminés comme viables seraient reproduits. C'est là que des mutations (de différentes natures : extension, duplication ou suppression d'un nœud ou d'un arc, modification d'un poids, *etc*) seraient appliquées, produisant ainsi de nouvelles "espèces" de réseaux. C'est dans un tel contexte que le choix de considérer qu'un poids d'une valeur de zéro représente l'absence d'un arc prend tout son sens. Un arc ne transportant aucun signal, mais néanmoins présent, est différent de l'absence d'un arc. L'arc présent, mais de poids nul, bien que ne jouant aucun rôle dans la dynamique du réseau, forme un potentiel d'évolution (ou un résidu d'évolution), surtout s'il est plus "couteux" de créer un arc que de faire muter un poids.

Les critères qui définissent l'environnement, les taux de mutations *etc* , forment autant de leviers permettant au modélisateur de mener diverses expériences sur l'évolution, telle que celle menée dans [28]. L'analyse des lignées de réseaux obtenues, à l'aide entre autres des mesures présentées dans ce manuscrit, pourrait permettre d'apporter des réponses à des questions telles que : Existe-t-il un "module", des caractéristiques qui permettent de garder un organisme viable au fil de l'évolution ? Il y a-t-il une structure, des motifs, des stratégies, communes aux différents réseaux qui parviennent à évoluer ? Ou au contraire, des impasses communes aux lignées qui s'éteignent ? Est-ce que de telles simulations permettent d'observer les mêmes valeurs d'évolutivité et de robustesse que l'on peut déterminer par calculs exhaustifs ?

ATAVISME

Ce simulateur pourrait également servir à tester certains aspects de la théorie ataviste du cancer, présentée très brièvement ci-dessous.

Il est possible de se représenter la structure d'un système comme les couches d'un oignon, chacune apparue à différents stades de l'évolution et qui régule et contrôle les couches précédentes pour les utiliser à son avantage pour faire face aux conditions de viabilité courante. L'évolution pousse les systèmes à se "hacker" eux-mêmes, à partir de l'existant plutôt qu'à se réinventer. En conséquence, les systèmes biologiques modernes héritent des fonctions biologiques primitives adaptées à des environnements ancestraux. Ces fonctions sont toujours présentes, mais régulées et réactivées dans des conditions particulières. Typiquement, c'est le cas du mécanisme de fermentation pour la production d'énergie des cellules qui prend le relais de la respiration lorsque l'oxygène vient à manquer, par exemple lors d'un effort musculaire trop important et qui dure trop longtemps.

Une hypothèse, émise dans le cadre de la théorie ataviste du cancer, est que les fonctions les plus récentes des systèmes, ici les cellules, sont également les moins robustes et donc les premières à dysfonctionner en cas de perturbations de la dynamique ou de mutations de la structure [29] [30], comme l'illustre la figure

103.

[28] CROMBACH et HOGEWEG « Evolution of Evolvability in Gene Regulatory Networks » (2008)

[29] ISRAEL « Tumour Progression : Random Mutations or an Integrated Survival Response to Cellular Stress Conserved from Unicellular Organisms ? » (1996)

[30] LINEWEAVER, DAVIES et VINCENT « Targeting cancer's weaknesses (not its strengths) : Therapeutic strategies suggested by the atavistic model. » (2014)



Figure 103 : Illustration de la re-primarisation des systèmes biologiques. Les cernes de l'arbre représentent les différents éléments structurels apparus au fil de l'évolution.

Ainsi, les parties "primitives" des systèmes, adaptées à des environnements ancestraux, ne sont plus régulées et se retrouvent libres de se comporter comme si leur environnement était celui qui les a vu émerger. Cet environnement est celui du Précambrien, où l'atmosphère ne contient que peu ou pas d'oxygène et où le pH ambiant est acide. Les formes de vie unicellulaires de l'époque sont adaptées à cet environnement et certaines commencent à vivre en colonies de cellules. Le comportement observé des cellules tumorales s'apparente à celui de ces cellules ancestrales [31], par exemple en rompant la coopération fine entre cellules, primordiale pour un organisme multicellulaire, ou en acidifiant le milieu où se situe la tumeur [32], reproduisant ainsi un environnement de l'époque.

Il peut sembler cohérent, si des fonctions biologiques ancestrales parviennent à se maintenir jusque dans les organismes modernes, que ces dernières aient un rôle important du point de vue évolutif. Peut-être que ces fonctions sont néfastes pour le système dans des conditions normales, mais se révèlent utiles dans des conditions de crises. La robustesse de l'organisme s'en trouverait améliorée dans de telles situations. Si ces fonctions apportent un avantage évolutif depuis "long-temps" il n'est pas surprenant qu'elles soient résistantes aux perturbations et aux mutations puisque ce sont justement ces conditions qu'elles sont censées permettre de traverser.

Dans des conditions normales, du point de vue de l'organisme multicellulaire, les utilisations de ces fonctions sont des événements courts en réponse à des perturbations extérieures. Par exemple une dérégulation temporaire de la division cellulaire qui permet la cicatrisation des tissus après une blessure. Puis lorsque les conditions redeviennent normales, ces fonctions sont de nouveau réprimées et contrôlées par les couches apparues plus récemment dans l'évolution.

Lorsque les conditions se détériorent considérablement, que les couches les plus anciennes se re-expriment et que les mécanismes de contrôle, tels que ceux qui déclenchent l'apoptose de la cellule, sont hors-jeu. C'est alors qu'un point de non-retour peut-être franchi et que les cellules, pour se maintenir en vie dans ces conditions, adoptent un comportement cancéreux et délétère pour l'organisme.

Ces hypothèses pourraient donc être testées sur le modèle des RBS via le simulateur d'évolution artificielle. Le scénario d'une telle expérience pourrait consister à faire évoluer les réseaux dans un premier environnement pendant de nombreuses

[31] VINCENT « Cancer : a de-repression of a default survival program common to all cells? : a life-history perspective on the nature of cancer. » (2012)

[32] JACQUET et STÉPHANOU « A reduced model of cell metabolism to revisit the glycolysis-OXPHOS relationship in the deregulated tumor microenvironment » (2023)

générations. Puis, progressivement, modifier l'environnement pour pousser les réseaux à évoluer. Enfin, un stress intense serait imposé aux réseaux, en rebasculant brutalement sur la condition de viabilité du premier environnement et en augmentant le bruit et le taux de mutation par exemple, ce stress final cherchant à refaire émerger les comportements des premiers réseaux de la lignée. Est-ce que les réseaux qui en résulteraient présenteraient effectivement une régression de leur comportement? Est-ce que cela aura tendance à sélectionner des réseaux de complexité moyenne, en tout cas attendus pour une grande évolutivité et robustesse? D'une manière plus globale, l'étude des lignées de réseaux ainsi obtenues pourrait permettre de tester si les comportements évolués les plus récemment sont en effet moins robustes que ceux apparus plus tôt. Cela permettrait également de tester si ces comportements sont véritablement conservés et régulés par les ajouts plus tardifs.

BIBLIOGRAPHIE

- [1] Urvan CHRISTEN, Sergiu IVANOV, Rémi SEGRETAINE, Laurent TRILLING et Nicolas GLADE. « On Computing Structural and Behavioral Complexities of Threshold Boolean Networks ». Dans : *Acta Biotheoretica* 68.1 (2019), p. 119-138. DOI : [10.1007/s10441-019-09358-8](https://doi.org/10.1007/s10441-019-09358-8).
- [2] Rémi SEGRETAINE, Sergiu IVANOV, Laurent TRILLING et Nicolas GLADE. « A Methodology for Evaluating the Extensibility of Boolean Networks' Structure and Function ». Dans : *Complex Networks & Their Applications IX* (2021), p. 372-385. DOI : [10.1007/978-3-030-65351-4_30](https://doi.org/10.1007/978-3-030-65351-4_30).
- [3] Rémi SEGRETAINE, Sergiu IVANOV, Laurent TRILLING et Nicolas GLADE. « Implementation of a Computing Pipeline for Evaluating the Extensibility of Boolean Networks' Structure and Function ». Dans : *bioRxiv* (2020). DOI : [10.1101/2020.10.02.323949](https://doi.org/10.1101/2020.10.02.323949).
- [4] Remi SEGRETAINE, Laurent TRILLING, Nicolas GLADE et Sergiu IVANOV. « Who Plays Complex Music? On the Correlations Between Structural and Behavioral Complexity Measures in Sign Boolean Networks ». Dans : *2021 IEEE 21st International Conference on Bioinformatics and Bioengineering (BIBE)*. IEEE, 2021. DOI : [10.1109/bibe52308.2021.9635403](https://doi.org/10.1109/bibe52308.2021.9635403).
- [5] R. THOMAS. « On the Relation Between the Logical Structure of Systems and Their Ability to Generate Multiple Steady States or Sustained Oscillations ». Dans : *Springer Series in Synergetics*. Springer Berlin Heidelberg, 1981, p. 180-193. DOI : [10.1007/978-3-642-81703-8_24](https://doi.org/10.1007/978-3-642-81703-8_24).
- [6] Warren S. McCULLOCH et Walter PITTS. « A logical calculus of the ideas immanent in nervous activity ». Dans : *The Bulletin of Mathematical Biophysics* 5.4 (1943), p. 115-133. DOI : [10.1007/bf02478259](https://doi.org/10.1007/bf02478259).
- [7] J J HOPFIELD. « Neural networks and physical systems with emergent collective computational abilities. » Dans : *Proceedings of the National Academy of Sciences* 79.8 (1982), p. 2554-2558. DOI : [10.1073/pnas.79.8.2554](https://doi.org/10.1073/pnas.79.8.2554).
- [8] S.A. KAUFFMAN. « Metabolic stability and epigenesis in randomly constructed genetic nets ». Dans : *Journal of Theoretical Biology* 22.3 (1969), p. 437-467. DOI : [10.1016/0022-5193\(69\)90015-0](https://doi.org/10.1016/0022-5193(69)90015-0).
- [9] Stefan BORNHOLDT. « Boolean network models of cellular regulation : prospects and limitations ». Dans : *Journal of The Royal Society Interface* 5.suppl_1 (2008). DOI : [10.1098/rsif.2008.0132.focus](https://doi.org/10.1098/rsif.2008.0132.focus).
- [10] Van TRAN, Matthew N. MCCALL, Helene R. McMURRAY et Anthony ALMUDEVAR. « On the underlying assumptions of threshold Boolean networks as a model for genetic regulatory network behavior ». Dans : *Frontiers in Genetics* 4 (2013). DOI : [10.3389/fgene.2013.00263](https://doi.org/10.3389/fgene.2013.00263).
- [11] Luis MENDOZA et Elena R. ALVAREZ-BUYLLA. « Dynamics of the Genetic Regulatory Network for Arabidopsis thaliana Flower Morphogenesis ». Dans : *Journal of Theoretical Biology* 193.2 (1998), p. 307-319. DOI : [10.1006/jtbi.1998.0701](https://doi.org/10.1006/jtbi.1998.0701).

- [12] Nicolas GLADE, Adrien ELENA, Fabien CORBLIN, Eric FANCHON, Jacques DEMONGEOT et Hedi BEN-AMOR. « Determination, Optimization and Taxonomy of Regulatory Networks : The Example of Arabidopsis thaliana Flower Morphogenesis ». Dans : *2011 IEEE Workshops of International Conference on Advanced Information Networking and Applications*. IEEE, 2011. DOI : [10.1109/waina.2011.155](https://doi.org/10.1109/waina.2011.155).
- [13] Hedi Ben AMOR, Fabien CORBLIN, Eric FANCHON, Adrien ELENA, Laurent TRILLING, Jacques DEMONGEOT et Nicolas GLADE. « Formal Methods for Hopfield-Like Networks ». Dans : *Acta Biotheoretica* 61.1 (2013), p. 21-39. DOI : [10.1007/s10441-013-9169-5](https://doi.org/10.1007/s10441-013-9169-5).
- [14] Nicolas GLADE. « Le Vivant Rare, Faible et Amorphe. Evolution depuis les Origines jusqu'à la Vie telle qu'elle nous Apparaît ». Thèse de doct. 2022.
- [15] Adrien ELENA. « Robustesse des réseaux d'automates booléens à seuil aux modes d'itération : application à la modélisation des réseaux de régulation génétique ». Thèse de doctorat dirigée par Demongeot, Jacques Modèles, méthodes et algorithmes en biologie, santé et environnement Grenoble 1 2009. Thèse de doct. 2009, 1 vol. (148 p.) URL : <http://www.theses.fr/2009GRE10068>.
- [16] S. MUROGA, T. TSUBOI et C.R. BAUGH. « Enumeration of Threshold Functions of Eight Variables ». Dans : *IEEE Transactions on Computers* C-19.9 (1970), p. 818-825. DOI : [10.1109/t-c.1970.223046](https://doi.org/10.1109/t-c.1970.223046).
- [17] P.C. OJHA. « Enumeration of linear threshold functions from the lattice of hyperplane intersections ». Dans : *IEEE Transactions on Neural Networks* 11.4 (2000), p. 839-850. DOI : [10.1109/72.857765](https://doi.org/10.1109/72.857765).
- [18] Martin GEBSER, Benjamin KAUFMANN, Roland KAMINSKI, Max OSTROWSKI, Torsten SCHAUB et Marius SCHNEIDER. « Potassco : The Potsdam Answer Set Solving Collection ». Dans : *AI Communications* 24.2 (2011), p. 107-124. DOI : [10.3233/aic-2011-0491](https://doi.org/10.3233/aic-2011-0491).
- [19] A. N. KOLMOGOROV. « Three approaches to the quantitative definition of information ». Dans : *International Journal of Computer Mathematics* 2.1-4 (1968), p. 157-168. DOI : [10.1080/00207166808803030](https://doi.org/10.1080/00207166808803030).
- [20] Fernando SOLER-TOSCANO, Hector ZENIL, Jean-Paul DELAHAYE et Nicolas GAUVRIT. « Calculating Kolmogorov Complexity from the Output Frequency Distributions of Small Turing Machines ». Dans : *PLoS ONE* 9.5 (2014). Sous la dir. de Matthias DEHMER, e96223. DOI : [10.1371/journal.pone.0096223](https://doi.org/10.1371/journal.pone.0096223).
- [21] Hector ZENIL, Santiago HERNÁNDEZ-OROZCO, Narsis KIANI, Fernando SOLER-TOSCANO, Antonio RUEDA-TOICEN et Jesper TEGNÉR. « A Decomposition Method for Global Evaluation of Shannon Entropy and Local Estimations of Algorithmic Complexity ». Dans : *Entropy* 20.8 (2018), p. 605. DOI : [10.3390/e20080605](https://doi.org/10.3390/e20080605).
- [22] Mark PAGEL, Ciara O'DONOVAN et Andrew MEADE. « General statistical model shows that macroevolutionary patterns and processes are consistent with Darwinian gradualism ». Dans : *Nature Communications* 13.1 (2022). DOI : [10.1038/s41467-022-28595-z](https://doi.org/10.1038/s41467-022-28595-z).

- [23] Andreas WAGNER. « Robustness and evolvability : a paradox resolved ». Dans : *Proceedings of the Royal Society B : Biological Sciences* 275.1630 (2007), p. 91-100. DOI : [10.1098/rspb.2007.1137](https://doi.org/10.1098/rspb.2007.1137).
- [24] Fabien CORBLIN, Eric FANCHON, Laurent TRILLING, Claudine CHAOUÏYA et Denis THIEFFRY. « Automatic Inference of Regulatory and Dynamical Properties from Incomplete Gene Interaction and Expression Data ». Dans : *Information Processign in Cells and Tissues*. Springer Berlin Heidelberg, 2012, p. 25-30. DOI : [10.1007/978-3-642-28792-3_4](https://doi.org/10.1007/978-3-642-28792-3_4).
- [25] Quoc-Trung VUONG, Roselyne CHAUVIN, Sergiu IVANOV, Nicolas GLADE et Laurent TRILLING. « A Logical Constraint-based Approach to Infer and Explore Diversity and Composition in Thresholded Boolean Automaton Networks ». Dans : *Complex Networks & Their Applications VI*. Springer International Publishing, 2017, p. 567-579. DOI : [10.1007/978-3-319-72150-7_46](https://doi.org/10.1007/978-3-319-72150-7_46).
- [26] Stephanie CHEVALIER, Christine FROIDEVAUX, Loic PAULEVE et Andrei ZINOVYEV. « Synthesis of Boolean Networks from Biological Dynamical Constraints using Answer-Set Programming ». Dans : *2019 IEEE 31st International Conference on Tools with Artificial Intelligence (ICTAI)*. IEEE, 2019. DOI : [10.1109/ictai.2019.00014](https://doi.org/10.1109/ictai.2019.00014).
- [27] Jean-Philippe RENNARD. *Vie Artificielle - Où la biologie rencontre l'informatique*. Sous la dir. de VUIBERT. 2002. ISBN : 2-7117-8694-3.
- [28] Anton CROMBACH et Paulien HOGEWEG. « Evolution of Evolvability in Gene Regulatory Networks ». Dans : *PLoS Computational Biology* 4.7 (2008). Sous la dir. d'Herbert M. SAURO, e1000112. DOI : [10.1371/journal.pcbi.1000112](https://doi.org/10.1371/journal.pcbi.1000112).
- [29] Lucien ISRAEL. « Tumour Progression : Random Mutations or an Integrated Survival Response to Cellular Stress Conserved from Unicellular Organisms ? » Dans : *Journal of Theoretical Biology* 178.4 (1996), p. 375-380. DOI : [10.1006/jtbi.1996.0033](https://doi.org/10.1006/jtbi.1996.0033).
- [30] Charles H. LINEWEAVER, Paul C. W. DAVIES et Mark D. VINCENT. « Targeting cancer's weaknesses (not its strengths) : Therapeutic strategies suggested by the atavistic model. » Dans : *BioEssays : news and reviews in molecular, cellular and developmental biology* 36 (9 sept. 2014), p. 827-835. ISSN : 1521-1878. DOI : [10.1002/bies.201400070](https://doi.org/10.1002/bies.201400070). ppublish.
- [31] Mark VINCENT. « Cancer : a de-repression of a default survival program common to all cells ? : a life-history perspective on the nature of cancer. » Dans : *BioEssays : news and reviews in molecular, cellular and developmental biology* 34 (1 jan. 2012), p. 72-82. ISSN : 1521-1878. DOI : [10.1002/bies.201100049](https://doi.org/10.1002/bies.201100049). ppublish.
- [32] Pierre JACQUET et Angélique STÉPHANOU. « A reduced model of cell metabolism to revisit the glycolysis-OXPHOS relationship in the deregulated tumor microenvironment ». Dans : *Journal of Theoretical Biology* 562 (2023), p. 111434. DOI : [10.1016/j.jtbi.2023.111434](https://doi.org/10.1016/j.jtbi.2023.111434).

COLOPHON

Ce manuscrit a été rédigé à l'aide du modèle `classicthesis` développé par André Miede, inspiré par le livre *“The Elements of Typographic Style”* de Robert Bringhurst. `classicthesis` est disponible pour L^AT_EX et L^YX :

<https://bitbucket.org/amiede/classicthesis/>

André Miede encourage vivement les utilisateurs ayant apprécié son modèle à le faire savoir en lui envoyant une carte postale, ce que j'ai bien l'intention de faire. Une collection de celles reçues jusqu'ici est disponible au lien suivant :

<http://postcards.miede.de/>